Статистика и емпирични методи

2025/2026

Илиан Запрянов

20 юли 2026 г.

Съдържание

1 Въведение **7**

1.1 Случаен експеримент и елементарни събития . . . 7

1.2 σ-алгебра . . . 8

1.3 Топология и Борелова σ-алгебра . . . 9

2 Вероятност и вероятностно пространство **11**

2.1 Дефиниция и аксиоми . . . 11

2.2 Вероятностно пространство . . . 12

3 Равномерна, условна и пълна вероятност **15**

3.1 Равномерна (класическа) вероятност . . . 15

3.2 Условна вероятност . . . 16

3.3 Независимост . . . 16

3.4 Формула за пълната вероятност и формула на Бейс . . . 17

4 Случайни величини **19**

4.1 Дефиниция и основни свойства . . . 19

4.2 Дискретни случайни величини . . . 21

4.3 Смяна на променливите . . . 22

4.4 Съвместни дискретни разпределения . . . 22

4.5 Независимост на дискретни случайни величини . . . 23

4.6 Функция на разпределение . . . 23

5 Очакване, дисперсия, пораждащи функции **25**

5.1 Математическо очакване . . . 25

5.2 Свойства на математическото очакване . . . 25

5.3 Дисперсия . . . 27

5.4 Свойства на дисперсията . . . 27

5.5 Пораждащи функции . . . 29

6 Основни дискретни разпределения **31**

6.1 Схема на Бернули . . . 31

6.2 Разпределение на Бернули . . . 31

6.3 Биномно разпределение . . . 31

6.4 Геометрично разпределение . . . 32

6.5 Отрицателно биномно разпределение . . . 33

6.6 Поасоново разпределение . . . 34

6.7 Сходимост по разпределение и теорема на Поасон . . . 35

6.8 Хипергеометрично разпределение . . . 36

7 Ковариация, корелация **39**
7.1 Съвместна функция на разпределение и независимост . . . 39
7.2 Ковариация . . . 40
7.3 Корелация . . . 41

8 Условно математическо очакване **43**
8.1 Мотивация: най-добра прогноза . . . 43
8.2 Дефиниция . . . 43
8.3 Свойства на условното математическо очакване . . . 45
8.4 Условно разпределение . . . 46

9 Непрекъснати случайни величини **47**
9.1 Дефиниция и плътност . . . 47
9.2 Функция на разпределение . . . 48
9.3 Смяна на променливите . . . 48
9.4 Математическо очакване . . . 49
9.5 Дисперсия . . . 50

10 Видове непрекъснати случайни величини **53**
10.1 Равномерно разпределение . . . 53
10.2 Нормално (Гаусово) разпределение . . . 54
10.3 Експоненциално разпределение . . . 56

11 Непрекъснати съвместни разпределения, Гама разпределение **59**
11.1 Съвместни непрекъснати разпределения . . . 59
11.2 Очакване за случаен вектор . . . 60
11.3 Смяна на променливите (многомерна) . . . 61
11.4 Гама разпределение . . . 63
11.5 χ^2 разпределение . . . 64
11.6 t-разпределение (на Стюдънт) . . . 65

12 Сходимост и закони за големите числа **67**
12.1 Видове сходимост . . . 67
12.2 Неравенство на Чебишов (обобщение) . . . 69
12.3 Закони за големите числа . . . 70

13 Централна гранична теорема **73**
13.1 Функции на моментите . . . 73
13.2 Централна гранична теорема . . . 75
13.3 Функция на моментите на Гама разпределението . . . 76

14 Точкови оценки **77**
14.1 Постановка . . . 77
14.2 Максимално правдоподобни оценки . . . 77
14.3 Метод на моментите . . . 79
14.4 Свойства на точковите оценки . . . 80

15 Доверителни интервали и хипотези **83**
15.1 Доверителни интервали . . . 83
15.2 Доверителни интервали за средната стойност на нормално разпределение . . . 84
15.3 Доверителни интервали за дисперсията на нормално разпределение . . . 86
15.4 Проверка на хипотези . . . 86

16 Линейна регресия **89**
16.1 Модел на линейната регресия 89
16.2 Статистически модел и оценки на параметрите 90
16.3 Оценка на дисперсията на грешката 91
16.4 Проверка на хипотези за наклона 92

Тема 1

Въведение

1.1 Случаен експеримент и елементарни събития

Дефиниция 1.1 (Случаен експеримент)

Случаен експеримент е опит или наблюдение, чийто изход не може да бъде предсказан предварително. Всеки възможен елементарен резултат от този експеримент наричаме **елементарно събитие** и го означаваме с малка гръцка буква (обикновено ω).

Мотивация

Случайният експеримент е моделът, чрез който математиката хваща явления с недетерминиран изход - от хвърляне на монета и зар, през резултати от избори, до напълно непрекъснати процеси. Класически пример за такъв процес е **Брауновото движение**: през 1827 г. ботаникът Робърт Браун наблюдава хаотичното движение на прашец във вода, а през 1905 г. Айнщайн му дава строго вероятностно обяснение. Именно нуждата от такива по-сложни пространства ни води до общата дефиниция по-долу.

Дефиниция 1.2 (Пространство от елементарни събития)

Пространството от елементарни събития е множеството от всички възможни елементарни събития за даден случаен експеримент. Означава се с главна гръцка буква (обикновено Ω).

Дефиниция 1.3 (Събитие)

Нека Ω е пространството от елементарни събития за даден случаен експеримент. Всяко подмножество $A \subseteq \Omega$ наричаме **събитие**. Едно събитие *настъпва*, ако резултатът ω от експеримента е елемент на това подмножество, т.е. $\omega \in A$. Най-често събитието групира елементарни събития по даден признак (рядко е точно едно елементарно събитие).

Операции с events (кратко резюме)

Събитията са множества, затова върху тях работят обичайните операции и закони от теория на множествата:

- $A \subseteq B \iff \forall \omega \in A \Rightarrow \omega \in B$ (влагане); $A = B \iff A \subseteq B$ и $B \subseteq A$.
- $A \cup B = \{\omega \in \Omega : \omega \in A$ или $\omega \in B\}$ - „*или*“;
- $A \cap B = \{\omega \in \Omega : \omega \in A$ и $\omega \in B\}$ - „*и*“;
- $A^c = \{\omega \in \Omega : \omega \notin A\}$ - *допълнение* (по-рядко: отрицание), като $\Omega = A \cup A^c$;
- $A \setminus B = A \cap B^c$ („A без B“);
- комутативност: $A \cup B = B \cup A$, $A \cap B = B \cap A$;
- асоциативност: $A \cup (B \cup C) = (A \cup B) \cup C$;
- дистрибутивност: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ и двойственото ѝ равенство;
- инволутивност: $(A^c)^c = A$;
- закони на Де Морган: $(\bigcup_{i=1}^{\infty} A_i)^c = \bigcap_{i=1}^{\infty} A_i^c$, $\quad (\bigcap_{i=1}^{\infty} A_i)^c = \bigcup_{i=1}^{\infty} A_i^c$.

1.2 σ-алгебра

Дефиниция 1.4 (σ-алгебра)

Нека Ω е произволно множество (наричано пространство от елементарни събития) и нека $\mathcal{A}$ е система от подмножества на Ω (т.е. $\mathcal{A} \subseteq \mathcal{P}(\Omega)$). Казваме, че $\mathcal{A}$ е **σ-алгебра** на Ω, ако са изпълнени:

1) $\Omega \in \mathcal{A}$ ($\mathcal{A}$ съдържа цялото пространство);

2) ако $A \in \mathcal{A}$, то $A^c = \Omega \setminus A \in \mathcal{A}$ (затвореност относно допълнение);

3) ако $A_1, A_2, \dots \in \mathcal{A}$, то $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$ (затвореност относно изброимо обединение).

Следствие 1.1 (основни свойства)

Ако $\mathcal{A}$ е σ-алгебра на Ω, то:

- $\varnothing \in \mathcal{A}$;
- ако $A_i \in \mathcal{A}$ за всяко $i \geq 1$, то $\bigcap_{i=1}^{\infty} A_i \in \mathcal{A}$ (затвореност и относно изброимо сечение);
- ако $A_1, \dots, A_n \in \mathcal{A}$, то $\bigcup_{i=1}^{n} A_i \in \mathcal{A}$ и $\bigcap_{i=1}^{n} A_i \in \mathcal{A}$ (затвореност и относно *крайно* обединение/сечение).

Доказателство

Понеже $\Omega \in \mathcal{A}$ и $\Omega^c = \varnothing$, от аксиома 2) следва $\varnothing = \Omega^c \in \mathcal{A}$.
Нека $A_i \in \mathcal{A}$ за всяко $i \geq 1$. От аксиома 2) $A_i^c \in \mathcal{A}$ за всяко i, а от аксиома 3), приложена към редицата $\{A_i^c\}$, следва $\bigcup_{i=1}^{\infty} A_i^c \in \mathcal{A}$. Прилагайки отново аксиома 2) към това обединение и закона на Де Морган:

$$\left(\bigcup_{i=1}^{\infty} A_i^c\right)^c \in \mathcal{A} \quad \Longrightarrow \quad \bigcap_{i=1}^{\infty} A_i \in \mathcal{A}.$$

За крайното обединение: нека $A_1, \ldots, A_n \in \mathcal{A}$. Допълваме редицата с $A_{n+k} := \varnothing$ за $k \geq 1$ (знаем вече, че $\varnothing \in \mathcal{A}$). Тогава по аксиома 3)

$$\bigcup_{i=1}^{n} A_i = \bigcup_{i=1}^{\infty} A_i \in \mathcal{A}.$$

Затвореността относно крайно сечение следва по същия начин чрез допълнение и закона на Де Морган. ■

Примери

Нека $\Omega = \{a, b\}$. Най-простата възможна σ-алгебра е **тривиалната** $\mathcal{A}_1 = \{\varnothing, \Omega\}$. От другата страна, **дискретната** (пълна) σ-алгебра е $2^{\Omega} = \{\varnothing, \Omega, \{a\}, \{b\}\}$ - множеството от *всички* подмножества на Ω; тя винаги е σ-алгебра и съдържа $2^{|\Omega|}$ елемента. За произволна крайна извадка от n изхода имаме $|2^{\Omega}| = 2^n$ възможни събития.

1.3 Топология и Борелова σ-алгебра

Дефиниция 1.5 (Система от отворени множества)

Нека X е произволно множество. Система от отворени множества (**топология**) е съвкупност $\tau \subseteq 2^X$, която удовлетворява аксиомите:

1) Празното множество и цялото пространство са отворени.

2) Обединението на произволен брой отворени множества е отворено.

3) Сечението на *крайно много* отворени множества е отворено.

Дефиниция 1.6 (Породена / Борелова σ-алгебра)

Нека Ω е множество от елементарни събития и G е произволна колекция от подмножества на Ω. Най-малката σ-алгебра, съдържаща G, се нарича **породена от** G **σ-алгебра** и се означава с $\sigma(G)$:

$$\sigma(G) := \bigcap_{\substack{\mathcal{A} \supseteq G \\ \mathcal{A}\ \sigma\text{-алгебра}}} \mathcal{A}.$$

Ако (X, τ) е топологично пространство, **Бореловата σ-алгебра** е $\mathcal{B}(X) := \sigma(\tau)$ - най-малката σ-алгебра, съдържаща всички отворени множества на τ.

Пример: породена σ-алгебра от три събития

Нека A, B, C образуват пълна група от несъвместими събития в Ω (т.е. A, B, C са по двойки непресичащи се и $A \cup B \cup C = \Omega$) и $G = \{A, B, C\}$. Тогава породената σ-алгебра е крайна:

$$\sigma(G) = \{\varnothing, \Omega, A, B, C, A \cup B, A \cup C, B \cup C\}.$$

Така изброимо-безкрайният проблем се редуцира до събиране на краен брой непресичащи се „тухлички“.

Пример: Бореловата σ-алгебра на $\mathbb{R}$

За $\Omega = \mathbb{R}$ с обичайната топология, $\mathcal{B}(\mathbb{R})$ съдържа всички интервали (a, b), (a, ∞), $(-\infty, a)$ за $a, b \in \mathbb{R}$, $a < b$. Съдържа и всяко едноточково множество $\{a\}$, защото

$$\{a\} = \bigcap_{i=1}^{\infty} \left(a - \tfrac{1}{i},\, a + \tfrac{1}{i}\right) \in \mathcal{B}(\mathbb{R}),$$

а оттам и $[a, b) = \{a\} \cup (a, b) \in \mathcal{B}(\mathbb{R})$, $[a, b] = \{a\} \cup (a, b) \cup \{b\} \in \mathcal{B}(\mathbb{R})$.

Тема 2

Вероятност и вероятностно пространство

2.1 Дефиниция и аксиоми

Дефиниция 2.1 (Вероятност)

Нека Ω е пространство от елементарни събития и нека $\mathcal{A}$ е σ-алгебра над Ω. **Вероятността** (вероятностна мярка) е функция $\mathbb{P} : \mathcal{A} \to [0,1]$, за която:

- $\mathbb{P}(A) \geq 0$ за всяко $A \in \mathcal{A}$;
- $\mathbb{P}(\Omega) = 1$;
- ако $A_1, \ldots, A_n, \ldots$ са несъвместими (т.е. $A_i \cap A_j = \varnothing$ за $i \neq j$), то $\mathbb{P}\Big(\bigcup_{i=1}^{\infty} A_i\Big) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$ (σ-адитивност).

Следствие 2.1 (основни свойства на вероятността)

Нека $\mathbb{P} : \mathcal{A} \to [0,1]$ е вероятност. Тогава са в сила:

а) $0 \leq \mathbb{P}(A) \leq 1$;

б) $\mathbb{P}(\varnothing) = 0$;

в) $\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A)$;

г) ако $A \cap B = \varnothing$, то $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$;

д) в общия случай $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$;

е) ако $A \subseteq B$, то $\mathbb{P}(A) \leq \mathbb{P}(B)$ (монотонност);

ж) (непрекъснатост отдолу) ако $A_1 \subseteq A_2 \subseteq \cdots \subseteq A_n \subseteq \ldots$, то $\mathbb{P}\Big(\bigcup_{j=1}^{\infty} A_j\Big) = \lim_{n\to\infty} \mathbb{P}(A_n)$;

з) (непрекъснатост отгоре) ако $A_1 \supseteq A_2 \supseteq \cdots \supseteq A_n \supseteq \ldots$, то $\mathbb{P}\Big(\bigcap_{i=1}^{\infty} A_i\Big) = \lim_{n\to\infty} \mathbb{P}(A_n)$;

и) (изброима субадитивност) ако $A_i \in \mathcal{A}$ за $i \geq 1$, то $\sum_{i=1}^{\infty} \mathbb{P}(A_i) \geq \mathbb{P}\Big(\bigcup_{i=1}^{\infty} A_i\Big)$, като същото важи и за крайно обединение: $\sum_{i=1}^{n} \mathbb{P}(A_i) \geq \mathbb{P}\big(\bigcup_{i=1}^{n} A_i\big)$ за $n \in \mathbb{N}$.

Доказателство

б) Понеже $\Omega \cap \varnothing = \varnothing$ (несъвместимо обединение) и $\Omega \cup \varnothing = \Omega$, по σ-адитивност $\mathbb{P}(\Omega) = \mathbb{P}(\Omega) + \mathbb{P}(\varnothing) \Rightarrow \mathbb{P}(\varnothing) = 0$.
а) От $\varnothing \subseteq A \subseteq \Omega$ и монотонността (доказана в (е) по-долу, независимо от (а)) получаваме $\mathbb{P}(\varnothing) \leq \mathbb{P}(A) \leq \mathbb{P}(\Omega)$, т.е. $0 \leq \mathbb{P}(A) \leq 1$.
в) От $\Omega = A \cup \bar{A}$ (несъвместимо обединение) и σ-адитивността: $1 = \mathbb{P}(A) + \mathbb{P}(\bar{A}) \Rightarrow \mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A)$.
г) Директно от σ-адитивността, приложена към две несъвместими събития (допълнена с $\varnothing, \varnothing, \dots$).
д) Пишем $A \cup B = A \cup (B \setminus A)$, като двете части са несъвместими, следователно $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A)$. От друга страна $B = (B \setminus A) \cup (A \cap B)$ (несъвместимо разбиване), т.е. $\mathbb{P}(B) = \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B)$, откъдето $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A \cap B)$. Заместваме и получаваме $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.
е) Пишем $B = A \cup (B \setminus A)$ - несъвместимо обединение, следователно $\mathbb{P}(B) = \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus A)}_{\geq 0} \geq \mathbb{P}(A)$.
ж) (непрекъснатост отдолу) Нека $A_1 \subseteq A_2 \subseteq \dots$ и $A = \bigcup_{n=1}^{\infty} A_n$. Дефинираме $C_1 = A_1$, $C_k = A_k \setminus A_{k-1}$ за $k \geq 2$. Тогава C_k са по двойки несъвместими и $A_n = \bigcup_{k=1}^{n} C_k$, $A = \bigcup_{k=1}^{\infty} C_k$. По σ-адитивност $\mathbb{P}(A_n) = \sum_{k=1}^{n} \mathbb{P}(C_k)$ и $\mathbb{P}(A) = \sum_{k=1}^{\infty} \mathbb{P}(C_k)$. Но сумата на реда по дефиниция е границата на частичните суми, откъдето $\lim_{n \to \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$.

Доказателство

з) (непрекъснатост отгоре) Първо разглеждаме частния случай, в който редицата се свива до празното множество: $B_1 \supseteq B_2 \supseteq \cdots \supseteq B_n \supseteq \ldots$ и $\bigcap_{j=1}^{\infty} B_j = \varnothing$. Трябва да покажем, че $0 = \mathbb{P}(\varnothing) = \lim_{n\to\infty} \mathbb{P}(B_n)$.
Всеки елемент на B_1 отпада от редицата на някоя стъпка, защото иначе би бил във всички B_j, т.е. в сечението. Затова B_1 се разбива на несъвместими „венци“ $B_j \setminus B_{j+1}$, и по същата причина това важи за всяко B_n:

$$B_1 = \bigcup_{j=1}^{\infty} (B_j \setminus B_{j+1}), \qquad B_n = \bigcup_{j=n}^{\infty} (B_j \setminus B_{j+1}).$$

По σ-адитивност

$$1 \;\geq\; \mathbb{P}(B_1) = \sum_{j=1}^{\infty} \mathbb{P}(B_j \setminus B_{j+1}) < \infty, \qquad \mathbb{P}(B_n) = \sum_{j=n}^{\infty} \mathbb{P}(B_j \setminus B_{j+1}) \xrightarrow[n\to\infty]{} 0.$$

Първият ред е сходящ, а $\mathbb{P}(B_n)$ е неговата остатъчна сума след $n-1$ члена, която за сходящ ред клони към 0. Това е точно непрекъснатостта в $\varnothing$.
Общият случай се свежда до частния. Нека $A_1 \supseteq A_2 \supseteq \ldots$ и $A = \bigcap_{i=1}^{\infty} A_i$. Полагаме $B_n = A_n \setminus A$. Тогава B_n намаляват и $\bigcap_n B_n = \varnothing$, а понеже $A \subseteq A_n$, имаме $\mathbb{P}(A_n) = \mathbb{P}(A) + \mathbb{P}(B_n) \to \mathbb{P}(A)$.
и) (субадитивност, чрез „венци“) Нека

$$B_1 = A_1, \quad B_2 = A_2 \setminus A_1, \quad B_3 = A_3 \setminus (A_2 \cup A_1), \quad \ldots, \quad B_n = A_n \setminus \bigcup_{i=1}^{n-1} A_i.$$

Тогава $B_i \cap B_j = \varnothing$ за $i \neq j$ (по конструкция) и $B_i \subseteq A_i$ за всяко i, откъдето по монотонност (е) $\mathbb{P}(B_i) \leq \mathbb{P}(A_i)$. Освен това $\bigcup_i B_i = \bigcup_i A_i$: включването „$\subseteq$“ е очевидно ($B_i \subseteq A_i$); за „$\supseteq$“ - ако $\omega \in \bigcup_i A_i$, нека $k = \min\{i \geq 1 : \omega \in A_i\}$; тогава $\omega \notin \bigcup_{i=1}^{k-1} A_i$, т.е. $\omega \in B_k \subseteq \bigcup_i B_i$. Следователно, по σ-адитивност и монотонност,

$$\mathbb{P}\Big(\bigcup_i A_i\Big) = \mathbb{P}\Big(\bigcup_i B_i\Big) = \sum_i \mathbb{P}(B_i) \leq \sum_i \mathbb{P}(A_i).$$

Крайният случай се получава аналогично (или чрез допълване с $\varnothing$). ■

2.2 Вероятностно пространство

Дефиниция 2.2 (Вероятностно пространство)

Вероятностно пространство е наредена тройка $(\Omega, \mathcal{A}, \mathbb{P})$, където:

- Ω е пространството на елементарните събития - непразно множество от всички възможни резултати от даден случаен експеримент;
- $\mathcal{A}$ е σ-алгебра на събитията върху Ω;
- $\mathbb{P}$ е вероятностна мярка, т.е. функция $\mathbb{P} : \mathcal{A} \to [0, 1]$, удовлетворяваща аксиомите от предната дефиниция.

Забележка

Ако първоначалното вероятностно пространство е било $(\Omega, \mathcal{A}, \mathbb{P})$ и ограничим вниманието си само до събития, съдържащи се в дадено фиксирано $B \in \mathcal{A}$ с $\mathbb{P}(B) > 0$, естествено е новото пространство от елементарни събития да стане самото B (вместо цялото Ω), с σ-алгебра $\mathcal{A} \cap B := \{A \cap B : A \in \mathcal{A}\}$ (следата на $\mathcal{A}$ върху B) и нова вероятностна мярка $\mathbb{P}(\cdot \mid B)$ - идея, върху която стъпва условната вероятност в следващата глава.

Тема 3

Равномерна, условна и пълна вероятност

3.1 Равномерна (класическа) вероятност

Дефиниция 3.1 (Равномерна вероятност)

За крайно вероятностно пространство с n на брой равновъзможни изхода, вероятността за всяко отделно събитие се дефинира като

$$\mathbb{P}(A) = \frac{\text{брой на благоприятните изходи за } A}{\text{общ брой възможни изходи}} = \frac{|A|}{n}.$$

Основни характеристики: *симетричност* (всички елементарни изходи са еднакво вероятни), *нормираност* (сумата от вероятностите на елементарните изходи е 1) и *простота* (пресмятането на вероятности се свежда до броене на благоприятни случаи).

Формално представяне

Нека $\Omega = \{s_1, \dots, s_n\}$ и $\mathbb{P}(s_i) = \frac{1}{n}$ за всяко i. За произволно събитие $A \subseteq \Omega$: $\mathbb{P}(A) = \frac{|A|}{n}$, където $|A|$ е броят на благоприятните изходи.

Дефиниция 3.2 (Дискретна вероятност)

Когато $\Omega = \{\omega_1, \omega_2, \dots\}$ е изброимо (но не непременно с равновероятни изходи), дискретна вероятност се задава чрез редица от числа $\{p_1, p_2, \dots\}$, $p_i \geq 0$, $\sum_{i=1}^{\infty} p_i = 1$, по правилото

$$\mathbb{P}(\{\omega_i\}) = p_i, \qquad \mathbb{P}(A) = \sum_{\omega_i \in A} p_i, \quad A \subseteq \Omega.$$

Дефиниция 3.3 (Геометрична вероятност)

Геометричната вероятност е пример за вероятностно разпределение върху *неизброимо* множество. За събитие A в геометрично пространство Ω (например $\Omega \subseteq \mathbb{R}^2$ с крайна мярка $|\Omega| = \int\int_{\Omega} dx < \infty$):

$$\mathbb{P}(A) = \frac{\text{мярка на благоприятната област } A}{\text{мярка на цялата област } \Omega} = \frac{|A|}{|\Omega|}.$$

Основни характеристики: безкраен брой изходи, работа с непрекъснати величини, използване на геометрични мерки (дължина за отсечки, площ за фигури, обем за тела).

Важно

За геометрична вероятност, вероятността точков резултат да се случи в дадена точка x е винаги нула: $\mathbb{P}(\{x\}) = \frac{|\{x\}|}{|\Omega|} = 0$, защото площта на точка е нула. Вероятността зависи само от мярката (площта/дължината/обема) на областта, а не от нейната локация или форма. *(Тази идея стои и в основата на алгоритмите на Монте Карло за приблизително пресмятане на мерки/интеграли чрез случайно семплиране.)*

3.2 Условна вероятност

Дефиниция 3.4 (Условна вероятност)

Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $B \in \mathcal{A}$ е такова, че $\mathbb{P}(B) > 0$. **Условната вероятност** на събитие A при условие B се дефинира като

$$\mathbb{P}_B(A) = \mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

В частност, ако $A \subseteq B$, то $A \cap B = A$, откъдето $\mathbb{P}(A \mid B) = \dfrac{\mathbb{P}(A)}{\mathbb{P}(B)}$ (коректно между 0 и 1, защото $A \subseteq B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$).

Забележка

Ако първоначалното вероятностно пространство е било $(\Omega, \mathcal{A}, \mathbb{P})$, то условната вероятност поражда ново вероятностно пространство $(B, \mathcal{A}\cap B, \mathbb{P}(\cdot \mid B))$, където новото пространство от елементарни събития е самото B (не цялото Ω), $\mathcal{A} \cap B := \{A \cap B : A \in \mathcal{A}\}$ е следата на $\mathcal{A}$ върху B, а мярката е условната вероятност $\mathbb{P}(\cdot \mid B)$ (не оригиналната $\mathbb{P}$).

3.3 Независимост

Дефиниция 3.5 (Независимост на две събития)

Две събития A и B се наричат **независими**, ако

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

Следствие 3.1

Ако $\mathbb{P}(A) > 0$, то A и B са независими точно когато $\mathbb{P}(B \mid A) = \mathbb{P}(B)$, т.е. независимостта означава, че настъпването на A не носи никаква информация за B.

Дефиниция 3.6 (Взаимна независимост (в съвкупност))

Дадени са събития $A_1, A_2, \ldots, A_n$. Казваме, че те са **независими взаимно (в съвкупност)**, ако за всяко непразно $M \subseteq \{1, \ldots, n\}$:

$$\mathbb{P}\Big(\bigcap_{i \in M} A_i\Big) = \prod_{i \in M} \mathbb{P}(A_i).$$

Т.е. вероятността да се случи кое да е подмножество на M от събитията се разпада на произведението на вероятностите да се случат съставните множества от M.

Теорема 3.1

Нека $A_1, A_2, \ldots, A_n$ са n събития, такива че $\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) > 0$. Тогава

$$\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) = \mathbb{P}(A_n \mid \bigcap_{i=1}^{n-1} A_i) \cdot \mathbb{P}(A_{n-1} \mid \bigcap_{i=1}^{n-2} A_i) \cdots \mathbb{P}(A_2 \mid A_1) \cdot \mathbb{P}(A_1).$$

Доказателство

По индукция по n.
База. За $n = 1$: $\mathbb{P}(A_1) = \mathbb{P}(A_1)$ - тривиално.
Индукционно предположение. Допускаме, че равенството е изпълнено за някое $n = k$.
Индукционна стъпка. Показваме го за $n = k + 1$:

$$\mathbb{P}\left(\bigcap_{i=1}^{k+1} A_i\right) = \mathbb{P}\left(A_{k+1} \cap \bigcap_{i=1}^{k} A_i\right) = \mathbb{P}\left(A_{k+1} \,\middle|\, \bigcap_{i=1}^{k} A_i\right) \cdot \mathbb{P}\left(\bigcap_{i=1}^{k} A_i\right),$$

и прилагаме индукционното предположение към последния множител. ■

Следствие 3.2

Ако $A_1, A_2, \ldots, A_n$ са (взаимно) независими, то

$$\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) = \prod_{i=1}^{n} \mathbb{P}(A_i).$$

3.4 Формула за пълната вероятност и формула на Бейс

Дефиниция 3.7 (Пълна група от събития)

Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство. Наборът от събития $\{A_1, A_2, \ldots, A_n\}$ (или безкрайна изброима редица $\{A_i\}_{i=1}^{\infty}$) се нарича **пълна група от събития**, ако са изпълнени условията:

- *несъвместимост (дизюнктност)*: $A_i \cap A_j = \varnothing$ за всички $i \neq j$ (никои две събития не могат да настъпят едновременно);
- *изчерпателност*: $\bigcup_{i=1}^{n} A_i = \Omega$ (за краен случай) или $\bigcup_{i=1}^{\infty} A_i = \Omega$ (за безкраен изброим случай) - т.е. всички заедно покриват цялото вероятностно пространство.

Теорема 3.2 (Формула за пълната вероятност)

Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $H_1, \ldots, H_n$ ($H_1, \ldots, H_n, \ldots$) е пълна група от събития. Тогава за всяко събитие $A \in \mathcal{A}$ е в сила:

$$\mathbb{P}(A) = \sum_{i} \mathbb{P}(A \cap H_i) = \sum_{i} \mathbb{P}(A \mid H_i) \cdot \mathbb{P}(H_i),$$

с конвенцията, че ако $\mathbb{P}(H_i) = 0$, то приемаме $\mathbb{P}(A \mid H_i) = 0$.

Доказателство

Понеже $\{H_i\}$ е пълна група, $A = A \cap \Omega = A \cap \bigcup_i H_i = \bigcup_i (A \cap H_i)$, като частите $A \cap H_i$ са по двойки несъвместими събития (наследяват несъвместимостта на H_i). Следователно, по σ-адитивност:

$$\mathbb{P}(A) = \mathbb{P}\Big(\bigcup_i (A \cap H_i)\Big) = \sum_i \mathbb{P}(A \cap H_i) = \sum_i \mathbb{P}(A \mid H_i)\,\mathbb{P}(H_i). \blacksquare$$

Теорема 3.3 (Формула на Бейс)

Нека $H_1, \ldots, H_n$ $(H_1, \ldots, H_n, \ldots)$ е пълна група от събития в Ω и нека $A \subseteq \Omega$ е такова, че $\mathbb{P}(A) > 0$. Тогава за всяко $1 \leq k \leq n$:

$$\mathbb{P}(H_k \mid A) = \frac{\mathbb{P}(A \mid H_k)\,\mathbb{P}(H_k)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid H_k)\,\mathbb{P}(H_k)}{\sum_i \mathbb{P}(A \mid H_i)\,\mathbb{P}(H_i)}.$$

Доказателство

От дефиницията на условна вероятност, приложена в двете посоки:

$$\mathbb{P}(A \cap H_k) = \mathbb{P}(A \mid H_k)\,\mathbb{P}(H_k) \qquad \text{и} \qquad \mathbb{P}(H_k \mid A)\,\mathbb{P}(A) = \mathbb{P}(H_k \cap A).$$

Следователно

$$\mathbb{P}(H_k \mid A) = \frac{\mathbb{P}(H_k \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(H_k)\,\mathbb{P}(A \mid H_k)}{\mathbb{P}(A)},$$

а по формулата за пълната вероятност заместваме $\mathbb{P}(A) = \sum_j \mathbb{P}(H_j)\,\mathbb{P}(A \mid H_j)$ в знаменателя. $\blacksquare$

Тема 4

Случайни величини

4.1 Дефиниция и основни свойства

Идея

Случайната величина е, грубо казано, функция/изображение, което на всяко елементарно събитие ω от Ω съпоставя някакво реално число. Резултатът е случаен, защото изходът ω е случаен, но самата функция е детерминистична - след като експериментът се случи, X приема една напълно определена числова стойност.

Дефиниция 4.1 (Случайна величина)

Нека $V = (\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство. Функцията $X : \Omega \to \mathbb{R}$ е **случайна величина** (стохастична), ако за всяко реално число $x \in \mathbb{R}$ праобразът на интервала $(-\infty, x)$ е събитие, т.е.

$$X^{-1}\big((-\infty, x)\big) = \{\omega \in \Omega : X(\omega) < x\} \in \mathcal{A}.$$

Това свойство се нарича **измеримост** на X спрямо σ-алгебрата $\mathcal{A}$ - трябва да можем да кажем каква е вероятността X да е по-малко от x, за всяко x.

Забележка

За да докажем, че X е случайна величина, е достатъчно да проверим, че $X^{-1}((-\infty, x)) \in \mathcal{A}$ за всяко $x \in \mathbb{R}$. Оттам насетне, за всяко борелово множество $B \in \mathcal{B}(\mathbb{R})$ следва по дефиниция, че $X^{-1}(B) \in \mathcal{A}$ - например за $B = [a, b]$, $B = \{a\}$, $B = (a, b)$ и т.н.

Теорема 4.1 (Свойства на случайните величини)

Нека V е вероятностно пространство и $X, Y : \Omega \to \mathbb{R}$ са случайни величини. Тогава:

1) $aX \pm bY$ е случайна величина за всички $a, b \in \mathbb{R}$;

2) cX е случайна величина за всяко $c \in \mathbb{R}$ (частен случай на 1) при $a = c$, $b = 0$);

3) XY е случайна величина;

4) $\dfrac{X}{Y}$ е случайна величина, ако $\mathbb{P}(Y_\omega{=}0) := \mathbb{P}(\{\omega \in \Omega : Y(\omega) = 0\}) = 0$.

Доказателство

1) Нека първо $Z_1 = aX$ при $a > 0$. За $\{aX < y\}$, $y \in \mathbb{R}$: $\{aX < y\} \overset{a>0}{=} \{X < \frac{y}{a}\} \in \mathcal{A}$, понеже X е случайна величина. Следователно $Z_1 = aX$ е случайна величина (аналогично се разглеждат случаите $a < 0$ и $a = 0$). По същия начин $Z_2 = bY$ е случайна величина. Остава да докажем, че $Z = Z_1 + Z_2$ е случайна величина, т.е. че $\{Z_1 + Z_2 < c\} \in \mathcal{A}$ за всяко $c \in \mathbb{R}$. Ключовото твърдение е:

$$\{Z_1 + Z_2 < c\} = \bigcup_{q \in \mathbb{Q}} \Big(\{Z_1 < q\} \cap \{Z_2 < c - q\} \Big).$$

(Обединението е по рационалните числа - изброимо, а не по $\mathbb{R}$ - точно защото σ-алгебрата гарантира затвореност само относно *изброимо* обединение.) За да докажем равенството на множествата $A = \{Z_1 + Z_2 < c\}$ и $B = \bigcup_q (\dots)$, показваме двете влагания:

- $B \subseteq A$: ако $\omega \in B$, съществува q такова, че $Z_1(\omega) < q$ и $Z_2(\omega) < c - q$; събирайки - $Z_1(\omega) + Z_2(\omega) < q + (c - q) = c$, т.е. $\omega \in A$.
- $A \subseteq B$: ако $\omega \in A$, то $Z_1(\omega) + Z_2(\omega) < c$, т.е. $Z_1(\omega) < c - Z_2(\omega)$. Поради гъстотата на $\mathbb{Q}$ в $\mathbb{R}$, съществува рационално q такова, че $Z_1(\omega) < q < c - Z_2(\omega)$; тогава $Z_1(\omega) < q$ и $Z_2(\omega) < c - q$, т.е. $\omega \in B$.

Всяко от множествата $\{Z_1 < q\}$, $\{Z_2 < c - q\}$ е от $\mathcal{A}$ (по измеримост на Z_1, Z_2), сечението им е от $\mathcal{A}$, а изброимото им обединение по $q \in \mathbb{Q}$ отново е от $\mathcal{A}$. Следователно $Z_1 + Z_2$ е случайна величина. ■

2) Частен случай на 1) при $b = 0$.

3) Записваме произведението алгебрично:

$$XY = \tfrac{1}{4}\big((X + Y)^2 - (X - Y)^2\big).$$

От 1) знаем, че $X \pm Y$ е случайна величина, а умножението с константа запазва свойството „случайна величина“ - остава да докажем, че квадратът на случайна величина също е случайна величина. Нека Z е произволна случайна величина; показваме $\{Z^2 < x\} \in \mathcal{A}$ за всяко $x \in \mathbb{R}$, разглеждайки два случая:

- $x \leq 0$: квадратът на реално число не може да е отрицателен, следователно $\{Z^2 < x\} = \varnothing \in \mathcal{A}$.
- $x > 0$: множеството $\{Z^2 < x\}$ е еквивалентно на $-\sqrt{x} < Z < \sqrt{x}$, т.е.

$$\{Z^2 < x\} = \{Z < \sqrt{x}\} \cap \{Z > -\sqrt{x}\}.$$

  Понеже Z е случайна величина, $\{Z < \sqrt{x}\} \in \mathcal{A}$; също $\{Z > -\sqrt{x}\} \in \mathcal{A}$, защото е допълнение на $\{Z \leq -\sqrt{x}\} \in \mathcal{A}$, а σ-алгебрите са затворени относно допълнение. Сечението на две множества от $\mathcal{A}$ също е в $\mathcal{A}$, следователно $\{Z^2 < x\} \in \mathcal{A}$.

Оттук XY, като линейна комбинация на квадрати на случайни величини, също е случайна величина. ■

4) Записваме частното като произведение: $\dfrac{X}{Y} = X \cdot \dfrac{1}{Y}$. Достатъчно е да покажем, че $\frac{1}{Y}$ е случайна величина, т.е. $\{\frac{1}{Y} < x\} \in \mathcal{A}$ за всяко $x \in \mathbb{R}$. Разглеждаме три случая:

- $x = 0$: $\{\frac{1}{Y} < 0\} = \{Y < 0\} \in \mathcal{A}$, защото Y е случайна величина.
- $x > 0$: $\{\frac{1}{Y} < x\} = \{Y < 0\} \cup \{Y > \frac{1}{x}\}$ - обединение на две множества от $\mathcal{A}$, следователно е в $\mathcal{A}$.
- $x < 0$: $\{\frac{1}{Y} < x\} = \{\frac{1}{x} < Y < 0\} = \{Y > \frac{1}{x}\} \cap \{Y < 0\}$ - сечение на множества от $\mathcal{A}$, следователно е в $\mathcal{A}$.

Във всички случаи $\{\frac{1}{Y} < x\} \in \mathcal{A}$, следователно $\frac{1}{Y}$, а оттам и $\frac{X}{Y}$, е случайна величина (при условието $\mathbb{P}(Y = 0) = 0$, което гарантира, че делението е коректно дефинирано с вероятност 1). ■

4.2 Дискретни случайни величини

Дефиниция 4.2 (Индикаторна функция)

Нека $V = (\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $H \in \mathcal{A}$. **Индикаторната функция** I_H се дефинира като

$$I_H(\omega) = \begin{cases} 1, & \omega \in H \\ 0, & \omega \notin H \ (\omega \in H^c) \end{cases}, \qquad I_H : \Omega \to \{0, 1\}.$$

Следствие 4.1 (свойства на индикаторната функция)

1) $I_{H^c} = 1 - I_H$;

2) $I_{A \cap B}(\omega) = I_A(\omega) \cdot I_B(\omega)$;

3) $I_{A \cup B} = I_A + I_B - I_A \cdot I_B$.

Лема 4.2

Нека $V = (\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $H \in \mathcal{A}$. Тогава I_H е случайна величина.

Доказателство

Полагаме $X(\omega) := I_H(\omega)$ и разглеждаме изчерпателно множеството $\{\omega \in \Omega : X(\omega) < c\}$ в зависимост от избора на $c \in \mathbb{R}$ - три случая:

1) $c \leq 0$: за $X(\omega)$ възможните стойности са само 0 и 1, така че $X^{-1}((-\infty, c)) = \varnothing \in \mathcal{A}$ (празното множество е част от всяка σ-алгебра).

2) $0 < c \leq 1$: единственият начин да е изпълнено $X(\omega) < c$ е при $X(\omega) = 0$, т.е. $X^{-1}((-\infty, c)) = H^c \in \mathcal{A}$ (защото $H \in \mathcal{A}$ и σ-алгебрите са затворени относно допълнение).

3) $c > 1$: търсим кога функцията е строго под число, което е строго над 1. Най-голямата възможна стойност на $X(\omega)$ е 1, т.е. условието е изпълнено винаги: $X^{-1}((-\infty, c)) = \Omega \in \mathcal{A}$ (по дефиниция на σ-алгебра). ■

Дефиниция 4.3 (Дискретна случайна величина)

Нека $V = (\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $H = \{H_1, \ldots, H_n\}$ (или $\{H_1, H_2, \ldots\}$) е **пълна група от събития** в него. Нека са зададени различни реални числа $\bar{x} = (x_1, \ldots, x_n)$ (или $(x_1, x_2, \ldots)$). Тогава

$$X(\omega) = X = \sum_j x_j \, I_{H_j}(\omega) = \sum_j x_j \, I_{H_j}$$

се нарича **дискретна случайна величина**. От лемата по-горе всяко I_{H_j} е случайна величина, а сума от случайни величини е случайна величина (Свойство 1), следователно X е случайна величина. Означаваме $H_j = \{X = x_j\} = \{\omega \in \Omega : X(\omega) = x_j\}$ и $p_j = \mathbb{P}(H_j)$, $j \geq 1$.

Дефиниция 4.4 (Разпределение на дискретна случайна величина)

Нека H е пълна група от събития във V, зададени са $\bar{x}$ и $X = \sum_j x_j I_{H_j}$ е дискретна случайна величина. Тогава таблицата

X	x_1	x_2	$\dots$	$x_j \dots$
$\mathbb{P}$	p_1	p_2	$\dots$	$p_j \dots$

където $\mathbb{P}(X = x_j) = p_j = \mathbb{P}(H_j)$ и $\sum_j p_j = 1$, се нарича **разпределение** на X. Две дискретни случайни величини имат *еднакво разпределение* (по разпределение, означено $X \overset{d}{=} Y$), ако техните таблици съвпадат, т.е. $\mathbb{P}(X = x_j) = \mathbb{P}(Y = x_j)$ за всяко j.

Хистограма

Графическото представяне на разпределението на дискретна случайна величина - стълбче с височина p_j над всяка стойност x_j - се нарича **хистограма**.

4.3 Смяна на променливите

Теорема 4.3

Нека X е дискретна случайна величина и $g : \mathbb{R} \to \mathbb{R}$. Тогава $Y = g(X)$ е дискретна случайна величина.

Доказателство

Ако $X = \sum_i I_{H_i} x_i$, то $Y = \sum_i I_{H_i} g(x_i)$. Полагайки $y_i := g(x_i)$, получаваме $Y = \sum_i \nVdash_{H_i} y_i$ - дискретна случайна величина по дефиниция. (Ако за някои $m \neq k$ се окаже $g(x_m) = g(x_k)$, това не е грешка - просто за удобство обединяваме съответните събития като $H_m \cup H_k$ с вероятност $p_m + p_k$.) ■

4.4 Съвместни дискретни разпределения

Дефиниция 4.5 (Съвместно дискретно разпределение)

Нека X, Y са две дискретни случайни величини във V. Под **съвместно дискретно разпределение** на двойката (X, Y) разбираме таблицата

$Y \setminus X$	x_1	x_2	$\dots$	x_k	$\dots$	
y_1	p_{11}	p_{21}	$\dots$	p_{k1}	$\dots$	$\sum_i p_{i1}$
y_2	p_{12}	p_{22}	$\dots$	p_{k2}	$\dots$	$\sum_i p_{i2}$
$\vdots$						$\vdots$

където $0 \leq p_{ij} = \mathbb{P}(X = x_i, Y = y_j)$ и $\sum_{i,j} p_{ij} = 1$.

Дефиниция 4.6 (Маргинални разпределения)

Разпределенията само на X (респ. само на Y), получени чрез сумиране на съвместната таблица по редове/колони - $\mathbb{P}(X = x_i) = \sum_j p_{ij}$, $\mathbb{P}(Y = y_j) = \sum_i p_{ij}$ - се наричат **маргинални разпределения**.

Дефиниция 4.7 (Смяна на променливите на две дискретни случайни величини)

Нека X и Y са две дискретни случайни величини във V и $g : \mathbb{R} \times \mathbb{R} \to \mathbb{R}$. Тогава $Z = g(X, Y)$ се нарича **смяна на променливите** на (X, Y) и е дискретна случайна величина.

Доказателство

Нека $X = \sum_i I_{H_i} x_i$ по стойности x_i и $Y = \sum_j I_{\widetilde{H}_j} y_j$ по стойности y_j, където $H_i = \{X = x_i\}$, $\widetilde{H}_j = \{Y = y_j\}$. Тогава

$$Z = g(X, Y) = \sum_i \sum_j g(x_i, y_j)\, I_{\{X=x_i, Y=y_j\}} = \sum_i \sum_j g(x_i, y_j)\, I_{H_i} I_{\widetilde{H}_j},$$

а групирайки по различните стойности $z = g(x_i, y_j)$, получаваме $Z = \sum_l z_l\, I_{T_l}$ за подходяща пълна група $\{T_l\}$ - т.е. Z е дискретна случайна величина. ■

4.5 Независимост на дискретни случайни величини

Дефиниция 4.8 (Независимост)

Нека X, Y са дискретни случайни величини във V. Казваме, че $X \perp\!\!\!\perp Y$ (са независими), ако за всички i, j:

$$\mathbb{P}(X = x_i,\, Y = y_j) = \mathbb{P}\big(\{X = x_i\} \cap \{Y = y_j\}\big) \overset{\text{def}}{=} \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j),$$

или еквивалентно $\mathbb{P}(X = x_i \mid Y = y_j) = \mathbb{P}(X = x_i)$ за всички i, j, за които $\mathbb{P}(Y = y_j) > 0$.

Дефиниция 4.9 (Независимост в съвкупност)

Нека $X_1, \ldots, X_n$ са n дискретни случайни величини във V. Тогава те са **независими в съвкупност**, ако за всеки избор на стойности $x_1, x_2, \ldots, x_n \in \mathbb{R}$ е изпълнено:

$$\mathbb{P}(X_1 = x_1, X_2 = x_2, \ldots, X_n = x_n) = \prod_{i=1}^{n} \mathbb{P}(X_i = x_i).$$

4.6 Функция на разпределение

Дефиниция 4.10 (Функция на разпределение)

Нека X е случайна величина във V. Тогава

$$F_X(x) = \mathbb{P}(X < x), \qquad \forall x \in [-\infty, +\infty],$$

се нарича **функция на разпределение** на случайната величина X. За нея винаги е в сила $F_X(-\infty) = 0$ и $F_X(+\infty) = 1$; за дискретна случайна величина с нарастващи стойности $x_1 < x_2 < \ldots$, F_X е стъпаловидна функция, постоянна между съседните стойности и скачаща с p_j при преминаване през x_j.

Тема 5

Очакване, дисперсия, пораждащи функции

5.1 Математическо очакване

Дефиниция 5.1 (Математическо очакване)

Нека X е дискретна случайна величина. Ако редът $\sum_i x_i p_i$ е добре дефиниран (т.е. крайна сума или абсолютно сходящ ред), то

$$\mathbb{E}X = \sum_i x_i p_i = \sum_i x_i \, \mathbb{P}(X = x_i)$$

се нарича **математическо очакване** на X. Ако X приема краен брой стойности, $\mathbb{E}X$ винаги съществува.

Частен случай: равномерно разпределение

Ако X е равномерно разпределена върху крайното множество $\{x_1, \ldots, x_n\}$ (т.е. $\mathbb{P}(X = x_i) = \frac{1}{n}$), то

$$\mathbb{E}X = \sum_{i=1}^{n} x_i \cdot \frac{1}{n} = \frac{\sum_{i=1}^{n} x_i}{n},$$

което е точно *средноаритметичното* на стойностите, които X може да приема.

Забележка: очакването не винаги съществува

Възможно е редът $\sum_i |x_i| \, p_i$ да се разлива дори когато $\sum_i p_i = 1$ коректно определя разпределение. Класически пример е разпределението $\mathbb{P}(X = j) = \frac{6}{\pi^2} \cdot \frac{1}{j^2}$ за $j \geq 1$ (коректно, защото $\sum \frac{1}{j^2} = \frac{\pi^2}{6}$), за което $\mathbb{E}X = \frac{6}{\pi^2} \sum_{j \geq 1} \frac{1}{j} = \infty$ - редът на средните стойности се разлива, следователно X няма математическо очакване.

5.2 Свойства на математическото очакване

Лема 5.1

Нека X и Y са две дискретни случайни величини, за които $\mathbb{E}X$ и $\mathbb{E}Y$ съществуват ($\mathbb{E}X < \infty$, $\mathbb{E}Y < \infty$). Тогава:

1) **Очакване на константа.** Ако $X \equiv c$, то $\mathbb{E}X = c$.

2) **Очакване на индикаторна случайна величина.** Ако $X = I_A$, то $\mathbb{E}X = \mathbb{P}(A)$ за някое събитие A.

3) **Умножение с константа.** За $c \in \mathbb{R}$: $\mathbb{E}(cX) = c\,\mathbb{E}X$.

4) **Линейност.** $\mathbb{E}(aX+bY) = a\,\mathbb{E}X + b\,\mathbb{E}Y$ (важи и без константите); по-общо, за краен брой случайни величини: $\mathbb{E}\sum_{i=1}^{n} c_i X_i = \sum_{i=1}^{n} c_i\,\mathbb{E}X_i$.

5) **Монотонност.** Ако $X \le Y$ (с вероятност 1), то $\mathbb{E}X \le \mathbb{E}Y$.

6) **Очакване на функция на случайна величина.** Ако $g : \mathbb{R} \to \mathbb{R}$ е измерима функция, то за дискретна X: $\mathbb{E}g(X) = \sum_{x \in \mathcal{X}} g(x)\,p_X(x)$, при условие че редът е абсолютно сходящ.

7) **Независимост.** Ако X, Y са независими случайни величини, то $\mathbb{E}(XY) = \mathbb{E}X \cdot \mathbb{E}Y$ (обратното не е вярно в общия случай).

8) **Неравенство на Йенсен.** Ако $\varphi : \mathbb{R} \to \mathbb{R}$ е изпъкнала функция и X е случайна величина с крайно очакване, то $\varphi(\mathbb{E}X) \le \mathbb{E}(\varphi(X))$.

Доказателство

1) $\mathbb{E}X = c \cdot \mathbb{P}(c = c) = c \cdot 1 = c$.
2) Нека $A \in \mathcal{A}$ е събитие и $I_A(\omega) = 1$ за $\omega \in A$, 0 за $\omega \notin A$. Тогава $\mathbb{E}I_A = 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(A^c) = \mathbb{P}(A)$.
3) $Z = cX = g(X)$ за $g(x) = cx$, следователно $\mathbb{E}Z = \mathbb{E}(cX) = \sum_j g(x_j)p_j = \sum_j cx_jp_j = c\sum_j x_jp_j = c\,\mathbb{E}X$.
4) Достатъчно е да покажем $\mathbb{E}(X+Y) = \mathbb{E}X + \mathbb{E}Y$ (общият случай с константи следва от 3). Нека $p_{ij} = \mathbb{P}(X = x_i, Y = y_j)$. Тогава

$$\begin{aligned}\mathbb{E}(X+Y) &= \sum_{i,j}(x_i + y_j)p_{ij} = \sum_i x_i \sum_j p_{ij} + \sum_j y_j \sum_i p_{ij} \\ &= \sum_i x_i\,\mathbb{P}(X = x_i) + \sum_j y_j\,\mathbb{P}(Y = y_j) = \mathbb{E}X + \mathbb{E}Y,\end{aligned}$$

защото $\mathbb{P}(X = x_i) = \sum_j \mathbb{P}(X = x_i, Y = y_j) = \sum_j p_{ij}$ - сумирайки съвместните вероятности по всички стойности на Y, ние покриваме всички сценарии за Y и получаваме пълната (маргинална) вероятност X да приеме стойността x_i, независимо каква стойност е приело Y.
5) Нека $X \le Y$ с вероятност 1, т.е. за всяка двойка (x, y) с $x > y$ имаме $p_{X,Y}(x, y) = 0$. За простота, ако X, Y са дефинирани върху едно и също вероятностно пространство, разглеждаме $Z = Y - X \ge 0$ с вероятност 1. Тогава $\mathbb{E}Z = \sum_{z\ge 0} z\,p_Z(z) \ge 0$, защото всички $z \ge 0$ и вероятностите са неотрицателни. От линейността (4): $\mathbb{E}Y - \mathbb{E}X = \mathbb{E}(Y - X) \ge 0 \Rightarrow \mathbb{E}X \le \mathbb{E}Y$.
6) Нека X приема стойности в изброимото множество $\mathcal{X}$ с $p_X(x) = \mathbb{P}(X = x)$, т.е. $X = \sum_{x_i\in\mathcal{X}} x_i\,I_{H_i}$, където $H_i = \{X = x_i\}$. От теоремата за смяна на променливите (Тема 4), $g(X) = \sum_i g(x_i)\,I_{H_i}$ е дискретна случайна величина, приемаща стойност $g(x_i)$ върху H_i (при съвпадащи стойности на g за различни x_i, съответните H_i просто се обединяват). Прилагайки дефиницията на очакване към тази нова дискретна случайна величина:

$$\mathbb{E}g(X) = \sum_i g(x_i)\,\mathbb{P}(H_i) = \sum_{x\in\mathcal{X}} g(x)\,p_X(x),$$

при условие че този ред е абсолютно сходящ (нужно е сумата да не зависи от реда на събиране, тъй като при групиране на равни стойности $g(x_i)$ редът на сумиране естествено се променя). ■
7) Нека $g(x, y) = xy$. Тогава, ползвайки независимостта $X \perp\!\!\!\perp Y$:

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{i,j} x_iy_jp_{ij} \overset{X\perp\!\!\!\perp Y}{=} \sum_{i,j} x_iy_j\,\mathbb{P}(X = x_i)\,\mathbb{P}(Y = y_j) \\ &= \sum_i x_i\,\mathbb{P}(X = x_i) \sum_j y_j\,\mathbb{P}(Y = y_j) = \mathbb{E}X \cdot \mathbb{E}Y.\end{aligned}$$

8) (Неравенство на Йенсен) Нека $\mu = \mathbb{E}X$. Понеже φ е изпъкнала, в точката μ съществува *опорна права* $\ell(x) = \varphi(\mu) + c(x - \mu)$ (с c равно на производната $\varphi'(\mu)$, ако тя съществува, или произволен subgradient в противен случай), такава че $\varphi(x) \ge \ell(x)$ за всяко $x \in \mathbb{R}$ (това е характеристично свойство на изпъкналите функции - графиката им лежи над всяка допирателна права). Прилагаме монотонността (5) и линейността (4) към неравенството $\varphi(X) \ge \ell(X) = \varphi(\mu) + c(X - \mu)$:

$$\mathbb{E}(\varphi(X)) \ge \mathbb{E}(\ell(X)) = \varphi(\mu) + c\big(\mathbb{E}X - \mu\big) = \varphi(\mu) + c \cdot 0 = \varphi(\mathbb{E}X).$$ ■

5.3 Дисперсия

Идея

Дисперсията е мярка за разпространението (разсейването) на стойностите на случайна величина спрямо нейната средна стойност (математическото очакване). Тя показва количествено колко стойностите се отклоняват от средната.

Дефиниция 5.2 (Дисперсия)

Нека X е дискретна случайна величина и нека сумата $\sum_j (x_j - \mathbb{E}X)^2 p_j$ е добре дефинирана (т.е. крайна). Тогава

$$DX = \mathbb{E}(X - \mathbb{E}X)^2 = \sum_j (x_j - \mathbb{E}X)^2 p_j$$

се нарича **дисперсия** на X. Това е средноаритметичното на квадратите на отклоненията на всяка стойност от средната.

Дефиниция 5.3 (Стандартно отклонение)

Ако X е случайна величина и DX е крайно, то $\sqrt{DX}$ се нарича **стандартно отклонение** на X.

Теорема 5.2

Нека X е дискретна случайна величина и нека $DX < \infty$. Тогава

$$DX = \mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2.$$

Доказателство

$$\mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}\big(X^2 - 2X\,\mathbb{E}X + (\mathbb{E}X)^2\big) = \mathbb{E}X^2 - 2\,\mathbb{E}X\,\mathbb{E}X + (\mathbb{E}X)^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2. \blacksquare$$

5.4 Свойства на дисперсията

Теорема 5.3

Нека X, Y са случайни величини с $DX < \infty$, $DY < \infty$.

1) **Неотрицателност.** $DX \geq 0$; частен случай: $DX = 0 \iff X$ е константа с вероятност 1.
2) $D(cX) = c^2 DX$ за константа c.
3) $D(aX + b) = a^2 DX$ за всички $a, b \in \mathbb{R}$.
4) Ако $X \perp\!\!\!\perp Y$, то $D(X + Y) = DX + DY$. В общия случай: $D\big(\sum_{i=1}^n X_i\big) = \sum_{i=1}^n DX_i$ (за взаимно независими X_i).

Доказателство

1) $DX = \sum_j (x_j - \mathbb{E}X)^2 p_j$ - всяко събираемо е неотрицателно ($(x_j - \mathbb{E}X)^2 \geq 0$, $p_j \geq 0$), следователно $DX \geq 0$. Ако $X \equiv c$ е константа, то $DC = \mathbb{E}(c - \mathbb{E}c)^2 = \mathbb{E}(c-c)^2 = 0$.
2) $D(cX) = \mathbb{E}(cX)^2 - (\mathbb{E}cX)^2 = c^2\mathbb{E}X^2 - c^2(\mathbb{E}X)^2 = c^2\big(\mathbb{E}X^2 - (\mathbb{E}X)^2\big) = c^2 DX$.
3) Нека $Y = aX + b$, $\mu = \mathbb{E}X$, тогава $\mathbb{E}Y = a\mu + b$ и

$$DY = \mathbb{E}\big(aX + b - (a\mu + b)\big)^2 = \mathbb{E}\big(aX - a\mu\big)^2 = \mathbb{E}\big(a^2(X-\mu)^2\big) = a^2\,\mathbb{E}(X-\mu)^2 = a^2 DX.$$

4)

$$\begin{aligned} D(X+Y) &= \mathbb{E}(X+Y)^2 - \big(\mathbb{E}(X+Y)\big)^2 = \mathbb{E}(X^2 + 2XY + Y^2) - (\mathbb{E}X + \mathbb{E}Y)^2 \\ &= \mathbb{E}X^2 + \mathbb{E}(2XY) + \mathbb{E}Y^2 - (\mathbb{E}X)^2 - 2\,\mathbb{E}X\,\mathbb{E}Y - (\mathbb{E}Y)^2 \\ &= DX + DY + 2\big(\mathbb{E}(XY) - \mathbb{E}X\,\mathbb{E}Y\big). \end{aligned}$$

Ако $X \perp\!\!\!\perp Y$, по свойство 7 от предната лема $\mathbb{E}(XY) = \mathbb{E}X\,\mathbb{E}Y$, следователно последната скоба е нула и $D(X+Y) = DX + DY$. ■

Неравенство 5.4 (на Марков)

Нека X е дискретна случайна величина, $X \geq 0$. Тогава за всяко $\alpha > 0$:

$$\mathbb{P}(X > \alpha) \leq \frac{\mathbb{E}X}{\alpha}.$$

Доказателство

$$\mathbb{E}X = \sum_{x \in \mathcal{X}} x\,p(x) \geq \sum_{x \in \mathcal{X}:\, x > \alpha} x\,p(x) \geq \sum_{x \in \mathcal{X}:\, x > \alpha} \alpha\,p(x) = \alpha\,\mathbb{P}(X > \alpha). \blacksquare$$

Неравенство 5.5 (на Чебишов)

Нека X е дискретна случайна величина с $\mathbb{E}X < \infty$, $DX < \infty$. Тогава за всяко $\alpha > 0$:

$$\mathbb{P}\big(|X - \mathbb{E}X| > \alpha\big) \leq \frac{DX}{\alpha^2}.$$

Доказателство

От неравенството на Марков, приложено към $(X - \mathbb{E}X)^2 \geq 0$ и прага α^2:

$$\mathbb{P}\big(|X - \mathbb{E}X| > \alpha\big) = \mathbb{P}\big((X - \mathbb{E}X)^2 > \alpha^2\big) \leq \frac{\mathbb{E}\big[(X - \mathbb{E}X)^2\big]}{\alpha^2} = \frac{DX}{\alpha^2}. \blacksquare$$

5.5 Пораждащи функции

Идея

Пораждащата (моментна) функция прибира на „горбичка“ или цифров пакет с данни цялата вероятностна информация за X, запазена и компресирана в една удобна за работа математическа форма. Разгръщайки я - чрез диференциране и други операции - можем да извлечем конкретни характеристики на разпределението, като моменти или вероятности.

Дефиниция 5.4 (Пораждаща функция)

Нека $X : \Omega \to \mathbb{N}$ е случайна величина във V. Функцията

$$g_X(s) := \mathbb{E}s^X = \sum_{k=0}^{\infty} s^k \, \mathbb{P}(X = k), \qquad |s| \leq 1,$$

се нарича **пораждаща функция** на X (условието $|s| \leq 1$ гарантира, че редът е сходящ).

Теорема 5.6

- За целочислена случайна величина X с $\mathbb{E}X < \infty$: $g'_X(1) = \mathbb{E}X$.
- Ако $\mathbb{E}X^2 < \infty$, то $DX = g''_X(1) + g'_X(1) - (g'_X(1))^2$.
- Във всички случаи: $\mathbb{P}(X = n) = \dfrac{g_X^{(n)}(0)}{n!}$, $\forall n \geq 0$.

Доказателство

Диференцираме почленно (термин по термин) реда, определящ g_X:

$$g'_X(s) = \frac{d}{ds}\mathbb{E}s^X = \mathbb{E}\frac{d}{ds}s^X = \mathbb{E}Xs^{X-1}.$$

При $s = 1$: $g'_X(1) = \mathbb{E}X \cdot 1 = \mathbb{E}X$.
Диференцираме отново:

$$g''_X(s) = \frac{d}{ds}\mathbb{E}Xs^{X-1} = \mathbb{E}X(X-1)s^{X-2},$$

и при $s = 1$: $g''_X(1) = \mathbb{E}X(X-1) = \mathbb{E}X^2 - \mathbb{E}X = \mathbb{E}X^2 - g'_X(1)$, откъдето $\mathbb{E}X^2 = g''_X(1) + g'_X(1)$.
Заместваме в $DX = \mathbb{E}X^2 - (\mathbb{E}X)^2$ и получаваме $DX = g''_X(1) + g'_X(1) - (g'_X(1))^2$.
За последното твърдение, разписваме реда:

$$g_X(s) = \sum_{k=0}^{\infty} s^k \, \mathbb{P}(X = k),$$

и вземаме неговата n-та производна:

$$g_X^{(n)}(s) = \Big(\sum_{k=0}^{\infty} s^k \, \mathbb{P}(X = k)\Big)^{(n)} = n! \, \mathbb{P}(X = n) + (n+1)n \cdots 2 \cdot s \, \mathbb{P}(X = n+1) + \ldots$$

(защото членовете с $k < n$ изчезват при n-кратно диференциране). При $s = 0$ всички членове с положителна степен на s се анулират и остава $g_X^{(n)}(0) = n! \, \mathbb{P}(X = n)$, откъдето $\mathbb{P}(X = n) = \dfrac{g_X^{(n)}(0)}{n!}$. ■

Лема 5.7

Нека $(X_1, \ldots, X_n)$ са независими в съвкупност целочислени случайни величини. Тогава

$$g_{X_1+\cdots+X_n}(s) = \prod_{j=1}^{n} g_{X_j}(s).$$

Ако в допълнение случайните величини са еднакво разпределени ($X_1 \stackrel{d}{=} X_j$ за всяко j, т.е. $\mathbb{P}(X_1 = k) = \mathbb{P}(X_j = k)$ за всяко k), то

$$g_{X_1+\cdots+X_n}(s) = g^n_{X_1}(s).$$

Доказателство

За $n = 2$:

$$\begin{aligned} g_{X_1+X_2}(s) = \mathbb{E}s^{X_1+X_2} &= \sum_{m,n\geq 0} s^{m+n}\,\mathbb{P}(X_1 = m, X_2 = n) \\ &\overset{X_1 \perp\!\!\!\perp X_2}{=} \sum_{m,n\geq 0} s^m s^n\,\mathbb{P}(X_1 = m)\,\mathbb{P}(X_2 = n) \\ &= \sum_{m=0}^{\infty} s^m\,\mathbb{P}(X_1 = m) \sum_{n=0}^{\infty} s^n\,\mathbb{P}(X_2 = n) = g_{X_1}(s)\,g_{X_2}(s). \end{aligned}$$

Общият случай за n величини следва по индукция по същата схема.
Ако допълнително $X_1 \stackrel{d}{=} X_j$, то $\mathbb{P}(X_1 = n) = \mathbb{P}(X_j = n)$ за всяко $n \geq 0$, следователно $g_{X_j}(s) = \sum_n s^n \mathbb{P}(X_j = n) = \sum_n s^n \mathbb{P}(X_1 = n) = g_{X_1}(s)$ за всяко j, откъдето $\prod_{j=1}^n g_{X_j}(s) = g^n_{X_1}(s)$. ■

Теорема 5.8

Нека $g_X(s) = g_Y(s)$ за $|s| < 1$. Тогава $X \stackrel{d}{=} Y$.

Доказателство

От предната теорема, $\mathbb{P}(X = n) = \dfrac{g_X^{(n)}(0)}{n!}$ и $\mathbb{P}(Y = n) = \dfrac{g_Y^{(n)}(0)}{n!}$. Понеже самите функции са равни ($g_X(s) = g_Y(s)$ като функции), то и производните им от всеки ред са равни ($g_X^{(n)}(0) = g_Y^{(n)}(0)$ за всяко n), следователно $\mathbb{P}(X = n) = \mathbb{P}(Y = n)$ за всяко $n \geq 0$, т.е. X и Y са еднакво разпределени ($X \stackrel{d}{=} Y$). ■

Тема 6

Основни дискретни разпределения

6.1 Схема на Бернули

Дефиниция 6.1 (Схема на Бернули)

Схема на Бернули е редица от n независими опити, където всеки опит има само два възможни изхода: *успех* с вероятност p $(0 \leq p \leq 1)$ и *неуспех* с вероятност $q = 1 - p$. Формално: нека $(X_1, \ldots, X_n)$ (или $(X_1, X_2, \ldots)$) са независими в съвкупност, еднакво разпределени случайни величини с

$$\begin{array}{c|cc} X_1 & 0 & 1 \\ \hline \mathbb{P} & q{=}1{-}p & p \end{array}.$$

Тогава редицата $(X_1, \ldots, X_n)$ се нарича схема на Бернули.

6.2 Разпределение на Бернули

Дефиниция 6.2 ($X \sim Be(p)$)

$X \sim Be(p)$, ако X има разпределението $\begin{array}{c|cc} X & 0 & 1 \\ \hline \mathbb{P} & q{=}1{-}p & p \end{array}$. Директно от дефиницията: $\mathbb{E}X = p$; понеже $X \in \{0, 1\}$, имаме $X^2 = X$, откъдето $DX = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \mathbb{E}X - (\mathbb{E}X)^2 = p - p^2 = p(1-p) = pq$; $g_X(s) = s^0 q + s^1 p = q + ps = 1 - p + ps$.

6.3 Биномно разпределение

Дефиниция 6.3 ($X \sim Bin(n, p)$)

Казваме, че $X \sim Bin(n, p)$, ако X е броят успехи измежду първите n опита в схема на Бернули с вероятност за успех p, т.е.

$$X = \sum_{j=1}^{n} X_j, \qquad X_j \sim Be(p) \text{ независими в съвкупност.}$$

Теорема 6.1

Ако $X \sim Bin(n,p)$, то:

$$\mathbb{E}X = np, \qquad DX = npq, \qquad g_X(s) = (q+ps)^n, \qquad \mathbb{P}(X=k) = \binom{n}{k} p^k q^{n-k},\ k = 0,\dots,n.$$

Доказателство

От линейността на очакването и адитивността на дисперсията за независими събираеми (Тема 5), ползвайки стойностите от $Be(p)$:

$$\mathbb{E}X = \sum_{j=1}^{n} \mathbb{E}X_j = \sum_{j=1}^{n} p = np, \qquad DX = D\sum_{j=1}^{n} X_j = \sum_{j=1}^{n} DX_j = \sum_{j=1}^{n} pq = npq.$$

От леммата за пораждащата функция на сума от независими еднакво разпределени величини (Тема 5): $g_X(s) = g_{X_1}^n(s) = (q+ps)^n$.
Остава да намерим разпределението на X. Диференцираме $g_X(s) = (q+ps)^n$ последователно:

$$g_X'(s) = n(q+ps)^{n-1}p, \quad g_X''(s) = n(n-1)(q+ps)^{n-2}p^2, \ \dots,$$
$$g_X^{(k)}(s) = n(n-1)\cdots(n-k+1)(q+ps)^{n-k}p^k.$$

Заместваме $s=0$: $g_X^{(k)}(0) = n(n-1)\cdots(n-k+1)\,q^{n-k}p^k$, и по формулата $\mathbb{P}(X=k) = \frac{g_X^{(k)}(0)}{k!}$ (Тема 5):

$$\mathbb{P}(X=k) = \frac{n(n-1)\cdots(n-k+1)}{k!}\,p^k q^{n-k} = \binom{n}{k} p^k q^{n-k}. \blacksquare$$

6.4 Геометрично разпределение

Дефиниция 6.4 ($X \sim Ge(p)$)

$X \sim Ge(p)$, ако $X = \min\{n \geq 1 : \sum_{j=1}^{n} X_j = 1\} - 1$ за схема на Бернули (X_j). Има два еквивалентни по смисъл варианта:

- *брой неуспехи преди първия успех* - това е дефиницията по-горе, $X \sim Ge(p)$, $\mathbb{P}(X = k) = (1-p)^k p = pq^k$ за $k = 0,1,2,\dots$;
- *брой опити до първия успех* (включително успеха) - $Y \sim Ge(p)$, $\mathbb{P}(Y=k) = (1-p)^{k-1}p$ за $k = 1,2,3,\dots$, свързано с горното чрез $Y = X+1$.

Теорема 6.2

Нека $X \sim Ge(p)$ (брой неуспехи преди първия успех). Тогава:

1) $\mathbb{P}(X = k) = (1-p)^k p = pq^k$, $k = 0, 1, 2, \ldots$

2) $g_X(s) = \dfrac{p}{1-qs}$, $|s| < 1$.

3) $\mathbb{E}X = \dfrac{q}{p}$.

4) $DX = \dfrac{q}{p^2}$.

Доказателство

2) Събитието $\{X = k\}$ означава първите k опита са неуспешни, а опит $k{+}1$ е успешен:

$$\mathbb{P}(X = k) = \mathbb{P}(X_1{=}0, \ldots, X_k{=}0, X_{k+1}{=}1) = \mathbb{P}(X_1{=}0) \cdots \mathbb{P}(X_k{=}0)\, \mathbb{P}(X_{k+1}{=}1) = q^k p.$$

Следователно, ползвайки сумата на геометрична прогресия $\sum_{k=0}^{\infty} r^k = \frac{1}{1-r}$ за $|r| < 1$:

$$g_X(s) = \sum_{k=0}^{\infty} s^k\, \mathbb{P}(X = k) = \sum_{k=0}^{\infty} s^k pq^k = p \sum_{k=0}^{\infty} (sq)^k = \frac{p}{1-qs}, \qquad |s| < 1.$$

3) $g'_X(s) = \left(\dfrac{p}{1-qs}\right)' = \dfrac{p \cdot q}{(1-qs)^2} = \dfrac{pq}{(1-qs)^2}$, следователно $g'_X(1) = \dfrac{pq}{(1-q)^2} = \dfrac{pq}{p^2} = \dfrac{q}{p}$.
Понеже $\mathbb{E}X = g'_X(1)$ (Тема 5), получаваме $\mathbb{E}X = \dfrac{q}{p}$.

4) $g''_X(s) = \left(\dfrac{pq}{(1-qs)^2}\right)' = \dfrac{2pq^2}{(1-qs)^3}$, откъдето $g''_X(1) = \dfrac{2pq^2}{p^3} = \dfrac{2q^2}{p^2}$. По формулата $DX = g''_X(1) + g'_X(1) - (g'_X(1))^2$ (Тема 5):

$$DX = \frac{2q^2}{p^2} + \frac{q}{p} - \left(\frac{q}{p}\right)^2 = \frac{q^2}{p^2} + \frac{q}{p} = \frac{q^2 + pq}{p^2} = \frac{q(q+p)}{p^2} = \frac{q}{p^2}. \blacksquare$$

Теорема 6.3 (безпаметност на геометричното разпределение)

Нека $X \sim Ge(p)$. Тогава за всички $m, k \in \mathbb{N}$:

$$\mathbb{P}(X \geq m + k \mid X \geq k) = \mathbb{P}(X \geq m) = q^m.$$

Интерпретация: ако вече сме имали k неуспеха, разпределението на оставащите опити до успех е същото като в началото - системата „не помни“ миналите неуспехи.

Доказателство

$\mathbb{P}(X \geq m) = \mathbb{P}(X_1{=}0, \ldots, X_m{=}0) = q^m$ (независимост). Следователно

$$\mathbb{P}(X \geq m + k \mid X \geq k) = \frac{\mathbb{P}(X \geq m + k,\ X \geq k)}{\mathbb{P}(X \geq k)} = \frac{\mathbb{P}(X \geq m + k)}{\mathbb{P}(X \geq k)} = \frac{q^{m+k}}{q^k} = q^m. \blacksquare$$

6.5 Отрицателно биномно разпределение

Дефиниция 6.5 ($X \sim NB(r,p)$)

Нека $r \geq 1$. Казваме, че $X \sim NB(r,p)$, ако $X = \min\{n \geq 1 : \sum_{j=1}^{n} X_j = r\} - r$ за схема на Бернули. Описва броя на *неуспешните* опити на Бернули, необходими за постигане на r-ти успех (частен случай $r = 1$: $NB(1,p) = Ge(p)$).

Теорема 6.4

Ако $X \sim NB(r,p)$, то $X = \sum_{j=1}^{r} Y_j$, където $(Y_1, \ldots, Y_r)$ са независими в съвкупност, еднакво разпределени $Y_j \sim Ge(p)$.

Доказателство

Идеята е, че броят неуспехи до r-тия успех се разбива на r последователни, независими „блока“: неуспехите между $(j-1)$-вия и j-тия успех имат точно геометрично разпределение (по безпаметността на схемата на Бернули - след всеки успех схемата „се рестартира“). За $r = 2$, директна проверка чрез разбиване по позицията на първия успех потвърждава, че $Y_1 \perp\!\!\!\perp Y_2$, $Y_1 \overset{d}{=} Y_2 \sim Ge(p)$ и $X \overset{d}{=} Y_1 + Y_2$; общият случай за произволно r следва по индукция по същата схема. ■

Теорема 6.5

Ако $X \sim NB(r,p)$, то:

$$g_X(s) = \left(\frac{p}{1-qs}\right)^r, \qquad \mathbb{E}X = r\frac{q}{p}, \qquad DX = r\frac{q}{p^2}.$$

Доказателство

От предната теорема $X = \sum_{j=1}^{r} Y_j$ с $Y_j \sim Ge(p)$ независими, следователно (Тема 5, лема за пораждаща функция на сума от еднакво разпределени независими величини):

$$g_X(s) = g_{Y_1}^r(s) = \left(\frac{p}{1-qs}\right)^r.$$

От линейността на очакването и адитивността на дисперсията:

$$\mathbb{E}X = \sum_{j=1}^{r} \mathbb{E}Y_j = r\frac{q}{p}, \qquad DX = \sum_{j=1}^{r} DY_j = r\,DY_1 = r\frac{q}{p^2}. \blacksquare$$

Теорема 6.6

Ако $X \sim NB(r,p)$, то

$$\mathbb{P}(X = k) = \binom{r+k-1}{k} q^k p^r, \qquad k \geq 0.$$

Доказателство

Комбинаторно: искаме сред първите $k+r-1$ опита (неуспехите плюс първите $r-1$ успеха) да изберем позициите на k-те неуспехи - $\binom{k+r-1}{k}$ начина - а опитът с номер $k+r$ задължително е успешен (r-тият успех). Всяка такава конфигурация има вероятност $q^k p^{r-1} \cdot p = q^k p^r$, откъдето $\mathbb{P}(X = k) = \binom{k+r-1}{k} q^k p^r$. ■

6.6 Поасоново разпределение

Дефиниция 6.6 ($X \sim Poi(\lambda)$)

Нека $\lambda > 0$. $X \sim Poi(\lambda)$, ако X е целочислена случайна величина, такава че

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k \geq 0 \qquad \Big(\text{коректност: } \sum_{k=0}^{\infty} \mathbb{P}(X = k) = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1\Big).$$

Моделиране

Поасоновото разпределение моделира броя събития, случващи се във фиксиран интервал от време или пространство, при условията: събитията се случват независимо; средният брой събития в интервала е постоянен (означава се с λ); две събития не могат да се случат в един и същ момент; вероятността за събитие в много малък подинтервал е пропорционална на дължината му. Типични примери: брой обаждания в кол-център за минута, брой насекоми в единица площ, брой клиенти за час.

Теорема 6.7

Ако $X \sim Poi(\lambda)$, $\lambda > 0$, то $g_X(s) = e^{\lambda(s-1)}$ и $\mathbb{E}X = DX = \lambda$.

Доказателство

$$g_X(s) = \mathbb{E}s^X = \sum_{k=0}^{\infty} s^k \, \mathbb{P}(X = k) = \sum_{k=0}^{\infty} s^k \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(s\lambda)^k}{k!} = e^{-\lambda} e^{s\lambda} = e^{\lambda(s-1)},$$

ползвайки реда на експонентата $\sum_{k=0}^{\infty} \frac{x^k}{k!} = e^x$. Тогава

$$\mathbb{E}X = g'_X(s)\big|_{s=1} = \lambda e^{\lambda(s-1)}\big|_{s=1} = \lambda,$$

а от $g''_X(s) = \lambda^2 e^{\lambda(s-1)}$, $g''_X(1) = \lambda^2$, и формулата $DX = g''_X(1) + \mathbb{E}X - (\mathbb{E}X)^2$:

$$DX = \lambda^2 + \lambda - \lambda^2 = \lambda. \blacksquare$$

6.7 Сходимост по разпределение и теорема на Поасон

Дефиниция 6.7 (Сходимост по разпределение)

Редицата от целочислени случайни величини $(X_n)_{n\geq 1}$ се **сближава по разпределение** към X, ако $\lim_{n\to\infty} \mathbb{P}(X_n = k) = \mathbb{P}(X = k)$ за всяко $k \in \mathbb{Z}$. Ако $(X_n)_{n\geq 1}$ са неотрицателни, това е еквивалентно на $\lim_{n\to\infty} g_{X_n}(s) = g_X(s)$ за всяко $|s| < 1$.

Теорема 6.8 (на Поасон)

Нека $X_n \sim Bin(n, p_n)$, $n \geq 1$, където $p_n = \frac{\lambda}{n} + \frac{\nu_n}{n}$, $\lambda > 0$ и $\lim_{n\to\infty} \nu_n = 0$. Тогава X_n се сближава по разпределение към $X \sim Poi(\lambda)$, т.е.

$$\forall k \geq 0 : \lim_{n\to\infty} \mathbb{P}(X_n = k) = e^{-\lambda}\frac{\lambda^k}{k!} = \mathbb{P}(X = k).$$

Интуитивно: когато имаме много на брой опити (n голямо), много малка вероятност за успех ($p_n \approx \lambda/n$), но среден брой успехи np_n, оставащ приблизително постоянен ($\approx \lambda$), биномното разпределение става неразличимо от поасоновото.

Доказателство

Ползваме $g_{X_n}(s) = (q_n + p_n s)^n = (1 - p_n + p_n s)^n$:

$$\begin{aligned} g_{X_n}(s) &= \left(1 - \frac{\lambda}{n} - \frac{\nu_n}{n} + \left(\frac{\lambda}{n} + \frac{\nu_n}{n}\right)s\right)^n = \left(1 - \frac{\lambda}{n} - \frac{\nu_n}{n} + \frac{\lambda}{n}s + \frac{\nu_n}{n}s\right)^n \\ &= \left(1 + \frac{\lambda}{n}(s-1) + \frac{\nu_n}{n}(s-1)\right)^n = \left(1 + \frac{(\lambda+\nu_n)(s-1)}{n}\right)^n. \end{aligned}$$

Граничният преход следва от класическото гранично твърдение $\lim_{n\to\infty}\left(1 + \frac{x_n}{n}\right)^n = e^{\lim_{n\to\infty} x_n}$ (валидно, ако границата на x_n съществува). В нашия случай $x_n = (\lambda+\nu_n)(s-1)$, и понеже $\lim_{n\to\infty}\nu_n = 0$, имаме $\lim_{n\to\infty} x_n = \lambda(s-1)$. Следователно, при $n \to \infty$, изразът клони към $e^{\lambda(s-1)} = g_X(s)$, където $X \sim Poi(\lambda)$. ■

6.8 Хипергеометрично разпределение

Постановка

Имаме N елемента, от които $M \leq N$ са „маркирани“. Избираме $n \leq N$ измежду тях (теглене *без връщане/повторение*) и случайната величина X е броят маркирани обекти сред избраните n.

Дефиниция 6.8 ($X \sim HG(N, M, n)$)

$X \sim HG(N, M, n)$, ако X брои колко маркирани (от общо M) елемента са избрани в извадка от n обекта (без повторение) от общо N елемента.

Теорема 6.9

Ако $X \sim HG(N, M, n)$, то:

а) $\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}$, за $\max(0, n - (N - M)) \leq k \leq \min(M, n)$;

б) $\mathbb{E}X = n\frac{M}{N}$, $\qquad DX = \frac{nM}{N} \cdot \frac{N-M}{N} \cdot \frac{N-n}{N-1}$.

Доказателство

а) $\binom{M}{k}$ е броят начини да изберем k маркирани измежду M-те маркирани; $\binom{N-M}{n-k}$ - броят начини да изберем останалите $n-k$ (обикновени) измежду $N-M$-те немаркирани; $\binom{N}{n}$ - общият брой начини да изберем n обекта измежду N. По равномерна вероятност, $\mathbb{P}(X=k)=\dfrac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}$.

б) (очакване) Дефинираме индикаторните случайни величини $X_j = \begin{cases}1, & \text{ако } j\text{-тият изтеглен обект е маркиран}\\ 0, & \text{иначе}\end{cases}$, $j=1,\dots,n$, така че $X=\sum_{j=1}^{n} X_j$ (величините (X_j) *не* са независими помежду си, но линейността на очакването не изисква независимост). По симетрия на изтеглянето без връщане, $\mathbb{P}(X_j=1)=\dfrac{\binom{N-1}{M-1}}{\binom{N}{M}}=\dfrac{M}{N}$ за всяко j, следователно

$$\mathbb{E}X=\mathbb{E}\sum_{j=1}^{n}X_j=\sum_{j=1}^{n}\mathbb{P}(X_j{=}1)=n\frac{M}{N}.$$

б) (дисперсия - доказателство чрез факториални моменти) За $i\neq j$: $X_iX_j=1$ точно когато и i-тият, и j-тият изтеглен обект са маркирани, следователно

$$\mathbb{E}(X_iX_j)=\mathbb{P}(X_i{=}1,X_j{=}1)=\frac{M}{N}\cdot\frac{M-1}{N-1},\qquad i\neq j$$

(вероятността вторият маркиран обект да е избран, при условие че първият вече е маркиран и не се връща в множеството). Понеже $X(X-1)=\sum_{i\neq j}X_iX_j$ (сума по всички $n(n-1)$ наредени двойки различни индекси),

$$\mathbb{E}\big[X(X-1)\big]=n(n-1)\cdot\frac{M}{N}\cdot\frac{M-1}{N-1}.$$

От тук $\mathbb{E}X^2=\mathbb{E}[X(X-1)]+\mathbb{E}X$, и

$$DX=\mathbb{E}X^2-(\mathbb{E}X)^2=n(n-1)\frac{M(M-1)}{N(N-1)}+n\frac{M}{N}-n^2\frac{M^2}{N^2}.$$

Изнасяме множител $\frac{nM}{N}$:

$$DX=\frac{nM}{N}\left[\frac{(n-1)(M-1)}{N-1}+1-\frac{nM}{N}\right].$$

Привеждаме скобата под общ знаменател $N(N-1)$; за числителя, разписвайки $(n-1)(M-1)=nM-n-M+1$:

$$\begin{aligned}N(n-1)(M-1)+N(N-1)-nM(N-1)&=N(nM-n-M+N)-nM(N-1)\\&=N^2-Nn-NM+nM=(N-n)(N-M).\end{aligned}$$

Следователно скобата е равна на $\dfrac{(N-n)(N-M)}{N(N-1)}$, и

$$DX=\frac{nM}{N}\cdot\frac{(N-n)(N-M)}{N(N-1)}=\frac{nM}{N}\cdot\frac{N-M}{N}\cdot\frac{N-n}{N-1}.\blacksquare$$

Тема 7

Ковариация, корелация

7.1 Съвместна функция на разпределение и независимост

Дефиниция 7.1 (Съвместна функция на разпределение)

Нека X, Y са случайни величини. Функцията

$$F_{X,Y}(x,y) := \mathbb{P}(X < x,\, Y < y), \qquad (x,y) \in \mathbb{R}^2,$$

се нарича **съвместна функция на разпределение** на двойката (X,Y). За нея са в сила

$$F_{X,Y}(\infty, y) = F_Y(y), \qquad F_{X,Y}(x,\infty) = F_X(x), \qquad F_{X,Y}(\infty,\infty) = 1, \qquad F_{X,Y}(-\infty, y) = 0.$$

Дефиниция 7.2 (Независимост чрез съвместната функция на разпределение)

Случайните величини X и Y са **независими**, ако

$$F_{X,Y}(x,y) = F_X(x) \cdot F_Y(y), \qquad \forall (x,y) \in \mathbb{R}^2,$$

т.е. $\mathbb{P}(X < x,\, Y < y) = \mathbb{P}(X < x) \cdot \mathbb{P}(Y < y)$.

Следствие 7.1

Ако X, Y са дискретни, дефиницията е еквивалентна на $\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j)$ за всички i, j.

Доказателство

($\Leftarrow$) Нека $\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j)$ за всички i, j. Тогава за произволни x, y:

$$\mathbb{P}(X < x, Y < y) = \sum_{x_i<x}\sum_{y_j<y} \mathbb{P}(X = x_i, Y = y_j) = \sum_{x_i<x}\sum_{y_j<y} \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j)$$

$$= \Big(\sum_{x_i<x} \mathbb{P}(X = x_i)\Big)\Big(\sum_{y_j<y} \mathbb{P}(Y = y_j)\Big) = F_X(x)F_Y(y).$$

($\Rightarrow$) Нека $F_{X,Y}(x, y) = F_X(x)F_Y(y)$ за всички (x, y). Нека x_i, y_j са съседни стойности в носителите на X, Y, а x_i^-, y_j^- означават непосредствено предходната стойност (или $-\infty$, ако x_i/y_j е най-малката). По принципа на включване-изключване:

$$\begin{aligned}\mathbb{P}(X = x_i, Y = y_j) &= F_{X,Y}(x_i^+, y_j^+) - F_{X,Y}(x_i^{-,+}, y_j^+) - F_{X,Y}(x_i^+, y_j^{-,+}) + F_{X,Y}(x_i^{-,+}, y_j^{-,+})\\ &= F_X(x_i)F_Y(y_j) - F_X(x_i^-)F_Y(y_j) - F_X(x_i)F_Y(y_j^-) + F_X(x_i^-)F_Y(y_j^-)\\ &= \big[F_X(x_i) - F_X(x_i^-)\big]\big[F_Y(y_j) - F_Y(y_j^-)\big] = \mathbb{P}(X = x_i)\,\mathbb{P}(Y = y_j).\end{aligned}$$ ■

7.2 Ковариация

Дефиниция 7.3 (Ковариация)

Нека X, Y са случайни величини. Количеството

$$\operatorname{cov}(X, Y) := \mathbb{E}\big[(X - \mathbb{E}X)(Y - \mathbb{E}Y)\big]$$

се нарича **ковариация** на X и Y, ако съществува. Тя измерва как двете случайни величини се изменят заедно. За дискретни X, Y: $\operatorname{cov}(X, Y) = \sum_{i,j}(x_i - \mathbb{E}X)(y_j - \mathbb{E}Y)\,p_{ij}$.

Идея: линейна връзка

Линейна зависимост между две случайни величини имаме, когато $Y = aX + b$. Ковариацията е мярка за *посоката* на линейната връзка. Наистина, ако положим $\widetilde{X} = X - \mathbb{E}X$, $\widetilde{Y} = Y - \mathbb{E}Y$ (центрирани версии), то от $Y = aX + b$ следва

$$Y - \mathbb{E}Y = a(X - \mathbb{E}X) \iff \widetilde{Y} = a\widetilde{X},$$

т.е. центрирането не променя линейната зависимост между величините - то само премества центъра в началото на координатната система.

Теорема 7.1

Нека X, Y са случайни величини. Тогава

$$\operatorname{cov}(X, Y) = \mathbb{E}\widetilde{X}\widetilde{Y} = \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y, \qquad \widetilde{X} = X - \mathbb{E}X,\ \widetilde{Y} = Y - \mathbb{E}Y.$$

Доказателство

$$\begin{aligned}\mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) &= \mathbb{E}\big[XY - Y\,\mathbb{E}X - X\,\mathbb{E}Y + \mathbb{E}X\,\mathbb{E}Y\big]\\ &= \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y - \mathbb{E}Y\,\mathbb{E}X + \mathbb{E}X\,\mathbb{E}Y = \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y.\end{aligned}$$ ■

Забележка: скалиране

Преминаването $X, Y \to X - \mathbb{E}X,\ Y - \mathbb{E}Y$ не променя зависимостта между X и Y, а само центрира величините. От друга страна, скалирането $X, Y \to 10X, 10Y$ скалира ковариацията квадратично:

$$\operatorname{cov}(10X, 10Y) = \mathbb{E}(10X - 10\,\mathbb{E}X)(10Y - 10\,\mathbb{E}Y) = 100\,\mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) = 100\operatorname{cov}(X, Y).$$

Свойства 7.2 (на ковариацията)

1) **Симетрия:** $\operatorname{cov}(X, Y) = \operatorname{cov}(Y, X)$.
2) $\operatorname{cov}(X, X) = DX$.
3) **Линейност:** $\operatorname{cov}(aX + b,\ cY + d) = ac \cdot \operatorname{cov}(X, Y)$.
4) **Адитивност:** $\operatorname{cov}(X + Z,\ Y) = \operatorname{cov}(X, Y) + \operatorname{cov}(Z, Y)$.
5) Ако $X \perp\!\!\!\perp Y$, то $\operatorname{cov}(X, Y) = 0$.

Доказателство

1) Директно от дефиницията: $\operatorname{cov}(X, Y) = \mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) = \mathbb{E}(Y - \mathbb{E}Y)(X - \mathbb{E}X) = \operatorname{cov}(Y, X)$.
2) $\operatorname{cov}(X, X) = \mathbb{E}X \cdot X - \mathbb{E}X \cdot \mathbb{E}X = \mathbb{E}X^2 - (\mathbb{E}X)^2 = DX$.
3) Ползвайки формулата $\operatorname{cov}(U, V) = \mathbb{E}UV - \mathbb{E}U\,\mathbb{E}V$ и линейността на очакването:

$$\begin{aligned}\operatorname{cov}(aX + b, cY + d) &= \mathbb{E}\big[(aX + b)(cY + d)\big] - \mathbb{E}(aX + b)\,\mathbb{E}(cY + d)\\ &= \mathbb{E}\big[ac\,XY + ad\,X + bc\,Y + bd\big] - (a\,\mathbb{E}X + b)(c\,\mathbb{E}Y + d)\\ &= ac\,\mathbb{E}XY + ad\,\mathbb{E}X + bc\,\mathbb{E}Y + bd - \big(ac\,\mathbb{E}X\,\mathbb{E}Y + ad\,\mathbb{E}X + bc\,\mathbb{E}Y + bd\big)\\ &= ac\big(\mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y\big) = ac \cdot \operatorname{cov}(X, Y).\end{aligned}$$

4) Аналогично:

$$\begin{aligned}\operatorname{cov}(X + Z, Y) &= \mathbb{E}\big[(X + Z)Y\big] - \mathbb{E}(X + Z)\,\mathbb{E}Y = \mathbb{E}XY + \mathbb{E}ZY - (\mathbb{E}X + \mathbb{E}Z)\mathbb{E}Y\\ &= \big(\mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y\big) + \big(\mathbb{E}ZY - \mathbb{E}Z\,\mathbb{E}Y\big) = \operatorname{cov}(X, Y) + \operatorname{cov}(Z, Y).\end{aligned}$$

5) Ако $X \perp\!\!\!\perp Y$, по свойството за очакване на произведение на независими случайни величини (Тема 5), $\mathbb{E}XY = \mathbb{E}X\,\mathbb{E}Y$, следователно $\operatorname{cov}(X, Y) = \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y = 0$. *(Обратното не е вярно в общия случай - нулева ковариация не означава непременно независимост.)* ■

7.3 Корелация

Дефиниция 7.4 (Корелация)

Нека X, Y са случайни величини с $0 < DX < \infty$, $0 < DY < \infty$ (т.е. нито едната не е почти сигурно константа). Тогава

$$\rho(X, Y) := \frac{\operatorname{cov}(X, Y)}{\sqrt{DX}\sqrt{DY}}$$

се нарича **корелация** (коефициент на корелация) между X и Y.

Инвариантност спрямо мащаб

За разлика от ковариацията, корелацията е инвариантна спрямо (положително) мащабиране:

$$\rho(10X, 10Y) = \frac{100\,\mathrm{cov}(X,Y)}{\sqrt{D(10X)}\sqrt{D(10Y)}} = \frac{100\,\mathrm{cov}(X,Y)}{10\sqrt{DX}\cdot 10\sqrt{DY}} = \frac{\mathrm{cov}(X,Y)}{\sqrt{DX}\sqrt{DY}} = \rho(X,Y).$$

Теорема 7.3

Нека X, Y са случайни величини с $0 < DX < \infty$, $0 < DY < \infty$, и нека $\bar{X} = \dfrac{X - \mathbb{E}X}{\sqrt{DX}}$, $\bar{Y} = \dfrac{Y - \mathbb{E}Y}{\sqrt{DY}}$ (**стандартизирани** случайни величини). Тогава $\mathbb{E}\bar{X} = \mathbb{E}\bar{Y} = 0$, $D\bar{X} = D\bar{Y} = 1$, и

$$\rho(X,Y) = \mathbb{E}\bar{X}\bar{Y}.$$

Доказателство

$\mathbb{E}\bar{X} = \mathbb{E}\dfrac{X - \mathbb{E}X}{\sqrt{DX}} = \dfrac{1}{\sqrt{DX}}\,\mathbb{E}(X - \mathbb{E}X) = 0$, понеже $\mathbb{E}(X - \mathbb{E}X) = \mathbb{E}X - \mathbb{E}X = 0$. Аналогично $\mathbb{E}\bar{Y} = 0$.

$D\bar{X} = D\Big(\dfrac{X - \mathbb{E}X}{\sqrt{DX}}\Big) = \dfrac{1}{(\sqrt{DX})^2}\,D(X - \mathbb{E}X) = \dfrac{1}{DX}\cdot DX = 1$ (изваждането на константа $\mathbb{E}X$ не променя дисперсията). Аналогично $D\bar{Y} = 1$.

Накрая:

$$\rho(X,Y) = \frac{\mathrm{cov}(X,Y)}{\sqrt{DX}\sqrt{DY}} = \mathbb{E}\left(\frac{X - \mathbb{E}X}{\sqrt{DX}}\right)\left(\frac{Y - \mathbb{E}Y}{\sqrt{DY}}\right) = \mathbb{E}\bar{X}\bar{Y}.\blacksquare$$

Теорема 7.4

Нека X, Y са случайни величини с $0 < DX < \infty$, $0 < DY < \infty$. Тогава:

а) $|\rho(X,Y)| \le 1$;

б) $|\rho(X,Y)| = 1 \iff Y = aX + b$ за някои $a, b \in \mathbb{R}$ (т.е. Y се предопределя линейно от X).

Доказателство

а) Нека $\bar{X}, \bar{Y}$ са стандартизираните величини от предната теорема, така че $\rho(X,Y) = \mathbb{E}\bar{X}\bar{Y}$. Понеже $D\bar{X} = \mathbb{E}\bar{X}^2 - (\mathbb{E}\bar{X})^2 = 1$ и $\mathbb{E}\bar{X} = 0$, следва $\mathbb{E}\bar{X}^2 = 1$; аналогично $\mathbb{E}\bar{Y}^2 = 1$. Разглеждаме

$$0 \le \mathbb{E}(\bar{X} \pm \bar{Y})^2 = \mathbb{E}\bar{X}^2 \pm 2\,\mathbb{E}\bar{X}\bar{Y} + \mathbb{E}\bar{Y}^2 = 1 \pm 2\rho(X,Y) + 1 = 2\big(1 \pm \rho(X,Y)\big),$$

откъдето $1 \pm \rho(X,Y) \ge 0$ и за двата знака, т.е. $-1 \le \rho(X,Y) \le 1$, или $|\rho(X,Y)| \le 1$.
б) ($\Rightarrow$) Нека $\rho(X,Y) = 1 = \mathbb{E}\bar{X}\bar{Y}$. От горното с избор на знак „$-$“:

$$\mathbb{E}(\bar{X} - \bar{Y})^2 = 1 - 2\rho(X,Y) + 1 = 1 - 2 + 1 = 0.$$

Понеже $(\bar{X} - \bar{Y})^2 \ge 0$ и очакването му е нула, следва $(\bar{X} - \bar{Y})^2 = 0$ (с вероятност 1), т.е. $\bar{X} = \bar{Y}$. Записвайки explicitno $\bar{X} = \dfrac{X - \mathbb{E}X}{\sqrt{DX}}$, $\bar{Y} = \dfrac{Y - \mathbb{E}Y}{\sqrt{DY}}$, от $\bar{X} = \bar{Y}$ получаваме

$$Y = \sqrt{\frac{DY}{DX}}\,X + \Big(\mathbb{E}Y - \sqrt{\frac{DY}{DX}}\,\mathbb{E}X\Big) =: aX + b,$$

където $a = \sqrt{DY/DX} \ge 0$ (в случая $\rho(X,Y) = -1$ разсъждението е аналогично с избор на знак „$+$“, и се получава $a \le 0$).
б) ($\Leftarrow$) Нека $Y = aX + b$. Тогава $\mathbb{E}Y = a\,\mathbb{E}X + b$, $DY = D(aX+b) = a^2 DX$, и

$$\rho(X,Y) = \frac{\mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y)}{\sqrt{DX}\sqrt{DY}} = \frac{\mathbb{E}(X - \mathbb{E}X)(aX + b - a\,\mathbb{E}X - b)}{\sqrt{DX}\sqrt{a^2 DX}}$$
$$= \frac{a\,\mathbb{E}(X - \mathbb{E}X)^2}{|a|\,DX} = \frac{a\,DX}{|a|\,DX} = \frac{a}{|a|} = \pm 1.\blacksquare$$

Тема 8

Условно математическо очакване

8.1 Мотивация: най-добра прогноза

Отправна точка

Знаем, че $DX = \mathbb{E}(X-\mathbb{E}X)^2 = \min_{a\in\mathbb{R}} \mathbb{E}(X-a)^2$ - т.е. константата $a = \mathbb{E}X$ е *най-добрата* (в смисъл на най-малка средноквадратична грешка) константна прогноза за случайната величина X. Естественият въпрос е: ако разполагаме с *допълнителна информация* за друга случайна величина Y, каква е най-добрата функция $G(Y)$, която прогнозира X, т.е. коя G минимизира $\mathbb{E}\big(X - G(Y)\big)^2$?

Извеждане за бинарно Y

Нека $Y \in \{0,1\}$, $A = \{Y{=}1\}$, $A^c = \{Y{=}0\}$. Всяка функция на Y има вида $G(Y) = G(1)I_A + G(0)I_{A^c} = aI_A + bI_{A^c}$ за някои константи a, b, така че задачата се свежда до

$$f(a,b) := \mathbb{E}\big(X - aI_A - bI_{A^c}\big)^2 = \mathbb{E}X^2 + a^2\,\mathbb{E}I_A + b^2\,\mathbb{E}I_{A^c} - 2a\,\mathbb{E}XI_A - 2b\,\mathbb{E}XI_{A^c} \to \min_{a,b\in\mathbb{R}}.$$

Полагаме частните производни на нула:

$$0 = \frac{\partial f}{\partial a} = 2a\,\mathbb{E}I_A - 2\,\mathbb{E}XI_A \;\Rightarrow\; a = \frac{\mathbb{E}XI_A}{\mathbb{P}(A)},$$
$$0 = \frac{\partial f}{\partial b} = 2b\,\mathbb{E}I_{A^c} - 2\,\mathbb{E}XI_{A^c} \;\Rightarrow\; b = \frac{\mathbb{E}XI_{A^c}}{\mathbb{P}(A^c)}$$

(използвахме $\mathbb{E}I_A = \mathbb{P}(A)$). Следователно оптималната прогноза е

$$G^*(Y) = \frac{\mathbb{E}XI_A}{\mathbb{P}(A)}\,I_A + \frac{\mathbb{E}XI_{A^c}}{\mathbb{P}(A^c)}\,I_{A^c},$$

т.е. функцията, която най-добре предсказва X на базата на Y, е именно **условното математическо очакване**.

8.2 Дефиниция

Дефиниция 8.1 (Условно математическо очакване)

Нека X, Y са случайни величини с $\mathbb{E}X^2 < \infty$ (т.е. $X \in L^2$, за да е добре дефиниран минимумът по-долу). Тогава $\mathbb{E}(X \mid Y) := G^*(Y)$ е случайната величина, за която

$$\min_G \mathbb{E}\big(X - G(Y)\big)^2 = \mathbb{E}\big(X - G^*(Y)\big)^2 = \mathbb{E}\big(X - \mathbb{E}(X \mid Y)\big)^2,$$

т.е. функцията на Y, която минимизира средноквадратичната грешка на прогнозата за X.

Теорема 8.1

Нека X, Y са случайни величини, като Y е дискретна с разпределение $\mathbb{P}(Y = y_j) = p_j$. Полагаме $A_j = \{Y = y_j\}$, така че $Y = \sum_j y_j I_{A_j}$. Тогава

$$\mathbb{E}[X \mid Y] = \sum_j \frac{\mathbb{E}X I_{A_j}}{\mathbb{P}(A_j)}\, I_{A_j}$$

(т.е. $\mathbb{E}[X \mid Y]$ е случайна величина).

Доказателство

Нека $G(Y) = \sum_j a_j I_{A_j}$ е произволна функция на Y (параметризирана с коефициентите a_j). Разглеждаме

$$f(a_1, a_2, \dots) = \mathbb{E}\big(X - G(Y)\big)^2 = \mathbb{E}\Big(X - \sum_j a_j I_{A_j}\Big)^2.$$

За всяко i, полагаме частната производна по a_i на нула (понеже $\{A_j\}$ са несъвместими, кръстосаните членове изчезват):

$$0 = \frac{\partial f}{\partial a_i} = -2\,\mathbb{E}\Big(X - \sum_j a_j I_{A_j}\Big) I_{A_i} = -2\big(\mathbb{E}X I_{A_i} - a_i\,\mathbb{E}I_{A_i}\big) \;\Rightarrow\; a_i = \frac{\mathbb{E}X I_{A_i}}{\mathbb{P}(A_i)}.$$

Следователно $\mathbb{E}(X \mid Y) = \sum_j \frac{\mathbb{E}X I_{A_j}}{\mathbb{P}(A_j)}\, I_{A_j}$. ■

Разписване по стойности на X

Нека допълнително $X = \sum_i x_i I_{B_i}$ е дискретна, $B_i = \{X = x_i\}$. Тогава

$$\begin{aligned}\frac{\mathbb{E}X I_{A_j}}{\mathbb{P}(A_j)} &= \frac{\mathbb{E}\sum_i x_i I_{B_i} I_{A_j}}{\mathbb{P}(A_j)} = \sum_i x_i \frac{\mathbb{P}(A_j \cap B_i)}{\mathbb{P}(A_j)} \\ &= \sum_i x_i\, \mathbb{P}(B_i \mid A_j) = \sum_i x_i\, \mathbb{P}(X = x_i \mid Y = y_j),\end{aligned}$$

което мотивира следната по-фина дефиниция - стойността на условното очакване *при конкретно фиксирано* $Y = y_j$.

Дефиниция 8.2 (УМО при фиксирано $Y = y_j$)

Нека X, Y са дискретни случайни величини. Тогава за всяко j:

$$\mathbb{E}[X \mid Y = y_j] = \sum_i x_i \, \mathbb{P}(X = x_i \mid Y = y_j).$$

Важно разграничение

$\mathbb{E}[X \mid Y]$ е **случайна величина** (функция на изхода на случайния експеримент чрез Y), докато $\mathbb{E}[X \mid Y = y_j]$ е **число** - стойността на тази случайна величина, когато Y вземе конкретната стойност y_j.

Следствие 8.1

Нека X, Y са дискретни случайни величини. Тогава $\mathbb{E}[X \mid Y]$ е дискретна случайна величина, приемаща стойностите $\mathbb{E}[X \mid Y = y_j]$ с вероятности $\mathbb{P}(Y = y_j)$:

$\mathbb{E}[X \mid Y]$	$\mathbb{E}[X \mid Y{=}y_1]$	$\dots$	$\mathbb{E}[X \mid Y{=}y_j]$	$\dots$
$\mathbb{P}$	$p_1 = \mathbb{P}(A_1)$	$\dots$	$p_j = \mathbb{P}(A_j)$	$\dots$

8.3 Свойства на условното математическо очакване

Свойства 8.2 (на условното математическо очакване)

Нека X, Y, Z са случайни величини с $\mathbb{E}X < \infty$, $\mathbb{E}Z < \infty$, като Y е дискретна.

1) **Линейност:** $\mathbb{E}[aX + bZ \mid Y] = a\,\mathbb{E}[X \mid Y] + b\,\mathbb{E}[Z \mid Y]$.

2) **Независимост:** ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}[X \mid Y] = \mathbb{E}X$.

3) **„Изваждане на познатото“:** ако $X = f(Y)$ за някаква функция f, то $\mathbb{E}[X \mid Y] = X = f(Y)$.

4) **Кула-свойство (закон за повторното очакване):** $\mathbb{E}\big[\mathbb{E}[X \mid Y]\big] = \mathbb{E}X$.

Доказателство

Навсякъде означаваме $A_j = \{Y = y_j\}$.

1)

$$\mathbb{E}[aX + bZ \mid Y] = \sum_j \frac{\mathbb{E}\big[(aX+bZ)I_{A_j}\big]}{\mathbb{P}(A_j)} I_{A_j} = \sum_j \frac{a\,\mathbb{E}XI_{A_j} + b\,\mathbb{E}ZI_{A_j}}{\mathbb{P}(A_j)} I_{A_j}$$

$$= a\sum_j \frac{\mathbb{E}XI_{A_j}}{\mathbb{P}(A_j)} I_{A_j} + b\sum_j \frac{\mathbb{E}ZI_{A_j}}{\mathbb{P}(A_j)} I_{A_j} = a\,\mathbb{E}[X \mid Y] + b\,\mathbb{E}[Z \mid Y].$$

2) Ако $X \perp\!\!\!\perp Y$, то $X \perp\!\!\!\perp I_{A_j}$ за всяко j (индикаторът на Y носи информация само за Y), следователно $\mathbb{E}XI_{A_j} = \mathbb{E}X \cdot \mathbb{E}I_{A_j} = \mathbb{E}X \cdot \mathbb{P}(A_j)$, т.е. $\dfrac{\mathbb{E}XI_{A_j}}{\mathbb{P}(A_j)} = \mathbb{E}X$ за всяко j. Тогава

$$\mathbb{E}[X \mid Y] = \sum_j \frac{\mathbb{E}XI_{A_j}}{\mathbb{P}(A_j)} I_{A_j} = \sum_j \mathbb{E}X \cdot I_{A_j} = \mathbb{E}X \sum_j I_{A_j} = \mathbb{E}X$$

(понеже $\{A_j\}$ е пълна група от събития, $\sum_j I_{A_j} \equiv 1$).

3) Ако $X = f(Y)$, то върху $A_j = \{Y = y_j\}$ имаме $X = f(y_j)$ (константа), следователно

$$\frac{\mathbb{E}XI_{A_j}}{\mathbb{P}(A_j)} = \frac{\mathbb{E}f(Y)I_{A_j}}{\mathbb{P}(A_j)} = \frac{f(y_j)\,\mathbb{P}(A_j)}{\mathbb{P}(A_j)} = f(y_j),$$

и оттам $\mathbb{E}[X \mid Y] = \sum_j f(y_j) I_{A_j} = f(Y) = X$.

4) Пряко от дефиницията и линейността на очакването:

$$\mathbb{E}\big[\mathbb{E}[X \mid Y]\big] = \mathbb{E}\Big[\sum_j \frac{\mathbb{E}XI_{A_j}}{\mathbb{P}(A_j)} I_{A_j}\Big] = \sum_j \frac{\mathbb{E}XI_{A_j}}{\mathbb{P}(A_j)}\,\mathbb{E}I_{A_j}$$

$$= \sum_j \mathbb{E}XI_{A_j} = \mathbb{E}X\Big(\sum_j I_{A_j}\Big) = \mathbb{E}X,$$

защото $\mathbb{E}I_{A_j} = \mathbb{P}(A_j)$ съкращава знаменателя, а $\{A_j\}$ е пълна група от събития. ■

8.4 Условно разпределение

Дефиниция 8.3 (Условно разпределение)

Нека X, Y са дискретни случайни величини. **Условното разпределение** на X при положение $Y = y_j$ е

$X \mid Y{=}y_j$	x_1	$\dots$	$x_i \dots$
$\mathbb{P}$	$\mathbb{P}(X{=}x_1 \mid Y{=}y_j)$	$\dots$	$\mathbb{P}(X{=}x_i \mid Y{=}y_j) \dots$

За всяко фиксирано j, $\sum_i \mathbb{P}(X = x_i \mid Y = y_j) = 1$ - това е коректно вероятностно разпределение (върху стойностите на X, „при новите правила на играта“, зададени от условието $Y = y_j$).

Тема 9

Непрекъснати случайни величини

9.1 Дефиниция и плътност

Дефиниция 9.1 (Непрекъсната случайна величина)

Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $X : \Omega \to \mathbb{R}$ - случайна величина. Казваме, че X е **(абсолютно) непрекъсната случайна величина** (за краткост - просто *непрекъсната*), ако съществува функция $f_X : \mathbb{R} \to [0, \infty)$, такава че:

1) $f_X(x) \geq 0$ за всяко $x \in \mathbb{R}$;

2) $\int_{-\infty}^{\infty} f_X(x)\, dx = 1$;

3) за всички $a < b$ $(-\infty \leq a < b \leq \infty)$: $\mathbb{P}\big(X \in (a, b)\big) = \int_a^b f_X(x)\, dx$.

Функцията f_X се нарича **плътност** на X.

Теорема 9.1

Нека X е непрекъсната случайна величина и $c \in \mathbb{R}$. Тогава $\mathbb{P}(X = c) = 0$, и следователно за $a < b$:

$$\mathbb{P}\big(X \in (a, b)\big) = \mathbb{P}(a < X < b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a \leq X \leq b).$$

Доказателство

Записваме $\{X = c\}$ като сечение на смаляващи се интервали:

$$\{X = c\} = \bigcap_{n \geq 1} \Big\{ X \in \big(c - \tfrac{1}{n},\, c + \tfrac{1}{n}\big) \Big\}.$$

По непрекъснатостта на вероятността отгоре (Тема 2):

$$\mathbb{P}(X = c) = \lim_{n \to \infty} \mathbb{P}\Big(X \in \big(c - \tfrac{1}{n}, c + \tfrac{1}{n}\big)\Big) = \lim_{n \to \infty} \int_{c - \frac{1}{n}}^{c + \frac{1}{n}} f_X(x)\, dx = \int_c^c f_X(x)\, dx = 0,$$

защото горната и долната граница на интеграла клонят към едно и също число c. Следователно добавянето или изваждането на краищата a, b (всяко от които е отделна точка с нулева вероятност) не променя вероятността на интервала. ■

Дефиниция 9.2 (Носител на плътността)

Ако f_X е плътност за X, множеството $D_{f_X} = \{x \in \mathbb{R} : f_X(x) > 0\}$ (областта, върху която плътността е строго положителна) се нарича **носител** на плътността.

9.2 Функция на разпределение

Дефиниция 9.3 (Функция на разпределение)

Нека X е случайна величина. Тогава $F_X(x) = \mathbb{P}(X < x)$. Ако X е непрекъсната с плътност f_X, то

$$F_X(x) = \int_{-\infty}^{x} f_X(y)\,dy, \qquad \forall x \in \mathbb{R},$$

и ако f_X е непрекъсната в точка x_0, то $F'_X(x_0) = f_X(x_0)$ - т.е. можем да възстановим плътността от функцията на разпределение чрез диференциране: $F'_X = f_X$. Освен това, за непрекъсната X: $\mathbb{P}(X < x) = \mathbb{P}(X \leq x)$ за всяко $x \in \mathbb{R}$ (следва от предната теорема).

9.3 Смяна на променливите

Предупреждение

Ако X е непрекъсната случайна величина, $Y = g(X)$ не е задължително непрекъсната случайна величина за произволна g. Например за $g(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$, $Y = g(X) \in \{0, 1\}$ приема само две стойности и *не е* непрекъсната случайна величина. Затова смяната на променливите изисква допълнителни условия върху g.

Теорема 9.2

Нека X е непрекъсната случайна величина с плътност f_X и носител D_{f_X}, и нека $g : \mathbb{R} \to \mathbb{R}$ е строго монотонна (растяща или намаляваща) и диференцируема функция върху D_{f_X} (или върху интервал $(A, B) \supseteq D_{f_X}$). Тогава $Y = g(X)$ е непрекъсната случайна величина с плътност

$$f_Y(y) = f_X\big(g^{-1}(y)\big) \cdot \big|(g^{-1}(y))'\big|, \qquad y \in \mathbb{R}.$$

Доказателство

Случай 1: g строго растяща. Нека $a < b$. Понеже g е растяща (и следователно обратима), $g(X) \in (a,b) \iff X \in (g^{-1}(a), g^{-1}(b))$, откъдето

$$\mathbb{P}\big(Y \in (a,b)\big) = \mathbb{P}\big(X \in (g^{-1}(a), g^{-1}(b))\big) = \int_{g^{-1}(a)}^{g^{-1}(b)} f_X(x)\,dx.$$

Извършваме смяна на променливата $x = g^{-1}(y)$, $dx = (g^{-1}(y))'\,dy$:

$$\int_{g^{-1}(a)}^{g^{-1}(b)} f_X(x)\,dx = \int_a^b f_X\big(g^{-1}(y)\big)\,(g^{-1}(y))'\,dy,$$

откъдето (по дефиниция на плътност) $f_Y(y) = f_X(g^{-1}(y)) \cdot (g^{-1}(y))'$. Понеже g е растяща, g^{-1} също е растяща, т.е. $(g^{-1}(y))' \geq 0$, следователно $(g^{-1}(y))' = |(g^{-1}(y))'|$.
Случай 2: g строго намаляваща. Аналогично, $g(X) \in (a,b) \iff X \in (g^{-1}(b), g^{-1}(a))$ (границите се разменят, защото g обръща посоката на неравенствата), откъдето

$$\mathbb{P}\big(Y \in (a,b)\big) = \int_{g^{-1}(b)}^{g^{-1}(a)} f_X(x)\,dx \overset{x=g^{-1}(y)}{=} -\int_a^b f_X\big(g^{-1}(y)\big)(g^{-1}(y))'\,dy,$$

и понеже сега g^{-1} е намаляваща, $(g^{-1}(y))' \leq 0$, т.е. $-(g^{-1}(y))' = |(g^{-1}(y))'|$, следователно отново $f_Y(y) = f_X(g^{-1}(y)) \cdot |(g^{-1}(y))'|$. ■

9.4 Математическо очакване

Дефиниция 9.4 (Математическо очакване на непрекъсната случайна величина)

Нека X е непрекъсната случайна величина с плътност f_X. Тогава

$$\mathbb{E}X = \int_{-\infty}^{\infty} x\, f_X(x)\,dx,$$

ако несобственият интеграл е добре дефиниран, т.е. $\int_{-\infty}^{\infty} |x| f_X(x)\,dx < \infty$.

Теорема 9.3 (Смяна на променливите за очакване)

Ако $Y = g(X)$ и $\int_{-\infty}^{\infty} |g(x)| f_X(x)\,dx < \infty$, то

$$\mathbb{E}Y = \mathbb{E}g(X) = \int_{-\infty}^{\infty} g(x)\, f_X(x)\,dx$$

(т.е. не е нужно първо да намираме плътността f_Y на Y).

Доказателство

По дефиниция и предната теорема за смяна на променливите (за g строго монотонна, диференцируема):

$$\mathbb{E}Y = \int_{-\infty}^{\infty} y\, f_Y(y)\, dy = \int_{-\infty}^{\infty} y\, f_X(g^{-1}(y))\, (g^{-1}(y))'\, dy.$$

Извършваме обратната смяна $x = g^{-1}(y)$, $y = g(x)$, $dy = g'(x)\, dx$:

$$= \int_{-\infty}^{\infty} g(x)\, f_X(x)\, \big(g^{-1}(g(x))\big)'\, g'(x)\, dx = \int_{-\infty}^{\infty} g(x)\, f_X(x)\, dx,$$

защото по правилото за диференциране на обратна функция, $\big(g^{-1}(g(x))\big)' \cdot g'(x) = \big(x\big)' = 1$. ■

Свойства 9.4 (на математическото очакване)

Нека X, Y са непрекъснати случайни величини с крайни очаквания.

1) $\mathbb{E}(aX + b) = a\,\mathbb{E}X + b$ за $a, b \in \mathbb{R}$.

2) $\mathbb{E}(X + Y) = \mathbb{E}X + \mathbb{E}Y$.

3) Ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}(XY) = \mathbb{E}X \cdot \mathbb{E}Y$.

4) $\mathbb{E}(cX) = c\,\mathbb{E}X$ за $c \in \mathbb{R}$.

Доказателство

1) Нека $g(x) = ax + b$. Ако $a = 0$, $Y \equiv b$ и $\mathbb{E}Y = b$ тривиално. Иначе, по теоремата за смяна на променливите за очакване:

$$\mathbb{E}g(X) = \int_{-\infty}^{\infty} (ax + b) f_X(x)\, dx = a \int_{-\infty}^{\infty} x f_X(x)\, dx + b \int_{-\infty}^{\infty} f_X(x)\, dx = a\,\mathbb{E}X + b.$$

2) Нека $f_{X,Y}(x, y)$ е съвместната плътност на (X, Y) (с маргинали f_X, f_Y). Тогава

$$\begin{aligned}
\mathbb{E}(X + Y) &= \iint (x + y) f_{X,Y}(x, y)\, dx\, dy = \iint x f_{X,Y}(x, y)\, dx\, dy + \iint y f_{X,Y}(x, y)\, dx\, dy \\
&= \int x \Big(\int f_{X,Y}(x, y)\, dy \Big) dx + \int y \Big(\int f_{X,Y}(x, y)\, dx \Big) dy \\
&= \int x f_X(x)\, dx + \int y f_Y(y)\, dy = \mathbb{E}X + \mathbb{E}Y.
\end{aligned}$$

3) Ако $X \perp\!\!\!\perp Y$, то съвместната плътност се разпада, $f_{X,Y}(x, y) = f_X(x) f_Y(y)$, следователно

$$\mathbb{E}XY = \iint xy\, f_X(x) f_Y(y)\, dx\, dy = \Big(\int x f_X(x)\, dx \Big) \Big(\int y f_Y(y)\, dy \Big) = \mathbb{E}X \cdot \mathbb{E}Y.$$

4) $\mathbb{E}cX = \int_{-\infty}^{\infty} cx\, f_X(x)\, dx = c \int_{-\infty}^{\infty} x f_X(x)\, dx = c\,\mathbb{E}X$. ■

9.5 Дисперсия

Дефиниция 9.5 (Дисперсия на непрекъсната случайна величина)

Нека X е непрекъсната случайна величина с очакване $\mathbb{E}X$. Тогава

$$DX = \int_{-\infty}^{\infty} (x - \mathbb{E}X)^2 f_X(x)\,dx = \mathbb{E}\big[X - \mathbb{E}X\big]^2 = \min_{a\in\mathbb{R}} \mathbb{E}(X-a)^2,$$

ако интегралът е добре дефиниран (краен). *(Съществуват случаи, в които $\mathbb{E}X < \infty$, но $DX = \infty$.)*

Свойства 9.5 (на дисперсията)

Нека X, Y са непрекъснати случайни величини с $DX < \infty$, $DY < \infty$.

1) $D(aX + b) = a^2 DX$ за $a, b \in \mathbb{R}$.
2) $DX = \mathbb{E}X^2 - (\mathbb{E}X)^2$.
3) $Dc = 0$ за константа c.
4) Ако $X \perp\!\!\!\perp Y$, то $D(X + Y) = DX + DY$.

Доказателство

1) Полагаме $a_0 = \mathbb{E}X$. Понеже $\mathbb{E}(aX + b) = a\,\mathbb{E}X + b$ (свойство 1 на очакването):

$$\begin{aligned} D(aX+b) &= \mathbb{E}\big(aX + b - \mathbb{E}(aX+b)\big)^2 = \mathbb{E}\big(aX + b - a\,\mathbb{E}X - b\big)^2 = \mathbb{E}\big[a^2(X - \mathbb{E}X)^2\big] \\ &= a^2 \int_{-\infty}^{\infty} (x - \mathbb{E}X)^2 f_X(x)\,dx = a^2 DX. \end{aligned}$$

2) Нека $a = \mathbb{E}X$. Тогава

$$\begin{aligned} DX &= \int_{-\infty}^{\infty} (x-a)^2 f_X(x)\,dx = \int_{-\infty}^{\infty} (x^2 - 2ax + a^2) f_X(x)\,dx \\ &= \int x^2 f_X(x)\,dx - 2a \int x f_X(x)\,dx + a^2 \int f_X(x)\,dx \\ &= \mathbb{E}X^2 - 2a \cdot a + a^2 \cdot 1 = \mathbb{E}X^2 - a^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2. \end{aligned}$$

3) $Dc = \mathbb{E}(c - \mathbb{E}c)^2 = \mathbb{E}(c-c)^2 = \mathbb{E}0 = 0$.
4) Използвайки свойство 2 (връзка с $\mathbb{E}X^2$) и свойство 3 на очакването (мултипликативност при независимост):

$$\begin{aligned} D(X+Y) &= \mathbb{E}(X+Y)^2 - \big(\mathbb{E}(X+Y)\big)^2 = \mathbb{E}\big(X^2 + 2XY + Y^2\big) - (\mathbb{E}X + \mathbb{E}Y)^2 \\ &= \mathbb{E}X^2 + 2\,\mathbb{E}XY + \mathbb{E}Y^2 - (\mathbb{E}X)^2 - 2\,\mathbb{E}X\,\mathbb{E}Y - (\mathbb{E}Y)^2 \\ &\overset{X \perp\!\!\!\perp Y}{=} \big(\mathbb{E}X^2 - (\mathbb{E}X)^2\big) + \big(\mathbb{E}Y^2 - (\mathbb{E}Y)^2\big) = DX + DY. \blacksquare \end{aligned}$$

Тема 10

Видове непрекъснати случайни величини

10.1 Равномерно разпределение

Дефиниция 10.1 ($X \sim U(a,b)$)

Нека $-\infty < a < b < \infty$. Казваме, че $X \sim U(a,b)$, ако

$$f_X(x) = \begin{cases} \dfrac{1}{b-a}, & x \in (a,b) \\ 0, & \text{иначе} \end{cases}.$$

Идея

Ако имаме интервал $(c,d) \subseteq (a,b)$, вероятността да попаднем в него зависи само от дължината на интервала - тя е пропорционална на $d-c$. Всички изходи в (a,b) са равновероятни.

Теорема 10.1

Ако $X \sim U(a,b)$, то за $A \subseteq (a,b)$: $\mathbb{P}(A) = \dfrac{|A|}{b-a}$; освен това

$$\mathbb{E}X = \frac{a+b}{2}, \qquad \mathbb{E}X^2 = \frac{a^2+ab+b^2}{3}, \qquad DX = \frac{(a-b)^2}{12},$$

и

$$F_X(x) = \begin{cases} 0, & x \le a \\ \dfrac{x-a}{b-a}, & x \in (a,b) \\ 1, & x \ge b \end{cases}.$$

Доказателство

$$\mathbb{E}X = \int_a^b \frac{x}{b-a}\,dx = \frac{1}{b-a}\cdot\frac{x^2}{2}\Big|_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{a+b}{2}.$$

$$\mathbb{E}X^2 = \int_a^b \frac{x^2}{b-a}\,dx = \frac{1}{b-a}\cdot\frac{x^3}{3}\Big|_a^b = \frac{b^3-a^3}{3(b-a)} = \frac{a^2+ab+b^2}{3}.$$

$$DX = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \frac{a^2+ab+b^2}{3} - \frac{(a+b)^2}{4} = \frac{(a-b)^2}{12}$$

(след привеждане под общ знаменател 12 и опростяване). Функцията на разпределение се получава директно чрез интегриране на плътността: за $x \in (a,b)$, $F_X(x) = \int_a^x \frac{1}{b-a}\,dy = \frac{x-a}{b-a}$. ■

Забележка

DX зависи само от дължината на интервала $b-a$, а не от неговото разположение (позиция) върху числовата ос.

Теорема 10.2 (стандартизация на равномерното разпределение)

Ако $X \sim U(a,b)$, то $Y = \dfrac{X-a}{b-a} \sim U(0,1)$; и обратно, ако $Y \sim U(0,1)$, то $X = a+(b-a)Y \sim U(a,b)$.

Доказателство

($\Rightarrow$) Нека $D_{f_X} = (a,b)$ и $g(x) = \dfrac{x-a}{b-a}$ - строго растяща функция. Тогава $g^{-1}(y) = a+(b-a)y$, $(g^{-1}(y))' = b-a$, и по теоремата за смяна на променливите (Тема 9):

$$f_Y(y) = f_X\big(g^{-1}(y)\big)\cdot(b-a) = \begin{cases} \dfrac{b-a}{b-a} = 1, & y \in (0,1) \\ 0, & \text{иначе} \end{cases} \quad\Longrightarrow\quad Y \sim U(0,1).$$

($\Leftarrow$) Нека $Y \sim U(0,1)$, т.е. $f_Y(y) = 1$ за $y \in (0,1)$, 0 иначе. Разглеждаме $X = g(Y) = a+(b-a)Y$ - строго растяща функция на Y (защото $b > a$), с $g^{-1}(x) = \dfrac{x-a}{b-a}$ и $(g^{-1}(x))' = \dfrac{1}{b-a}$. Тогава

$$f_X(x) = f_Y\big(g^{-1}(x)\big)\cdot\left|\frac{1}{b-a}\right| = \begin{cases} \dfrac{1}{b-a}, & 0 < \dfrac{x-a}{b-a} < 1 \iff a < x < b \\ 0, & \text{иначе} \end{cases}$$

$$\Longrightarrow \quad X \sim U(a,b).$$ ■

Пресмятане за $U(0,1)$

За $X \sim U(0,1)$: $\mathbb{E}X = \int_0^1 x\,dx = \frac{1}{2}$, и

$$DX = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \int_0^1 x^2\,dx - \frac{1}{4} = \frac{1}{3} - \frac{1}{4} = \frac{1}{12},$$

което съвпада с горната обща формула $DX = \frac{(b-a)^2}{12}$ при $a = 0, b = 1$.

10.2 Нормално (Гаусово) разпределение

Дефиниция 10.2 ($X \sim N(\mu, \sigma^2)$)

Нека $\mu \in \mathbb{R}$, $\sigma^2 > 0$. Казваме, че $X \sim N(\mu, \sigma^2)$ (*нормално/Гаусово разпределение*), ако

$$f_X(x) = \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \qquad x \in \mathbb{R},$$

където μ е средната стойност, а σ - стандартното отклонение. „Камбанката“ е по-висока и по-тясна за по-малко σ.

Стандартно нормално разпределение

$Z \sim N(0,1)$ се нарича **стандартно нормално разпределение**: $f_Z(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$. Приемаме за известен факта, че $\frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} e^{-(y-\mu)^2/(2\sigma^2)}\, dy = 1$ (нормировъчен интеграл на Гаус), т.е. плътността f_X е коректно дефинирана. Означаваме $F_Z(x) = \Phi(x) = \mathbb{P}(Z < x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-y^2/2}\, dy$.

Теорема 10.3

Ако $X \sim N(\mu, \sigma^2)$, то $Z = \dfrac{X-\mu}{\sigma} \sim N(0,1)$.

Доказателство

Нека $g(x) = \dfrac{x-\mu}{\sigma}$ - строго растяща функция, с $g^{-1}(z) = \mu + \sigma z$, $(g^{-1}(z))' = \sigma$. По теоремата за смяна на променливите (Тема 9):

$$f_Z(z) = f_X\big(g^{-1}(z)\big) \cdot \sigma = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\mu+\sigma z-\mu)^2}{2\sigma^2}} \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-\frac{\sigma^2 z^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}. \blacksquare$$

Следствие 10.1

Ако $X \sim N(\mu, \sigma^2)$, то $\mathbb{E}X = \mu$ и $DX = \sigma^2$.

Доказателство

От предната теорема $X = \mu + \sigma Z$, $Z \sim N(0,1)$.
$\mathbb{E}X = \mu + \sigma\,\mathbb{E}Z$, като

$$\mathbb{E}Z = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z\, e^{-z^2/2}\, dz = 0,$$

защото подинтегралната функция $z \mapsto ze^{-z^2/2}$ е нечетна (а интегралът ѝ по симетричен относно нулата интервал е нула). Следователно $\mathbb{E}X = \mu$.
$DX = \sigma^2 DZ$, като (интегрирайки по части, с $u = z$, $dv = ze^{-z^2/2}dz \Rightarrow v = -e^{-z^2/2}$):

$$DZ = \mathbb{E}Z^2 - (\mathbb{E}Z)^2 = \mathbb{E}Z^2 = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z^2 e^{-z^2/2}\, dz = \frac{2}{\sqrt{2\pi}} \int_{0}^{\infty} z^2 e^{-z^2/2}\, dz$$
$$= \frac{2}{\sqrt{2\pi}} \left[-ze^{-z^2/2}\Big|_0^{\infty} + \int_0^{\infty} e^{-z^2/2}\, dz \right] = \frac{2}{\sqrt{2\pi}} \cdot \frac{1}{2} \int_{-\infty}^{\infty} e^{-z^2/2}\, dz = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-z^2/2} dz = 1$$

(използвахме четността на $z \mapsto z^2 e^{-z^2/2}$, граничния член $-ze^{-z^2/2} \to 0$ при $z \to \infty$, и нормировъчния интеграл на Гаус за $N(0,1)$). Следователно $DX = \sigma^2 \cdot 1 = \sigma^2$. ■

10.3 Експоненциално разпределение

Дефиниция 10.3 ($X \sim Exp(\lambda)$)

Нека $\lambda > 0$. Казваме, че $X \sim Exp(\lambda)$, ако

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{иначе} \end{cases}.$$

Коректност и функция на разпределение

$$\int_0^{\infty} \lambda e^{-\lambda x}\, dx = -e^{-\lambda x}\Big|_0^{\infty} = \lim_{x\to\infty} (-e^{-\lambda x}) - (-1) = 0 + 1 = 1.$$

Функцията на разпределение и функцията на оцеляване („опашка“) са:

$$F_X(x) = \int_0^x \lambda e^{-\lambda y}\, dy = 1 - e^{-\lambda x}, \qquad \overline{F}_X(x) = 1 - F_X(x) = e^{-\lambda x}, \qquad x \geq 0.$$

Теорема 10.4

Ако $X \sim Exp(\lambda)$, то $\mathbb{E}X = \frac{1}{\lambda}$ и $DX = \frac{1}{\lambda^2}$.

Доказателство

Интегрираме по части ($u = x$, $dv = \lambda e^{-\lambda x} dx \Rightarrow v = -e^{-\lambda x}$):

$$\mathbb{E}X = \int_0^\infty x\lambda e^{-\lambda x}\, dx = -xe^{-\lambda x}\Big|_0^\infty + \int_0^\infty e^{-\lambda x}\, dx = 0 + \Big(-\frac{e^{-\lambda x}}{\lambda}\Big|_0^\infty\Big) = \frac{1}{\lambda}$$

(граничният член изчезва, защото експонентата клони към нула по-бързо, отколкото x расте). За дисперсията ползваме метода на диференциране по параметър („трик на Файнман“): нека $f(\lambda) := \mathbb{E}X = \int_0^\infty x\lambda e^{-\lambda x}\, dx = \frac{1}{\lambda}$. Диференцираме двете представяния на $f(\lambda)$ по λ. От дясната страна: $f'(\lambda) = -\frac{1}{\lambda^2}$. От лявата страна, диференцирайки под интеграла:

$$f'(\lambda) = \int_0^\infty x\,\frac{\partial}{\partial\lambda}\big(\lambda e^{-\lambda x}\big)\, dx = \int_0^\infty x\big(e^{-\lambda x} - \lambda x e^{-\lambda x}\big)\, dx = \underbrace{\int_0^\infty xe^{-\lambda x}\, dx}_{=1/\lambda^2} - \underbrace{\int_0^\infty x^2\lambda e^{-\lambda x}\, dx}_{=\mathbb{E}X^2}.$$

Приравнявайки двата израза за $f'(\lambda)$:

$$\frac{1}{\lambda^2} - \mathbb{E}X^2 = -\frac{1}{\lambda^2} \quad\Longrightarrow\quad \mathbb{E}X^2 = \frac{2}{\lambda^2}.$$

Следователно

$$DX = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.\blacksquare$$

Теорема 10.5 (безпаметност на експоненциалното разпределение)

Ако $X \sim Exp(\lambda)$, то за всички $x, y > 0$:

$$\mathbb{P}(X > x + y \mid X > x) = \mathbb{P}(X > y).$$

Доказателство

$$\mathbb{P}(X > x + y \mid X > x) = \frac{\mathbb{P}(X > x + y,\, X > x)}{\mathbb{P}(X > x)} = \frac{\mathbb{P}(X > x + y)}{\mathbb{P}(X > x)}$$
$$= \frac{e^{-\lambda(x+y)}}{e^{-\lambda x}} = e^{-\lambda y} = \mathbb{P}(X > y).\blacksquare$$

Тема 11

Непрекъснати съвместни разпределения, Гама разпределение

11.1 Съвместни непрекъснати разпределения

Дефиниция 11.1 (Съвместно непрекъснато разпределение)

Нека $X = (X_1, \ldots, X_n)$ е вектор от n случайни величини. Казваме, че X има **съвместно непрекъснато разпределение** със **съвместна плътност** $f_X : \mathbb{R}^n \to \mathbb{R}$, ако:

1) $f_X(x_1, \ldots, x_n) \geq 0$;

2) $\displaystyle\int_{\mathbb{R}^n} f_X(x_1, \ldots, x_n)\, dx_1 \cdots dx_n = 1$;

3) за всяко $D \subseteq \mathbb{R}^n$: $\mathbb{P}(X \in D) = \displaystyle\int_D f_X(x_1, \ldots, x_n)\, dx_1 \cdots dx_n$.

Дефиниция 11.2 (Носител)

$D_{f_X} = \{\bar{x} \in \mathbb{R}^n : f_X(\bar{x}) > 0\}$.

Дефиниция 11.3 (Маргинална плътност)

Нека $X = (X_1, \ldots, X_n)$ има съвместна плътност f_X. Тогава

$$f_{X_j}(x_j) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_X(x_1, \ldots, x_{j-1}, x_j, x_{j+1}, \ldots, x_n)\, dx_1 \cdots dx_{j-1}\, dx_{j+1} \cdots dx_n$$

(интегрираме по всички променливи с изключение на x_j, който остава фиксиран) се нарича **маргинална плътност** на X_j.

Дефиниция 11.4 (Условна плътност)

Нека $X = (X_1, X_2)$ със съвместна плътност f_X и нека x_2 е фиксирано с $f_{X_2}(x_2) > 0$. Тогава

$$f_{X_1 | X_2 = x_2}(x_1 \mid x_2) := \frac{f_X(x_1, x_2)}{f_{X_2}(x_2)}$$

е **условната плътност** на X_1 при информация за $X_2 = x_2$. За нея $\mathbb{P}\big(X_1 \in (a, b) \mid X_2 = x_2\big) = \displaystyle\int_a^b f_{X_1 | X_2 = x_2}(x_1 \mid x_2)\, dx_1$.

Дефиниция 11.5 (Съвместна функция на разпределение)

Нека $X = (X_1, \ldots, X_n)$. Тогава

$$F_X(x_1, \ldots, x_n) = \mathbb{P}(X_1 < x_1, \ldots, X_n < x_n), \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n.$$

Ако X е вектор от непрекъснати случайни величини със съвместна плътност f_X, непрекъсната в $\bar{x} \in \mathbb{R}^n$, то

$$f_X(\bar{x}) = \frac{\partial^n F_X(\bar{x})}{\partial x_1 \partial x_2 \cdots \partial x_n}, \qquad F_X(\bar{x}) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \cdots \int_{-\infty}^{x_n} f_X(y_1, \ldots, y_n)\, dy_1 \cdots dy_n.$$

Дефиниция 11.6 (Независимост)

Нека $X = (X_1, X_2)$. Казваме, че $X_1 \perp\!\!\!\perp X_2$, ако

$$\forall (x_1, x_2) \in \mathbb{R}^2 : \quad F_X(x_1, x_2) = F_{X_1}(x_1) F_{X_2}(x_2)$$

$$\big(\text{т.е. } \mathbb{P}(X_1 < x_1, X_2 < x_2) = \mathbb{P}(X_1 < x_1)\mathbb{P}(X_2 < x_2)\big),$$

еквивалентно на $f_X(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2)$ - съвместната плътност се разпада на произведение от двете маргинални плътности.

Дефиниция 11.7 (Независимост в съвкупност)

Нека $X = (X_1, \ldots, X_n)$ има съвместна плътност f_X. Казваме, че $X_1, \ldots, X_n$ са **независими в съвкупност**, ако за всяко $\bar{x} = (x_1, \ldots, x_n) \in \mathbb{R}^n$:

$$f_X(x_1, \ldots, x_n) = \prod_{j=1}^{n} f_{X_j}(x_j).$$

11.2 Очакване за случаен вектор

Смяна на променливите за очакване (много измерения)

Нека X е вектор от случайни величини със съвместна плътност f_X и $g : \mathbb{R}^n \to \mathbb{R}$. Тогава $\mathbb{E}g(X) = \int_{\bar{x} \in \mathbb{R}^n} g(\bar{x})\, f_X(\bar{x})\, d\bar{x}$.

Теорема 11.1

Нека $X = (X_1, X_2)$ е непрекъснат случаен вектор със съвместна плътност f_X и нека $\mathbb{E}X_1, \mathbb{E}X_2$ съществуват. Тогава $\mathbb{E}(X_1 + X_2) = \mathbb{E}X_1 + \mathbb{E}X_2$. *(Тази формула важи за всякакви случайни величини - дискретни, непрекъснати, независими или не.)*

Доказателство

Нека $g(x_1, x_2) = x_1 + x_2$. Тогава

$$\begin{aligned}\mathbb{E}(X_1 + X_2) &= \iint (x_1 + x_2) f_X(x_1, x_2)\, dx_1 dx_2 \\ &= \int x_1 \Big(\int f_X(x_1, x_2)\, dx_2 \Big) dx_1 + \int x_2 \Big(\int f_X(x_1, x_2)\, dx_1 \Big) dx_2 \\ &= \int x_1 f_{X_1}(x_1)\, dx_1 + \int x_2 f_{X_2}(x_2)\, dx_2 = \mathbb{E}X_1 + \mathbb{E}X_2. \blacksquare\end{aligned}$$

Теорема 11.2

Нека $X = (X_1, X_2)$ е непрекъснат случаен вектор, $X_1 \perp\!\!\!\perp X_2$, и нека DX_1, DX_2 съществуват. Тогава $D(X_1 + X_2) = DX_1 + DX_2$.

Доказателство

$$\begin{aligned}D(X_1 + X_2) &= \mathbb{E}\big[(X_1 + X_2) - \mathbb{E}(X_1 + X_2)\big]^2 = \mathbb{E}\big[(X_1 - \mathbb{E}X_1) + (X_2 - \mathbb{E}X_2)\big]^2 \\ &= \mathbb{E}(X_1 - \mathbb{E}X_1)^2 + \mathbb{E}(X_2 - \mathbb{E}X_2)^2 + 2\,\mathbb{E}(X_1 - \mathbb{E}X_1)(X_2 - \mathbb{E}X_2) \\ &= DX_1 + DX_2 + 2\,\mathbb{E}(X_1 - \mathbb{E}X_1)(X_2 - \mathbb{E}X_2).\end{aligned}$$

Остава да покажем, че последният член е нула. Понеже $X_1 \perp\!\!\!\perp X_2$, съвместната плътност се разпада: $f_X(x_1, x_2) = f_{X_1}(x_1) f_{X_2}(x_2)$. Тогава

$$\begin{aligned}\mathbb{E}(X_1 - \mathbb{E}X_1)(X_2 - \mathbb{E}X_2) &= \iint (x_1 - \mathbb{E}X_1)(x_2 - \mathbb{E}X_2) f_{X_1}(x_1) f_{X_2}(x_2)\, dx_1 dx_2 \\ &= \Big(\int (x_1 - \mathbb{E}X_1) f_{X_1}(x_1)\, dx_1 \Big) \Big(\int (x_2 - \mathbb{E}X_2) f_{X_2}(x_2)\, dx_2 \Big),\end{aligned}$$

а всеки от двата множителя е нула: $\int (x_2 - \mathbb{E}X_2) f_{X_2}(x_2)\, dx_2 = \int x_2 f_{X_2}(x_2) dx_2 - \mathbb{E}X_2 \int f_{X_2}(x_2) dx_2 = \mathbb{E}X_2 - \mathbb{E}X_2 \cdot 1 = 0$ (аналогично за първия множител). Следователно $D(X_1 + X_2) = DX_1 + DX_2$. $\blacksquare$

Теорема 11.3

Нека $X = (X_1, X_2)$ е непрекъснат случаен вектор, $X_1 \perp\!\!\!\perp X_2$, и $\mathbb{E}X_1, \mathbb{E}X_2$ съществуват. Тогава $\mathbb{E}X_1 X_2 = \mathbb{E}X_1 \cdot \mathbb{E}X_2$.

Доказателство

$$\begin{aligned}\mathbb{E}X_1 X_2 &= \iint x_1 x_2\, f_X(x_1, x_2)\, dx_1 dx_2 \overset{X_1 \perp\!\!\!\perp X_2}{=} \iint x_1 x_2\, f_{X_1}(x_1) f_{X_2}(x_2)\, dx_1 dx_2 \\ &= \Big(\int x_1 f_{X_1}(x_1)\, dx_1 \Big) \Big(\int x_2 f_{X_2}(x_2)\, dx_2 \Big) = \mathbb{E}X_1 \cdot \mathbb{E}X_2. \blacksquare\end{aligned}$$

11.3 Смяна на променливите (многомерна)

Теорема 11.4

Нека $X = (X_1, X_2)$ е случаен вектор със съвместна плътност f_X и носител $D_{f_X} \subseteq \mathbb{R}^2$, и нека $g : D_{f_X} \to \mathbb{R}^2$, $Y = g(X) = (g_1(X_1, X_2), g_2(X_1, X_2))$, е биективна. Нека $h = g^{-1}$, $X = h(Y) = (h_1(Y_1, Y_2), h_2(Y_1, Y_2))$, като g и h са непрекъснати и диференцируеми в D_{f_X} и $g(D_{f_X})$ съответно. Ако Якобианът

$$J(y) = \begin{pmatrix} \dfrac{\partial h_1}{\partial y_1} & \dfrac{\partial h_1}{\partial y_2} \\ \dfrac{\partial h_2}{\partial y_1} & \dfrac{\partial h_2}{\partial y_2} \end{pmatrix}$$

удовлетворява $\det J(y) \neq 0$ за всяко $y \in g(D_{f_X})$, то Y е непрекъснат случаен вектор с

$$f_Y(y_1, y_2) = f_X\big(h_1(y_1, y_2), h_2(y_1, y_2)\big) \cdot \big|\det J(y)\big|.$$

Доказателство

Нека $A \subseteq g(D_{f_X})$. Тогава

$$\mathbb{P}(Y \in A) = \mathbb{P}\big(g(X) \in A\big) = \mathbb{P}\big(X \in h(A)\big) = \int_{x \in h(A)} f_X(x)\, dx.$$

Извършваме смяната на променливите $x = h(y)$ (с якобиан $J(y)$):

$$\int_{x \in h(A)} f_X(x)\, dx = \int_{y \in A} f_X\big(h(y)\big) \cdot |\det J(y)|\, dy,$$

откъдето, по дефиниция на плътност, $f_Y(y) = f_X(h(y)) \cdot |\det J(y)|$. ■

Теорема 11.5 (сума на независими нормални случайни величини)

Нека $X_i \sim N(\mu_i, \sigma_i^2)$, $1 \leq i \leq n$, са независими в съвкупност. Тогава

$$Y = \sum_{i=1}^{n} X_i \sim N\Big(\sum_{i=1}^{n} \mu_i,\ \sum_{i=1}^{n} \sigma_i^2\Big).$$

Доказателство

Достатъчно е да докажем твърдението за $n = 2$ - общият случай следва по индукция (сумираме последователно). Записваме $X_1 = \mu_1 + \sigma_1 V_1$, $X_2 = \mu_2 + \sigma_2 V_2$, където $V_1, V_2 \sim N(0,1)$ независими (Тема 10). Тогава

$$X_1 + X_2 = (\mu_1 + \mu_2) + \underbrace{\sigma_1 V_1}_{=:W_1 \sim N(0,\sigma_1^2)} + \underbrace{\sigma_2 V_2}_{=:W_2 \sim N(0,\sigma_2^2)},$$

и е достатъчно да докажем, че $W_1 + W_2 \sim N(0, \sigma_1^2 + \sigma_2^2)$ за независими $W_1 \sim N(0,\sigma_1^2)$, $W_2 \sim N(0,\sigma_2^2)$ (тогава $Y = (\mu_1+\mu_2) + (W_1+W_2) \sim N(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$ по теоремата за линейно преобразуване на нормално разпределение).
Правим трансформацията $W = X_2$, $Z = X_1 + X_2$ (т.е. $X_1 = Z - W$, $X_2 = W$), с Якобиан $|J|(z,w) = \left|\det \begin{pmatrix} \partial X_1/\partial Z & \partial X_1/\partial W \\ \partial X_2/\partial Z & \partial X_2/\partial W \end{pmatrix}\right| = \left|\det \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}\right| = 1$. Понеже $X_1 \perp\!\!\!\perp X_2$, съвместната им плътност е $f_{X_1,X_2}(x_1,x_2) = \dfrac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{x_1^2}{2\sigma_1^2} - \frac{x_2^2}{2\sigma_2^2}}$, следователно

$$f_{Z,W}(z,w) = \frac{1}{2\pi\sigma_1\sigma_2}\, e^{-\frac{(z-w)^2}{2\sigma_1^2} - \frac{w^2}{2\sigma_2^2}}.$$

Търсим маргиналната плътност на $Z = W_1 + W_2$, интегрирайки по w. Разгръщаме показателя (групирайки по степени на w):

$$-\frac{(z-w)^2}{2\sigma_1^2} - \frac{w^2}{2\sigma_2^2} = -\frac{w^2}{2\sigma_1^2} - \frac{w^2}{2\sigma_2^2} + \frac{wz}{\sigma_1^2} - \frac{z^2}{2\sigma_1^2}.$$

Полагаме $\sigma^2 := \sigma_1^2 + \sigma_2^2$, така че коефициентът пред w^2 е $-\frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2} = -\frac{\sigma^2}{2\sigma_1^2\sigma_2^2}$, и допълваме до точен квадрат по общата формула $-Aw^2 + Bw + C = -A\big(w - \frac{B}{2A}\big)^2 + \frac{B^2}{4A} + C$ с $A = \frac{\sigma^2}{2\sigma_1^2\sigma_2^2}$, $B = \frac{z}{\sigma_1^2}$, $C = -\frac{z^2}{2\sigma_1^2}$:

$$\frac{B}{2A} = \frac{z}{\sigma_1^2} \cdot \frac{\sigma_1^2\sigma_2^2}{\sigma^2} = \frac{\sigma_2^2 z}{\sigma^2}, \qquad \frac{B^2}{4A} + C = \frac{z^2\sigma_2^2}{2\sigma_1^2\sigma^2} - \frac{z^2}{2\sigma_1^2} = \frac{z^2}{2\sigma_1^2} \cdot \frac{\sigma_2^2 - \sigma^2}{\sigma^2} = -\frac{z^2}{2\sigma^2}$$

(последното — понеже $\sigma_2^2 - \sigma^2 = -\sigma_1^2$). Следователно показателят се разпада точно на

$$-\frac{(z-w)^2}{2\sigma_1^2} - \frac{w^2}{2\sigma_2^2} = -\frac{\sigma^2}{2\sigma_1^2\sigma_2^2}\Big(w - \frac{\sigma_2^2}{\sigma^2} z\Big)^2 - \frac{z^2}{2\sigma^2}.$$

Извършваме смяната $v = \dfrac{\sigma}{\sigma_1\sigma_2}\Big(w - \dfrac{\sigma_2^2}{\sigma^2} z\Big)$ (т.е. $dw = \dfrac{\sigma_1\sigma_2}{\sigma}\, dv$), която превръща експонентата в $-\frac{1}{2}v^2$:

$$f_Z(z) = \frac{1}{2\pi\sigma_1\sigma_2}\, e^{-\frac{z^2}{2\sigma^2}} \cdot \underbrace{\int_{-\infty}^{\infty} e^{-\frac{1}{2}v^2}\, \frac{\sigma_1\sigma_2}{\sigma}\, dv}_{= \frac{\sigma_1\sigma_2}{\sigma}\sqrt{2\pi} \text{ (нормировъчен интеграл на Гаус)}}$$

$$= \frac{1}{2\pi\sigma_1\sigma_2} \cdot \frac{\sigma_1\sigma_2}{\sigma}\sqrt{2\pi}\, e^{-\frac{z^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}\,\sigma}\, e^{-\frac{z^2}{2\sigma^2}} \sim N(0, \sigma_1^2 + \sigma_2^2). \blacksquare$$

11.4 Гама разпределение

Дефиниция 11.8 (Гама функция и Гама разпределение)

Нека $\alpha > 0$. **(Ойлеровата) Гама функция** е

$$\Gamma(\alpha) := \int_0^\infty x^{\alpha-1} e^{-x}\, dx.$$

Известни свойства: $\Gamma(1) = 1$, $\Gamma(n+1) = n!$ за $n \in \mathbb{N}$, и рекурентната формула $\Gamma(\alpha+1) = \alpha\,\Gamma(\alpha)$ за $\alpha > 0$. Нека $\alpha > 0$, $\beta > 0$. Казваме, че $X \sim \Gamma(\alpha, \beta)$ (**Гама разпределение**), ако

$$f_X(x) = \begin{cases} \dfrac{\beta^\alpha}{\Gamma(\alpha)}\, x^{\alpha-1} e^{-\beta x}, & x > 0 \\ 0, & \text{иначе} \end{cases}.$$

Следствие 11.1 (частни случаи)

При $\alpha = \beta = 1$: $X \sim Exp(1)$. При $\alpha = 1$, $\beta > 0$ произволно: $f_X(x) = \dfrac{\beta}{\Gamma(1)} e^{-\beta x} = \beta e^{-\beta x}$ за $x > 0$, т.е. $\Gamma(1, \beta) = Exp(\beta)$.

Теорема 11.6

Нека $X_i \sim \Gamma(\alpha_i, \beta)$, $i = 1, \ldots, n$ (*еднакво* β), независими в съвкупност. Тогава

$$Y = \sum_{j=1}^{n} X_j \sim \Gamma(\alpha_1 + \cdots + \alpha_n,\ \beta).$$

Доказателство

Достатъчно е да докажем твърдението за $n = 2$ (общият случай следва по индукция). Нека $Y_1 = X_1 + X_2$, $Y_2 = X_2$ (т.е. $X_1 = Y_1 - Y_2$, $X_2 = Y_2$), с Якобиан $|J| = \det \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix} = 1$. Понеже $X_1 \perp\!\!\!\perp X_2$:

$$f_X(x_1, x_2) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\beta(x_1+x_2)} x_1^{\alpha_1-1} x_2^{\alpha_2-1},$$

и след смяната на променливите:

$$f_{Y_1,Y_2}(y_1, y_2) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\beta y_1} (y_1 - y_2)^{\alpha_1-1} y_2^{\alpha_2-1}, \qquad 0 < y_2 < y_1.$$

Интегрираме по y_2, за да получим маргиналната плътност на $Y_1 = X_1 + X_2$:

$$f_{Y_1}(y_1) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\beta y_1} \int_0^{y_1} (y_1 - y_2)^{\alpha_1-1} y_2^{\alpha_2-1}\, dy_2.$$

Полагаме $y_2 = v y_1$ (т.е. $v \in (0, 1)$), $dy_2 = y_1\, dv$:

$$\int_0^{y_1} (y_1 - y_2)^{\alpha_1-1} y_2^{\alpha_2-1}\, dy_2 = y_1^{\alpha_1+\alpha_2-1} \underbrace{\int_0^1 (1 - v)^{\alpha_1-1} v^{\alpha_2-1}\, dv}_{= B(\alpha_1,\alpha_2) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1+\alpha_2)}}$$

(последният интеграл е класическата Ойлерова Бета-функция, за която е известна връзката с Гама функцията). Заместваме:

$$f_{Y_1}(y_1) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\beta y_1} y_1^{\alpha_1+\alpha_2-1} \cdot \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1+\alpha_2)} = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1+\alpha_2)} y_1^{\alpha_1+\alpha_2-1} e^{-\beta y_1},$$

т.е. $Y_1 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$. ■

Следствие 11.2

Ако $X_1, \ldots, X_n$ са независими в съвкупност, еднакво разпределени $X_i \sim Exp(\lambda)$ (т.е. $X_i \sim \Gamma(1, \lambda)$), то $\sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$.

Теорема 11.7

Ако $X \sim \Gamma(\alpha, \beta)$, то $\mathbb{E}X = \frac{\alpha}{\beta}$ и $DX = \frac{\alpha}{\beta^2}$.

Доказателство

Извършваме смяна на променливата $y = \beta x$ ($x = y/\beta$, $dx = dy/\beta$), избрана така, че да разпознаем плътността на $\Gamma(\alpha{+}1, \beta)$ (респ. $\Gamma(\alpha{+}2, \beta)$) под интеграла:

$$\mathbb{E}X = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x \cdot x^{\alpha-1} e^{-\beta x}\, dx = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^\alpha e^{-\beta x}\, dx.$$

Разпознаваме под интеграла плътността на $\Gamma(\alpha{+}1, \beta)$ (с изключение на нормиращата константа), т.е. $\int_0^\infty x^\alpha e^{-\beta x}\, dx = \dfrac{\Gamma(\alpha+1)}{\beta^{\alpha+1}}$ (понеже $\frac{\beta^{\alpha+1}}{\Gamma(\alpha+1)} x^\alpha e^{-\beta x}$ е плътност и интегрира до 1). Следователно

$$\mathbb{E}X = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+1)}{\beta^{\alpha+1}} = \frac{\Gamma(\alpha+1)}{\beta\,\Gamma(\alpha)} = \frac{\alpha\,\Gamma(\alpha)}{\beta\,\Gamma(\alpha)} = \frac{\alpha}{\beta}.$$

Аналогично, разпознавайки плътността на $\Gamma(\alpha{+}2, \beta)$:

$$\mathbb{E}X^2 = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha+1} e^{-\beta x}\, dx = \frac{\Gamma(\alpha+2)}{\beta^2\,\Gamma(\alpha)} = \frac{(\alpha+1)\alpha\,\Gamma(\alpha)}{\beta^2\,\Gamma(\alpha)} = \frac{\alpha^2+\alpha}{\beta^2}$$

(използвахме $\Gamma(\alpha{+}2) = (\alpha{+}1)\Gamma(\alpha{+}1) = (\alpha{+}1)\alpha\,\Gamma(\alpha)$). Следователно

$$DX = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \frac{\alpha^2+\alpha}{\beta^2} - \frac{\alpha^2}{\beta^2} = \frac{\alpha}{\beta^2}. \blacksquare$$

11.5 χ^2 разпределение

Дефиниция 11.9 (χ^2 разпределение)

Хи-квадрат разпределението с n *степени на свобода* е частен случай на Гама разпределението: $X \sim \chi^2(n)$, ако $X \sim \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$, т.е.

$$f_X(x) = \begin{cases} \dfrac{(1/2)^{n/2}}{\Gamma(n/2)}\, x^{n/2-1} e^{-x/2}, & x > 0 \\ 0, & \text{иначе} \end{cases}.$$

От формулите за Гама разпределение: $\mathbb{E}X = \dfrac{n/2}{1/2} = n$, $DX = \dfrac{n/2}{(1/2)^2} = 2n$.

Теорема 11.8

Нека $X_1, \ldots, X_n \sim N(0,1)$ са независими в съвкупност. Тогава

$$Y = \sum_{i=1}^n X_i^2 \sim \chi^2(n).$$

Доказателство

Ако докажем, че $X_1^2 \sim \chi^2(1) = \Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$, то по теоремата за сумата на независими Гама-разпределени величини (с еднакво $\beta = \frac{1}{2}$): $\sum_{i=1}^n X_i^2 \sim \Gamma\left(\frac{n}{2}, \frac{1}{2}\right) = \chi^2(n)$.
Нека $H = X_1^2$ (H не е монотонна функция на X_1 - параболата не е инжективна - затова минаваме през функцията на разпределение директно, вместо през общата теорема за смяна на променливите). За $h > 0$:

$$\mathbb{P}(H \le h) = \mathbb{P}(X_1^2 \le h) = \mathbb{P}(-\sqrt{h} \le X_1 \le \sqrt{h}) = 2\,\mathbb{P}(0 \le X_1 \le \sqrt{h}) = \frac{2}{\sqrt{2\pi}} \int_0^{\sqrt{h}} e^{-y^2/2}\, dy.$$

Диференцираме директно по h (правило на Лайбниц за диференциране на интеграл с граница, зависеща от параметъра), за да получим плътността $f_H(h) = \frac{d}{dh}\mathbb{P}(H \le h)$:

$$f_H(h) = \frac{2}{\sqrt{2\pi}} \cdot e^{-h/2} \cdot \frac{d}{dh}\sqrt{h} = \frac{2}{\sqrt{2\pi}} \cdot e^{-h/2} \cdot \frac{1}{2\sqrt{h}} = \frac{1}{\sqrt{2\pi}}\, h^{-1/2} e^{-h/2}.$$

Понеже $\Gamma(\frac{1}{2}) = \sqrt{\pi}$, плътността на $\Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$ е точно $\frac{(1/2)^{1/2}}{\Gamma(1/2)} h^{-1/2} e^{-h/2} = \frac{1}{\sqrt{2}\sqrt{\pi}} h^{-1/2} e^{-h/2} = \frac{1}{\sqrt{2\pi}} h^{-1/2} e^{-h/2}$, което съвпада с $f_H(h)$. Следователно $H = X_1^2 \sim \Gamma\left(\frac{1}{2}, \frac{1}{2}\right) = \chi^2(1)$. ■

11.6 t-разпределение (на Стюдънт)

Дефиниция 11.10 (t-разпределение)

Нека $n \ge 1$. Казваме, че $X \sim t(n)$ с n степени на свобода, ако

$$X = \frac{Z}{\sqrt{Y/n}}, \qquad Z \perp\!\!\!\perp Y, \quad Z \sim N(0,1), \quad Y \sim \chi^2(n).$$

Тема 12

Сходимост и закони за големите числа

Забележка

Това е сред най-важните теми в курса - сходимостта на случайни величини и законите за големите числа стоят в основата на цялата математическа статистика (оценки, доверителни интервали, гранични теореми).

12.1 Видове сходимост

Постановка

Нека $(X_n)_{n=1}^{\infty}$ е редица от случайни величини във вероятностно пространство $V = (\Omega, \mathcal{A}, \mathbb{P})$.

Дефиниция 12.1 (Почти сигурна сходимост, п.с.)

Нека $L_X = \{\omega \in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}$. Казваме, че $X_n \xrightarrow[n\to\infty]{\text{п.с.}} X$, ако $\mathbb{P}(L_X) = 1$ („X_n клони почти сигурно към X“). Възможно е да съществуват изходи ω, за които границата не е изпълнена, но множеството от такива изходи да има вероятност нула.

Дефиниция 12.2 (Сходимост по вероятност)

Нека $A_{n,\varepsilon} = \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}$. Казваме, че $X_n \xrightarrow[n\to\infty]{\mathbb{P}} X$, ако $\forall \varepsilon > 0$: $\lim_{n\to\infty} \mathbb{P}(A_{n,\varepsilon}) = 0$.

Дефиниция 12.3 (Сходимост по разпределение)

Нека $C_{F_X} = \{x \in \mathbb{R} : F_X$ е непрекъсната в $x\}$ - множеството от точки на непрекъснатост на функцията на разпределение F_X. Казваме, че $X_n \xrightarrow[n\to\infty]{d} X$, ако за всяко $x \in C_{F_X}$: $\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$.

Теорема 12.1

Нека $(X_n)_{n=1}^{\infty}$ е редица от случайни величини.

а) Ако $X_n \xrightarrow{\text{п.с.}} X$, то $X_n \xrightarrow{\mathbb{P}} X$.

б) Ако $X_n \xrightarrow{\mathbb{P}} X$, то $X_n \xrightarrow{d} X$.

(Т.е. п.с. сходимостта е най-силна, следвана от сходимостта по вероятност, а сходимостта по разпределение е най-слабата.)

Доказателство

а) Нека $X_n \xrightarrow{\text{п.с.}} X$, т.е. $\mathbb{P}(L) = 1$ за $L = \{\omega : \lim_n X_n(\omega) = X(\omega)\}$. Твърдим, че

$$L = \bigcap_{r=1}^{\infty} \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} \Big\{\omega \in \Omega : |X_k(\omega) - X(\omega)| \le \frac{1}{r}\Big\}.$$

(⊆) Нека $\tilde\omega \in L$. За всяко $r \ge 1$ (с $\varepsilon = 1/r$), понеже $X_n(\tilde\omega) \to X(\tilde\omega)$, съществува n_r такова, че $|X_n(\tilde\omega) - X(\tilde\omega)| < \frac{1}{r}$ за $n \ge n_r$, т.е. $\tilde\omega \in \bigcap_{k=n_r}^{\infty}\{|X_k - X| \le \frac{1}{r}\} \subseteq \bigcup_n \bigcap_{k=n}^{\infty}\{\dots\}$, и това важи за всяко r, следователно $\tilde\omega$ принадлежи на дясната страна.
(⊇) Нека $\tilde\omega$ принадлежи на дясната страна. За всяко $r \ge 1$ съществува n_r, такова че $\tilde\omega \in \bigcap_{k=n_r}^{\infty}\{|X_k - X| \le \frac{1}{r}\}$, т.е. $|X_k(\tilde\omega) - X(\tilde\omega)| \le \frac{1}{r}$ за всяко $k \ge n_r$. Това означава $\lim_{k\to\infty} X_k(\tilde\omega) = X(\tilde\omega)$ (по дефиниция на граница), т.е. $\tilde\omega \in L$.
От равенството и закона на Де Морган:

$$L^c = \bigcup_{r=1}^{\infty} \bigcap_{n=1}^{\infty} \underbrace{\bigcup_{k=n}^{\infty} A_{k,\frac{1}{r}}}_{=:B_{n,r}}.$$

Понеже $\mathbb{P}(L) = 1$, имаме $\mathbb{P}(L^c) = 0$, следователно $\mathbb{P}\big(\bigcap_n B_{n,r}\big) = 0$ за всяко $r \ge 1$ (обединение на неотрицателни членове е нула точно когато всеки е нула). Нека $r \ge 1$ е фиксирано. Редицата $(B_{n,r})_{n\ge1}$ намалява по n (защото обединяваме над все по-малко индекси), следователно по непрекъснатостта на вероятността отгоре (Тема 2):

$$0 = \mathbb{P}\Big(\bigcap_{n=1}^{\infty} B_{n,r}\Big) = \lim_{n\to\infty} \mathbb{P}(B_{n,r}).$$

Понеже $B_{n,r} = \bigcup_{k=n}^{\infty} A_{k,1/r} \supseteq A_{n,1/r}$, имаме $\mathbb{P}(A_{n,1/r}) \le \mathbb{P}(B_{n,r}) \to 0$, т.е. $\lim_{n\to\infty}\mathbb{P}(A_{n,1/r}) = 0$ за всяко $r \ge 1$ - а това означава точно $X_n \xrightarrow{\mathbb{P}} X$ (произволно $\varepsilon > 0$ може да бъде „уловено“ от достатъчно голямо r с $1/r < \varepsilon$).
б) Нека $X_n \xrightarrow{\mathbb{P}} X$, т.е. $\lim_n \mathbb{P}(A_{n,\varepsilon}) = 0$ за всяко $\varepsilon > 0$. Нека $x \in C_{F_X}$ е фиксирано и нека $\varepsilon > 0$. Забелязваме двете включвания:

$$\{X_n < x\} \subseteq A_{n,\varepsilon} \cup \{X < x + \varepsilon\}, \qquad \{X < x - \varepsilon\} \cap A_{n,\varepsilon}^c \subseteq \{X_n < x\}$$

(геометрично: ако $X_n < x$ и $|X_n - X| \le \varepsilon$, то $X < x + \varepsilon$; а ако $X < x - \varepsilon$ и $|X_n - X| \le \varepsilon$, то $X_n < x$). От тези включвания следва:

$$\mathbb{P}(X < x - \varepsilon) - \mathbb{P}(A_{n,\varepsilon}) \le \mathbb{P}(X_n < x) \le \mathbb{P}(X < x + \varepsilon) + \mathbb{P}(A_{n,\varepsilon}),$$

т.е. $F_X(x-\varepsilon) - \mathbb{P}(A_{n,\varepsilon}) \le \mathbb{P}(X_n < x) \le F_X(x+\varepsilon) + \mathbb{P}(A_{n,\varepsilon})$. Взимаме $\liminf/\limsup$ по $n \to \infty$ (при което $\mathbb{P}(A_{n,\varepsilon}) \to 0$):

$$F_X(x-\varepsilon) \le \liminf_{n\to\infty} \mathbb{P}(X_n < x) \le \limsup_{n\to\infty} \mathbb{P}(X_n < x) \le F_X(x+\varepsilon).$$

Понеже $x \in C_{F_X}$ (точка на непрекъснатост), $\lim_{\varepsilon\to0} F_X(x-\varepsilon) = \lim_{\varepsilon\to0} F_X(x+\varepsilon) = F_X(x)$, следователно при $\varepsilon \to 0$ границите отляво и отдясно се сближават до $F_X(x)$, откъдето $\lim_{n\to\infty}\mathbb{P}(X_n < x) = F_X(x)$, т.е. $X_n \xrightarrow{d} X$. ■

Теорема 12.2

Нека $(X_n)_{n=1}^{\infty}$ е редица от случайни величини в едно вероятностно пространство. Ако $X_n \xrightarrow{d} c$, то $X_n \xrightarrow{\mathbb{P}} c$, където c е константа.

Доказателство

$F_c(x) = I_{\{x>c\}}$, т.е. $C_{F_c} = \mathbb{R} \setminus \{c\}$. Фиксираме $\varepsilon > 0$ и разписваме:

$$\begin{aligned}\mathbb{P}(|X_n - c| > \varepsilon) &= \mathbb{P}(X_n > c+\varepsilon) + \mathbb{P}(X_n < c-\varepsilon) \\ &= 1 - \mathbb{P}(X_n \le c+\varepsilon) + F_{X_n}(c-\varepsilon) \\ &= 1 - F_{X_n}(c+\varepsilon) - \mathbb{P}(X_n = c+\varepsilon) + F_{X_n}(c-\varepsilon).\end{aligned}$$

Понеже $c+\varepsilon, c-\varepsilon \in C_{F_c}$, от $X_n \xrightarrow{d} c$ следва $F_{X_n}(c+\varepsilon) \to F_c(c+\varepsilon) = 1$ и $F_{X_n}(c-\varepsilon) \to F_c(c-\varepsilon) = 0$ при $n \to \infty$. Следователно

$$0 \le \lim_{n\to\infty} \mathbb{P}(|X_n - c| > \varepsilon) = \underbrace{1 - 1 - 0}_{=0} - \lim_{n\to\infty} \mathbb{P}(X_n = c+\varepsilon) = -\lim_{n\to\infty} \mathbb{P}(X_n = c+\varepsilon) \le 0$$

(последното неравенство, защото вероятности са неотрицателни), т.е. границата е едновременно ≥ 0 и ≤ 0, откъдето $\lim_{n\to\infty} \mathbb{P}(|X_n - c| > \varepsilon) = 0$. ■

12.2 Неравенство на Чебишов (обобщение)

Теорема 12.3 (на Чебишов, чрез индикатор)

Нека X е случайна величина с $DX < \infty$. Тогава за всяко $a > 0$:

$$\mathbb{P}(|X - \mathbb{E}X| > a) \le \frac{DX}{a^2}.$$

Доказателство

Нека $Y = X - \mathbb{E}X$. Тогава $\mathbb{P}(|Y| > a) = \mathbb{E}I_{\{|Y|>a\}}$, и разбивайки по допълващи се събития:

$$\begin{aligned}DX = \mathbb{E}Y^2 &= \mathbb{E}\big[Y^2 \cdot 1\big] = \mathbb{E}\big[Y^2\big(I_{\{|Y|\le a\}} + I_{\{|Y|>a\}}\big)\big] \\ &\ge \mathbb{E}\big[Y^2 I_{\{|Y|>a\}}\big] \ge a^2\,\mathbb{E}I_{\{|Y|>a\}} = a^2\,\mathbb{P}(|Y| > a)\end{aligned}$$

(изпуснахме неотрицателния член с $I_{\{|Y|\le a\}}$, а на събитието $\{|Y| > a\}$ имаме $Y^2 > a^2$). Следователно $\mathbb{P}(|X - \mathbb{E}X| > a) \le DX/a^2$. ■

Следствие 12.1 (обобщение за по-висок момент)

Нека X е случайна величина и $n \ge 1$. Тогава за всяко $a > 0$:

$$\mathbb{P}(|X - \mathbb{E}X| > a) \le \frac{\mathbb{E}|X - \mathbb{E}X|^n}{a^n}$$

(доказва се по абсолютно същата схема, заместваики квадрат с n-та степен: на $\{|Y| > a\}$ имаме $|Y|^n > a^n$).

12.3 Закони за големите числа

Дефиниция 12.4 (Независими еднакво разпределени - i.i.d.)

Редицата $(X_i)_{i=1}^n$ (или $(X_i)_{i=1}^\infty$) е от **независими еднакво разпределени** случайни величини (съкратено **i.i.d.**), ако $X_1 \overset{d}{=} X_i$ (т.е. $F_{X_1} = F_{X_i}$) за всяко $i \geq 2$, и (X_i) са независими в съвкупност (т.е. за всяко $n \geq 1$ и всеки избор на индекси $(i_1, \ldots, i_n)$, величините $(X_{i_1}, \ldots, X_{i_n})$ са независими в съвкупност).

Дефиниция 12.5 (Слаб закон за големите числа, СЗГЧ)

Нека $(X_i)_{i=1}^\infty$ е редица от случайни величини с очаквания $(\mathbb{E}X_i)_{i=1}^\infty$. Казваме, че за редицата е в сила **слабият закон за големите числа**, ако

$$\frac{\sum_{i=1}^n (X_i - \mathbb{E}X_i)}{n} \xrightarrow[n\to\infty]{\mathbb{P}} 0.$$

Теорема 12.4 (СЗГЧ)

Нека $(X_i)_{i=1}^\infty$ е i.i.d. редица с $\mathbb{E}X_1$ и $DX_1 < \infty$. Тогава

$$\frac{\sum_{i=1}^n X_i}{n} \xrightarrow[n\to\infty]{\mathbb{P}} \mathbb{E}X_1.$$

Доказателство

Фиксираме $\varepsilon > 0$. Понеже (X_i) са i.i.d., $D\big(\sum_{i=1}^n (X_i - \mathbb{E}X_i)\big) = \sum_{i=1}^n D(X_i - \mathbb{E}X_i) = \sum_{i=1}^n DX_i = n\,DX_1$ (адитивност на дисперсията за независими събираеми, Тема 5/9; изваждането на константа $\mathbb{E}X_i$ не променя дисперсията). По неравенството на Чебишов, приложено към $\sum_{i=1}^n (X_i - \mathbb{E}X_i)$:

$$\mathbb{P}\Big(\Big|\frac{\sum_{i=1}^n X_i}{n} - \mathbb{E}X_1\Big| > \varepsilon\Big) = \mathbb{P}\Big(\Big|\sum_{i=1}^n (X_i - \mathbb{E}X_i)\Big| > n\varepsilon\Big) \leq \frac{D\big(\sum_{i=1}^n (X_i - \mathbb{E}X_i)\big)}{\varepsilon^2 n^2}$$
$$= \frac{n\,DX_1}{\varepsilon^2 n^2} = \frac{DX_1}{n\varepsilon^2} \xrightarrow[n\to\infty]{} 0. \blacksquare$$

Дефиниция 12.6 (Усилен закон за големите числа, УЗГЧ)

Нека $(X_i)_{i=1}^\infty$ е редица от случайни величини с очаквания $(\mathbb{E}X_i)_{i=1}^\infty$. Казваме, че за редицата е в сила **усиленият закон за големите числа**, ако

$$\frac{\sum_{i=1}^n (X_i - \mathbb{E}X_i)}{n} \xrightarrow[n\to\infty]{\text{п.с.}} 0.$$

Теорема 12.5 (УЗГЧ)

Нека $(X_i)_{i=1}^\infty$ е i.i.d. редица с $\mathbb{E}|X_1| < \infty$. Тогава

$$\frac{\sum_{i=1}^n X_i}{n} \xrightarrow[n\to\infty]{\text{п.с.}} \mathbb{E}X_1.$$

Доказателство

(Доказваме при допълнителното техническо предположение $\mathbb{E}X_1^4 < \infty$, което опростява сметките.) Без ограничение на общността приемаме $\mathbb{E}X_1 = 0$ (иначе разглеждаме $X_i - \mathbb{E}X_i$). Полагаме $S_k = \sum_{i=1}^{k} X_i$. Целта е да докажем $\mathbb{P}(L) = 1$ за $L = \{\omega : S_n(\omega)/n \to 0\}$, т.е. $\mathbb{P}(L^c) = 0$. Аналогично на предната теорема,

$$L^c = \bigcup_{r=1}^{\infty} C_r, \qquad C_r = \bigcap_{n=1}^{\infty} B_{n,r}, \qquad B_{n,r} = \bigcup_{k=n}^{\infty} \Big\{ \Big| \frac{S_k}{k} \Big| > \frac{1}{r} \Big\}.$$

Достатъчно е да покажем $\mathbb{P}(C_r) = 0$ за всяко $r \geq 1$. Понеже $(B_{n,r})_{n \geq 1}$ намалява по n, $\mathbb{P}(C_r) = \lim_{n\to\infty} \mathbb{P}(B_{n,r})$. По субадитивност (Тема 2):

$$\mathbb{P}(B_{n,r}) \leq \sum_{k=n}^{\infty} \mathbb{P}\Big(\Big| \frac{S_k}{k} \Big| > \frac{1}{r} \Big).$$

Прилагаме обобщеното неравенство на Чебишов с $n = 4$-ти момент:

$$\mathbb{P}\Big(\Big| \frac{S_k}{k} \Big| > \frac{1}{r} \Big) \leq \frac{r^4}{k^4}\, \mathbb{E}S_k^4 = \frac{r^4}{k^4}\, \mathbb{E}\Big(\sum_{i=1}^{k} X_i \Big)^4.$$

Разгръщаме четвъртата степен:

$$\Big(\sum_{i=1}^{k} X_i \Big)^4 = \sum_{i=1}^{k} X_i^4 + 6 \sum_{i<j} X_i^2 X_j^2 + (\text{членове с нечетни степени}).$$

Понеже (X_i) са независими и $\mathbb{E}X_i = 0$, всеки член с нечетна степен на кой да е от множителите (напр. $X_i^3 X_j$) се анулира при вземане на очакване: $\mathbb{E}[X_i^3 X_j] = \mathbb{E}X_i^3 \cdot \mathbb{E}X_j = \mathbb{E}X_i^3 \cdot 0 = 0$. Остават само членовете от четни степени:

$$\mathbb{E}\Big(\sum_{i=1}^{k} X_i \Big)^4 = k\, \mathbb{E}X_1^4 + 6 \binom{k}{2} \big(\mathbb{E}X_1^2 \big)^2 \leq C \cdot k^2$$

за подходяща константа $C > 0$ (защото първият член расте линейно по k, а вторият - квадратично, откъдето изразът е от порядъка на k^2 за големи k). Заместваме:

$$\mathbb{P}\Big(\Big| \frac{S_k}{k} \Big| > \frac{1}{r} \Big) \leq \frac{r^4}{k^4} \cdot Ck^2 = \frac{Cr^4}{k^2}.$$

Следователно

$$\mathbb{P}(B_{n,r}) \leq \sum_{k=n}^{\infty} \frac{Cr^4}{k^2} = Cr^4 \sum_{k=n}^{\infty} \frac{1}{k^2} \xrightarrow[n\to\infty]{} 0$$

(опашка на сходящ ред $\sum 1/k^2$ клони към нула). Следователно $\mathbb{P}(C_r) = \lim_n \mathbb{P}(B_{n,r}) = 0$ за всяко $r \geq 1$, и по субадитивност $\mathbb{P}(L^c) = \mathbb{P}\big(\bigcup_r C_r \big) \leq \sum_r \mathbb{P}(C_r) = 0$, т.е. $\mathbb{P}(L) = 1$. ■

Обобщение при $\mathbb{E}X_1 = \mathbb{E}X_i$

Независимост и общо (крайно) очакване **сами по себе си не са достатъчни** за СЗГЧ/УЗГЧ при нееднакво разпределени величини - нужно е допълнително условие върху дисперсиите. Едно просто достатъчно условие е *равномерна ограниченост на дисперсиите*: съществува $M > 0$, такова че $DX_i \leq M$ за всяко i. Тогава $\sum_{i=1}^n (X_i - \mathbb{E}X_i)/n = \sum_{i=1}^n X_i/n - \mathbb{E}X_1$, и заключението на СЗГЧ остава в сила:

$$\frac{\sum_{i=1}^n X_i}{n} \xrightarrow{\mathbb{P}} \mathbb{E}X_1,$$

защото по независимост и равномерна ограниченост, $D\big(\sum_{i=1}^n (X_i - \mathbb{E}X_i)\big) = \sum_{i=1}^n DX_i \leq nM$, и неравенството на Чебишов дава (аналогично на доказателството по-горе) $\mathbb{P}\big(|\sum_{i=1}^n (X_i - \mathbb{E}X_i)/n| > \varepsilon\big) \leq M/(n\varepsilon^2) \to 0$. За УЗГЧ равномерната ограниченост на дисперсиите също е достатъчна (чрез по-финото условие на Колмогоров $\sum_i DX_i/i^2 < \infty$), но доказателството излиза извън рамките на този курс.

Тема 13

Централна гранична теорема

13.1 Функции на моментите

Дефиниция 13.1 (Функция на моментите)

Нека X е случайна величина, за която $\mathbb{E}e^{tX}$ съществува за $t \in (-a, a)$, $a > 0$. Тогава

$$M_X(t) := \mathbb{E}e^{tX}, \qquad t \in (-a, a),$$

се нарича **функция на моментите** на X. Ако X е дискретна: $M_X(t) = \sum_i \mathbb{P}(X = x_i)\, e^{tx_i}$; ако X е непрекъсната: $M_X(t) = \int_{\mathbb{R}} f_X(x)\, e^{tx}\, dx$.

Дефиниция 13.2 (k-ти момент, абсолютен и централен момент)

Нека X е случайна величина и $k \geq 1$.

- Ако $\mathbb{E}X^k$ съществува, той се нарича **k-ти момент** на X.
- Ако $\mathbb{E}|X|^k$ съществува, той се нарича **k-ти абсолютен момент**.
- Ако $\mathbb{E}|X - \mathbb{E}X|^k$ съществува, той се нарича **k-ти (абсолютен) централен момент**; при $k = 2$ това е точно дисперсията: $DX = \mathbb{E}(X - \mathbb{E}X)^2$.

Свойства 13.1 (на функцията на моментите)

Нека X, Y са случайни величини, за които M_X, M_Y съществуват в околност на нулата.

а) $M_X(0) = 1$.

б) $M_X(t) = \sum_{k=0}^{\infty} \frac{t^k}{k!}\, \mathbb{E}X^k$ (за t в радиуса на сходимост).

в) $M_X^{(k)}(0) = \mathbb{E}X^k$ (k-тата производна в нулата е k-тият момент).

г) Ако $X \perp\!\!\!\perp Y$, то $M_{X+Y}(t) = M_X(t) \cdot M_Y(t)$.

д) Ако $\lim_{n\to\infty} M_{X_n}(t) = M_X(t)$ за $|t| < \varepsilon$, то $X_n \xrightarrow{d} X$ (теорема за непрекъснатост).

е) Ако $M_X(t) = M_Y(t)$ за $|t| < a$, то $X \stackrel{d}{=} Y$ (единственост).

ж) Ако $Y = aX + b$, то $M_Y(t) = e^{bt}\, M_X(at)$.

Доказателство

а) $M_X(0) = \mathbb{E}e^{0\cdot X} = \mathbb{E}1 = 1$.
б) Разлагаме e^{tX} в степенен ред и разменяме ред на сумиране с очакване (валидно в радиуса на сходимост):

$$M_X(t) = \mathbb{E}e^{tX} = \mathbb{E}\sum_{k=0}^{\infty} \frac{(tX)^k}{k!} = \sum_{k=0}^{\infty} \frac{t^k}{k!}\,\mathbb{E}X^k.$$

в) От б), M_X е степенен ред по t с коефициенти $a_k = \frac{1}{k!}\mathbb{E}X^k$. Диференцираме почленно k пъти (позволено вътре в радиуса на сходимост на степенен ред):

$$M_X^{(k)}(t) = \sum_{j=k}^{\infty} j(j-1)\cdots(j-k+1)\,\frac{t^{j-k}}{j!}\,\mathbb{E}X^j.$$

При $t = 0$ оцелява само членът с $j = k$ (всички останали съдържат положителна степен на t и се анулират):

$$M_X^{(k)}(0) = k(k-1)\cdots 1 \cdot \frac{1}{k!}\,\mathbb{E}X^k = \frac{k!}{k!}\,\mathbb{E}X^k = \mathbb{E}X^k.$$

г) Понеже $X \perp\!\!\!\perp Y$, функциите e^{tX} и e^{tY} на тях са също независими случайни величини, следователно по свойството за очакване на произведение на независими случайни величини (Тема 5):

$$M_{X+Y}(t) = \mathbb{E}e^{t(X+Y)} = \mathbb{E}\big(e^{tX}e^{tY}\big) = \mathbb{E}e^{tX}\cdot\mathbb{E}e^{tY} = M_X(t)\cdot M_Y(t)$$

(тук не се налага X, Y да имат съвместна плътност - равенството е в сила еднакво за дискретни, непрекъснати или смесени случаи).
д), е) Дълбоки аналитични резултати от теорията на преобразуванията на Лаплас/Фурие на вероятностни мерки - приемаме ги без доказателство в рамките на този курс.
ж)

$$M_Y(t) = \mathbb{E}e^{tY} = \mathbb{E}e^{t(aX+b)} = e^{bt}\,\mathbb{E}e^{atX} = e^{bt}\,M_X(at),$$

дефинирано за $|at| < \varepsilon \iff |t| < \varepsilon/|a|$. ■

Лема 13.2

Ако $X \sim N(\mu, \sigma^2)$, то $M_X(t) = e^{\mu t + \frac{\sigma^2 t^2}{2}}$ за всяко $t \in \mathbb{R}$.

Доказателство

Нека $Z = \frac{X-\mu}{\sigma} \sim N(0,1)$, т.е. $X = \mu + \sigma Z$. По свойство ж): $M_X(t) = e^{\mu t}\, M_Z(\sigma t)$. Остава да намерим $M_Z(s)$ за $Z \sim N(0,1)$:

$$M_Z(s) = \mathbb{E}e^{sZ} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{sz} e^{-z^2/2}\, dz = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{sz - \frac{z^2}{2}}\, dz.$$

Допълваме показателя до точен квадрат: $sz - \frac{z^2}{2} = -\frac{1}{2}(z-s)^2 + \frac{s^2}{2}$, следователно

$$M_Z(s) = \frac{e^{s^2/2}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(z-s)^2}\, dz \overset{\omega = z-s}{=} \frac{e^{s^2/2}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\omega^2/2}\, d\omega = e^{s^2/2} \cdot 1 = e^{s^2/2}$$

(последният интеграл е нормировъчният интеграл на плътността на $N(0,1)$, следователно е равен на $\sqrt{2\pi}$, което съкращава множителя пред него). Заместваме $s = \sigma t$:

$$M_X(t) = e^{\mu t}\, M_Z(\sigma t) = e^{\mu t}\, e^{\sigma^2 t^2/2} = e^{\mu t + \frac{\sigma^2 t^2}{2}}. \blacksquare$$

13.2 Централна гранична теорема

Теорема 13.3 (ЦГТ)

Нека $(X_i)_{i=1}^{\infty}$ е i.i.d. редица с $\mathbb{E}X_1 = \mu < \infty$, $0 < DX_1 = \sigma^2 < \infty$. Нека $S_n = \sum_{i=1}^{n} X_i$. Тогава

$$Z_n = \frac{S_n - \mathbb{E}S_n}{\sqrt{DS_n}} = \frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow[n\to\infty]{d} Z \sim N(0,1).$$

Доказателство

(Класическото доказателство на тази теорема минава през характеристични функции, тъй като те съществуват винаги; характеристичните функции обаче излизат извън рамките на този курс. Затова тук доказваме теоремата при допълнителното техническо предположение, че функцията на моментите $M_{X_1}(t)$ съществува в околност на нулата - аналогично на опростяването, направено при доказателството на УЗГЧ в Тема 12.)

Нека $Y_i = \dfrac{X_i - \mu}{\sigma}$, $i \geq 1$ - стандартизирани, i.i.d. величини с $\mathbb{E}Y_1 = 0$, $\mathbb{E}Y_1^2 = DY_1 = 1$. Тогава

$$Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i.$$

По допускането, $M_{X_1}(t)$ (следователно и $M_{Y_1}(t)$) съществува за $|t| < \varepsilon$. Понеже (Y_i) са i.i.d., по свойства г) и ж) на функцията на моментите:

$$M_{Z_n}(t) = M_{\frac{1}{\sqrt{n}}\sum Y_i}(t) = M_{\sum Y_i}\Big(\frac{t}{\sqrt{n}}\Big) = \prod_{i=1}^n M_{Y_i}\Big(\frac{t}{\sqrt{n}}\Big) = \Big(M_{Y_1}\big(\tfrac{t}{\sqrt{n}}\big)\Big)^n,$$

дефинирано за $\big|\frac{t}{\sqrt{n}}\big| < \varepsilon \iff |t| < \varepsilon\sqrt{n}$. Разгръщаме $M_{Y_1}(s)$ по свойство б) (на предната теорема) за малки $s = t/\sqrt{n}$:

$$M_{Y_1}\Big(\frac{t}{\sqrt{n}}\Big) = 1 + \frac{t}{\sqrt{n}}\,\mathbb{E}Y_1 + \frac{t^2}{2n}\,\mathbb{E}Y_1^2 + o\Big(\frac{t^2}{n}\Big) = 1 + \frac{t^2}{2n} + o\Big(\frac{t^2}{n}\Big)$$

(използвахме $\mathbb{E}Y_1 = 0$, $\mathbb{E}Y_1^2 = 1$). Следователно

$$M_{Z_n}(t) = \Big(1 + \frac{t^2}{2n} + o\Big(\frac{t^2}{n}\Big)\Big)^n \xrightarrow[n\to\infty]{} e^{t^2/2} = M_Z(t), \qquad Z \sim N(0,1)$$

(класически граничен преход $(1 + x_n/n)^n \to e^{\lim x_n}$, тук с $x_n = \frac{t^2}{2} + n \cdot o(t^2/n) \to \frac{t^2}{2}$). По свойство д) на функцията на моментите (теоремата за непрекъснатост), от $M_{Z_n}(t) \to M_Z(t)$ следва $Z_n \xrightarrow{d} Z$. ■

Полезни следствия (означаваме $\Phi(x) = \mathbb{P}(Z < x)$ за $Z \sim N(0,1)$)

От ЦГТ получаваме следните приблизителни (асимптотични) формули за голямо n:

- $\dfrac{S_n}{n} \approx \mu + Z \cdot \dfrac{\sigma}{\sqrt{n}}$ (приближение на извадковата средна);
- $\mathbb{P}\big(a < \frac{S_n - n\mu}{\sigma\sqrt{n}} < b\big) \approx \Phi(b) - \Phi(a)$;
- $\mathbb{P}\big(|\frac{S_n}{n} - \mu| > a\big) \approx \mathbb{P}\big(|Z| > \frac{a\sqrt{n}}{\sigma}\big)$.

Следствие 13.1 (на Моавър–Лаплас, ЦГТ за биномно разпределение)

Нека $S_n \sim Bin(n,p)$ (или еквивалентно, $S_n = \sum_{i=1}^n X_i$, $X_i \sim Be(p)$ i.i.d.). Тогава

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow[n\to\infty]{d} Z \sim N(0,1), \qquad \text{т.е.}$$

$$\mathbb{P}\Big(a \leq \frac{S_n - np}{\sqrt{np(1-p)}} \leq b\Big) \approx \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\,dx = \Phi(b) - \Phi(a).$$

Доказателство

Директно частен случай на ЦГТ за $X_i \sim Be(p)$, $\mu = \mathbb{E}X_1 = p$, $\sigma^2 = DX_1 = p(1-p)$: $Z_n = \frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} Z \sim N(0,1)$. ■

Неравенство 13.4 (Бери–Есен)

Нека $(X_i)_{i=1}^{\infty}$ е i.i.d. редица с $\mathbb{E}X_1 = \mu$, $DX_1 = \sigma^2$, $\mathbb{E}|X_1 - \mu|^3 < \infty$. Тогава

$$\sup_{x \in \mathbb{R}} \left| \mathbb{P}\Big(\frac{\sum_{i=1}^{N} X_i}{N} - \mu \le \frac{\sigma x}{\sqrt{N}} \Big) - \Phi(x) \right| \le \frac{0.4748 \cdot \mathbb{E}|X_1 - \mathbb{E}X_1|^3}{\sigma^3 \sqrt{N}}.$$

Забележка

ЦГТ ни казва, че разпределението на (стандартизираната) грешка клони към нормално разпределение, но не и *колко бързо*. Неравенството на Бери–Есен допълва тази картина, като дава количествена оценка на скоростта на сходимост - максималното отклонение между нашето (крайно) разпределение и идеалната нормална крива за конкретно N е от порядъка на $1/\sqrt{N}$.

13.3 Функция на моментите на Гама разпределението

Теорема 13.5

Ако $X \sim \Gamma(\alpha, \beta)$, то $M_X(t) = \left(\frac{\beta}{\beta - t}\right)^{\alpha}$ за $t < \beta$.

Доказателство

$$M_X(t) = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty e^{tx} x^{\alpha-1} e^{-\beta x}\, dx = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha-1} e^{-x(\beta - t)}\, dx.$$

Заместваме $y = x(\beta - t)$ (коректно за $t < \beta$, т.е. $\beta - t > 0$), $x = y/(\beta - t)$, $dx = dy/(\beta - t)$:

$$M_X(t) = \frac{\beta^\alpha}{\Gamma(\alpha)(\beta - t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y}\, dy = \frac{\beta^\alpha}{\Gamma(\alpha)(\beta - t)^\alpha} \cdot \Gamma(\alpha) = \left(\frac{\beta}{\beta - t}\right)^{\alpha}. \blacksquare$$

Следствие 13.2 (проверка на моментите чрез M_X)

Диференцирайки $M_X(t) = \beta^\alpha (\beta - t)^{-\alpha}$:

$$\mathbb{E}X = M_X'(0) = \frac{\alpha \beta^\alpha}{(\beta - t)^{\alpha+1}}\Big|_{t=0} = \frac{\alpha}{\beta}, \qquad \mathbb{E}X^2 = M_X''(0) = \frac{\alpha(\alpha+1)\beta^\alpha}{(\beta - t)^{\alpha+2}}\Big|_{t=0} = \frac{\alpha(\alpha+1)}{\beta^2},$$

което съвпада с директно пресметнатите стойности от Тема 11 ($\mathbb{E}X = \alpha/\beta$, $DX = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \alpha/\beta^2$) - потвърждение чрез независим метод.

Тема 14

Точкови оценки

14.1 Постановка

Идея

Нека X описва някакво свойство на генерална съвкупност, с функция на разпределение $F_X(x) = \mathbb{P}(X < x)$ (или плътност f_X). Разполагаме с **извадка** $\bar{X} = (X_1, \ldots, X_n)$, където $(X_i)_{i=1}^n$ са i.i.d. (независими наблюдения над X, $X_i \overset{d}{=} X$), и искаме на базата на извадката да определим или приближим F_X (респ. f_X). Важно е да отбележим: това, че знаем f_X или F_X, не означава, че познаваме случайния изход X предварително - знаем само разпределението му.

Допускане: параметричен клас

Допускаме, че X принадлежи на някакъв **клас** от случайни величини $F_X(x;\theta)$, където θ е параметър (или вектор от параметри), асоцииран с възможните разпределения на X. Например:

- $\theta = p$: $X \sim Be(p)$, $p \in (0,1)$;
- $\theta = \lambda$: $X \sim Exp(\lambda)$, $F_X(x;\lambda) = 1 - e^{-\lambda x}$, $\lambda > 0$;
- $\theta = (\mu, \sigma^2)$: $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$.

Дефиниция 14.1 (Точкова оценка)

Нека X е от класа $F_X(x;\theta)$ и нека $\bar{X} = (X_1, \ldots, X_n)$ е извадка от независими наблюдения над X. Функцията $\hat{\theta} = \hat{\theta}(\bar{X})$ се нарича **точкова оценка** (или **статистика**) за θ. Тъй като $\hat{\theta}$ е функция на случайни величини, самата $\hat{\theta}$ е случайна величина; за конкретна реализация $\bar{x} = (x_1, \ldots, x_n)$ получаваме конкретно число $\hat{\theta} = \hat{\theta}(\bar{x})$.

14.2 Максимално правдоподобни оценки

Дефиниция 14.2 (Функция на правдоподобие)

Нека X е от класа $f_X(x;\theta)$ (или дискретна с $f(x;\theta) = \mathbb{P}(X = x;\theta)$) и $\bar{X} = (X_1, \ldots, X_n)$ е извадка от независими наблюдения над X. **Функцията на правдоподобие** е съвместната плътност на извадката:

$$L(\bar{X};\theta) = \prod_{j=1}^{n} f_X(X_j;\theta).$$

Дефиниция 14.3 (Максимално правдоподобна оценка, МПО)

Нека Θ е множеството от възможни стойности на θ. Оценката $\hat{\theta}$, за която

$$L(\bar{X}, \hat{\theta}) = \sup_{\theta \in \Theta} \prod_{j=1}^{n} f(X_j; \theta),$$

се нарича **максимално правдоподобна оценка** за θ. Т.е. $\hat{\theta}$ е стойността на параметъра, за която функцията на правдоподобие достига максимум - интуитивно, тази стойност на θ, при която наблюдаваната извадка би била „най-вероятна“.

Логаритмуване

Ако f_X е диференцируема по θ, МПО обикновено се търси чрез $\dfrac{\partial L}{\partial \theta} = 0$ или (по-удобно на практика) чрез $\dfrac{\partial \ln L}{\partial \theta} = 0$ - понеже логаритъмът е монотонна функция, L и $\ln L$ достигат максимум в една и съща точка.

Пример: едно наблюдение от $N(\mu, 1)$

Нека $X \sim N(\mu, 1)$ и $\bar{X} = X_1 = x_1$ (едно единствено наблюдение). Тогава $L(\bar{X}, \mu) = f_X(x_1, \mu)$ - плътността на $N(\mu, 1)$, изчислена в точката x_1, като функция на μ. Тя се максимизира, когато центърът на камбанката съвпада точно с наблюдението, т.е. $\hat{\mu} = x_1$ (интуитивно: измежду всички възможни центрове μ, стойността $\mu = x_1$ прави наблюдението x_1 „най-вероятно“).

Теорема 14.1

Нека $X \sim N(\mu, \sigma^2)$ и $\bar{X} = (X_1, \ldots, X_n)$ са независими наблюдения над X. Тогава МПО за μ е

$$\hat{\mu} = \overline{X}_n = \frac{1}{n} \sum_{j=1}^{n} X_j$$

(винаги, независимо дали σ^2 е известно), а МПО за σ^2 зависи от това дали μ е известно:

а) $\hat{\sigma}^2 = \dfrac{1}{n} \sum_{j=1}^{n} (X_j - \mu)^2$ (ако μ е известно),

б) $\hat{\sigma}^2 = \dfrac{1}{n} \sum_{j=1}^{n} (X_j - \overline{X}_n)^2$ (ако μ не е известно).

Доказателство

Функцията на правдоподобие е

$$L(\bar{X},\theta)=\left(\frac{1}{\sqrt{2\pi}}\right)^n(\sigma^2)^{-n/2}\,e^{-\sum_{j=1}^n\frac{(X_j-\mu)^2}{2\sigma^2}},\qquad \theta=(\mu,\sigma^2),$$

следователно

$$\ln L(\bar{X},\theta)=-\frac{n}{2}\ln(2\pi)-\frac{n}{2}\ln(\sigma^2)-\sum_{j=1}^n\frac{(X_j-\mu)^2}{2\sigma^2}.$$

Диференцираме по μ и приравняваме на нула:

$$\frac{\partial\ln L}{\partial\mu}=\frac{1}{\sigma^2}\sum_{j=1}^n(X_j-\mu)=0\quad\Longrightarrow\quad\hat{\mu}=\overline{X}_n$$

(независимо от стойността на σ^2). Диференцираме по σ^2:

$$\frac{\partial\ln L}{\partial\sigma^2}=-\frac{n}{2\sigma^2}+\frac{1}{2\sigma^4}\sum_{j=1}^n(X_j-\mu)^2=0.$$

Ако μ е известно, решаваме директно: $\hat{\sigma}^2=\frac{1}{n}\sum_{j=1}^n(X_j-\mu)^2$. Ако μ не е известно, заместваме неговата МПО оценка $\hat{\mu}=\overline{X}_n$ (решавайки системата от двете уравнения едновременно): $\hat{\sigma}^2=\frac{1}{n}\sum_{j=1}^n(X_j-\overline{X}_n)^2$. ■

Пример: $X\sim U(0,\theta)$

Нека $f_X(x)=\frac{1}{\theta}\,I_{[0,\theta]}(x)$, $\theta>0$. Тогава

$$L(\bar{X},\theta)=\prod_{j=1}^n\frac{1}{\theta}\,I_{[0,\theta]}(X_j)=\begin{cases}\dfrac{1}{\theta^n}, & \theta\geq\max_{1\leq j\leq n}X_j\\ 0, & \theta<\max_{1\leq j\leq n}X_j\end{cases}.$$

Понеже $\frac{1}{\theta^n}$ намалява по θ, функцията на правдоподобие е максимална при най-малкото допустимо θ, т.е.

$$\hat{\theta}=\max_{1\leq j\leq n}X_j.$$

14.3 Метод на моментите

Идея

От усиления закон за големите числа (Тема 12), за i.i.d. извадка: $\overline{X}_n^{(j)}:=\frac{1}{n}\sum_{k=1}^n X_k^j\xrightarrow{\text{п.с.}}\mathbb{E}X^j$ за всеки ред на момента j (стига моментът да съществува). Идеята на метода на моментите е да *изравним* теоретичните моменти (функции на θ) с емпиричните моменти от извадката и да решим спрямо θ.

Дефиниция 14.4 (Метод на моментите, ММ)

Нека X е случайна величина от клас $F_X(x;\theta)$, $\theta = (\theta_1, \dots, \theta_s)$, и $\bar{X}$ е извадка. Ако първите s момента на X съществуват, полагаме $\mu^{(j)}(\theta) := \mathbb{E}X^j$, $1 \le j \le s$, и емпиричните моменти $\overline{X}_n^{(j)} = \frac{1}{n}\sum_{k=1}^n X_k^j$. Тогава **оценката по метода на моментите** $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_s)$ се получава чрез решаване на системата (спрямо целия вектор θ едновременно - за $s \ge 2$ всеки момент обикновено зависи от *няколко* от параметрите, така че координатно обръщане по компоненти на θ най-често не е възможно)

$$\mu^{(j)}(\theta) = \overline{X}_n^{(j)}, \qquad 1 \le j \le s.$$

При $s = 1$ системата е едно уравнение с едно неизвестно и решението приема простия вид $\hat{\theta} = \big(\mu^{(1)}\big)^{-1}\big(\overline{X}_n^{(1)}\big)$.

Пример: $X \sim U(0, \theta)$

$\mu^{(1)}(\theta) = \mathbb{E}X = \frac{\theta}{2}$. Изравняваме с $\overline{X}_n^{(1)}$: $\frac{\theta}{2} = \overline{X}_n^{(1)} \Rightarrow \hat{\theta} = 2\overline{X}_n^{(1)} = 2\overline{X}_n$ - различна от МПО оценката $\max_j X_j$, но също разумна оценка на θ.

Пример: $X \sim N(\mu, \sigma^2)$, *двата параметъра неизвестни*

Тук $\theta = (\mu, \sigma^2)$, а системата е $\mathbb{E}X = \overline{X}_n^{(1)}$, $\mathbb{E}X^2 = \overline{X}_n^{(2)}$. От $\mathbb{E}X = \mu$ получаваме $\hat{\mu} = \overline{X}_n^{(1)} = \overline{X}_n$. От $\mathbb{E}X^2 = DX + (\mathbb{E}X)^2 = \sigma^2 + \mu^2$ получаваме

$$\hat{\sigma}^2 = \overline{X}_n^{(2)} - \hat{\mu}^2 = \overline{X}_n^{(2)} - \big(\overline{X}_n^{(1)}\big)^2,$$

което съвпада точно с МПО оценката от предната теорема (в случая, когато μ не е известно) - в този пример методът на моментите и методът на максималното правдоподобие дават *една и съща* оценка.

14.4 Свойства на точковите оценки

Дефиниция 14.5 (Неизместеност)

Казваме, че $\hat{\theta}$ е **неизместена** (несмесена) оценка за θ, ако $\mathbb{E}\hat{\theta}(\bar{X}) = \theta$ (респ. $\mathbb{E}\hat{\theta}_j = \theta_j$ за всяко $1 \le j \le s$, ако $\theta = (\theta_1, \dots, \theta_s)$). Величината $|\mathbb{E}\hat{\theta} - \theta|$ се нарича **систематична грешка** на $\hat{\theta}$.

Пример: $\hat{\mu} = \overline{X}_n$, $X \sim N(\mu, \sigma^2)$

$$\mathbb{E}\hat{\mu} = \mathbb{E}\Big(\frac{1}{n}\sum_{j=1}^n X_j\Big) = \frac{1}{n}\sum_{j=1}^n \mathbb{E}X_j = \frac{1}{n}\cdot n\mu = \mu \quad \Longrightarrow \quad \hat{\mu} \text{ е неизместена.}$$

Пример: дисперсията, ако μ ***е известно***

$\hat{\sigma}^2 = \frac{1}{n}\sum_{j=1}^n (X_j - \mu)^2$:

$$\mathbb{E}\hat{\sigma}^2 = \frac{1}{n}\sum_{j=1}^n \mathbb{E}(X_j - \mu)^2 = \frac{1}{n}\cdot n\sigma^2 = \sigma^2 \quad \Longrightarrow \quad \hat{\sigma}^2 \text{ е неизместена.}$$

Пример: дисперсията, ако μ не е известно (важен случай!)

Нека $\hat\sigma^2 = \frac{1}{n}\sum_{j=1}^n (X_j - \overline{X}_n)^2 = \overline{X}_n^{(2)} - \big(\overline{X}_n^{(1)}\big)^2$ (разписано чрез разкриване на квадрата, аналогично на $DX = \mathbb{E}X^2 - (\mathbb{E}X)^2$). Тогава

$$\mathbb{E}\hat\sigma^2 = \mathbb{E}\overline{X}_n^{(2)} - \mathbb{E}\big(\overline{X}_n^{(1)}\big)^2 = \mathbb{E}X_1^2 - \frac{1}{n^2}\,\mathbb{E}\Big(\sum_{j=1}^n X_j^2 + \sum_{i\neq j} X_iX_j\Big).$$

Понеже (X_i) са i.i.d., $\mathbb{E}\sum_j X_j^2 = n\,\mathbb{E}X_1^2$, а за $i \neq j$ (независими, $\mathbb{E}X_iX_j = \mathbb{E}X_i\,\mathbb{E}X_j = \mu^2$) има точно $n(n-1)$ наредени двойки, следователно:

$$\begin{aligned}\mathbb{E}\hat\sigma^2 &= \mathbb{E}X_1^2 - \frac{1}{n^2}\Big(n\,\mathbb{E}X_1^2 + n(n-1)\mu^2\Big) = \Big(1-\frac{1}{n}\Big)\mathbb{E}X_1^2 - \frac{n-1}{n}\mu^2\\ &= \frac{n-1}{n}\big(\mathbb{E}X_1^2 - \mu^2\big) = \frac{n-1}{n}\,\sigma^2 \neq \sigma^2.\end{aligned}$$

Следователно тази оценка е **изместена**, със систематична грешка $|\mathbb{E}\hat\sigma^2 - \sigma^2| = \frac{\sigma^2}{n}$. Но $\mathbb{E}\hat\sigma^2 = \frac{n-1}{n}\sigma^2 \to \sigma^2$ при $n\to\infty$ - казваме, че $\hat\sigma^2$ е **асимптотично неизместена**. *(Затова на практика често се предпочита нормираната с $\frac{1}{n-1}$ версия на извадковата дисперсия - тя е точно неизместена.)*

Пример: $X \sim U(0,\theta)$, МПО оценката $\hat\theta = \max_j X_j$

Намираме плътността на $\hat\theta$:

$$F_{\hat\theta}(x) = \mathbb{P}\Big(\max_{1\le j\le n} X_j \le x\Big) = \prod_{j=1}^n \mathbb{P}(X_j \le x) = \big(\mathbb{P}(X_1\le x)\big)^n = \begin{cases}0, & x\le 0\\ (x/\theta)^n, & x\in(0,\theta)\\ 1, & x\ge\theta\end{cases}$$

(използвахме независимостта на (X_j)), следователно $f_{\hat\theta}(x) = \frac{n}{\theta^n}x^{n-1}$ за $x\in(0,\theta)$. Тогава

$$\mathbb{E}\hat\theta = \int_0^\theta x\cdot\frac{n}{\theta^n}x^{n-1}\,dx = \frac{n}{\theta^n}\int_0^\theta x^n\,dx = \frac{n}{\theta^n}\cdot\frac{\theta^{n+1}}{n+1} = \frac{n}{n+1}\,\theta < \theta,$$

т.е. $\hat\theta$ е **изместена** оценка, но $\frac{n}{n+1}\theta \to \theta$ при $n\to\infty$, т.е. тя е **асимптотично неизместена**.

Дефиниция 14.6 (Състоятелност)

Нека $\hat\theta = \hat\theta(\bar X)$ е точкова оценка на θ (респ. $\theta = (\theta_1,\dots,\theta_s)$). Казваме, че $\hat\theta$ е **състоятелна** оценка на θ, ако

$$\hat\theta \xrightarrow[n\to\infty]{\mathbb{P}} \theta \qquad \Big(\text{еквивалентно: } \forall\varepsilon>0:\ \mathbb{P}\big(|\hat\theta(\bar X)-\theta|>\varepsilon\big)\xrightarrow[n\to\infty]{} 0\Big)$$

(вероятността за грешка намалява, когато броят на наблюденията в извадката расте).

Дефиниция 14.7 (Силна състоятелност)

Казваме, че $\hat\theta$ е **силно състоятелна** оценка на θ, ако $\hat\theta \xrightarrow[n\to\infty]{\text{п.с.}} \theta$. От теоремата за видовете сходимост (Тема 12), силната състоятелност влече състоятелност.

Пример:** $\hat{\mu} = \overline{X}_n$ **е силно състоятелна

По усиления закон за големите числа (Тема 12), директно приложен към i.i.d. извадката (X_j): $\overline{X}_n = \frac{1}{n}\sum_j X_j \xrightarrow{\text{п.с.}} \mathbb{E}X_1 = \mu$.

Пример:** $\hat{\sigma}^2 = \overline{X}_n^{(2)} - (\overline{X}_n^{(1)})^2$ **е силно състоятелна

По УЗГЧ, приложен поотделно към редиците (X_j) и (X_j^2): $\overline{X}_n^{(1)} \xrightarrow{\text{п.с.}} \mathbb{E}X_1 = \mu$ и $\overline{X}_n^{(2)} \xrightarrow{\text{п.с.}} \mathbb{E}X_1^2$. Функцията $g(a,b) = b - a^2$ е непрекъсната, следователно

$$\hat{\sigma}^2 = \overline{X}_n^{(2)} - \left(\overline{X}_n^{(1)}\right)^2 \xrightarrow[n\to\infty]{\text{п.с.}} \mathbb{E}X_1^2 - \mu^2 = \sigma^2,$$

т.е. $\hat{\sigma}^2$ е силно състоятелна (макар да е изместена за крайно n, видяхме по-горе).

Тема 15

Доверителни интервали и хипотези

15.1 Доверителни интервали

Постановка

Нека X е от клас $F_X(x;\theta)$, $\theta = (\theta_1, \ldots, \theta_s)$, и $\bar{X} = (X_1, \ldots, X_n)$ е извадка. Търсим $I_1 = I_1(\bar{X}) < I_2(\bar{X}) = I_2$, такива че

$$\mathbb{P}(I_1 \leq \theta \leq I_2) \geq \gamma,$$

където $\gamma \in (0,1)$ (обикновено $\gamma = 0.9, 0.95, 0.99$) се нарича **ниво на доверие** и зависи от най-голямата вероятност за грешка, която можем да си позволим да допуснем. *Важно:* I_1 и I_2 са стохастични (зависят от случайната извадка), докато θ е фиксирано - търсим интервал (със случайни краища), който да „улавя“ фиксирания параметър с висока вероятност.

Дефиниция 15.1 (Централна статистика)

Казваме, че $T = T(\bar{X}, \theta)$ е **централна статистика**, ако:

1) $T(\bar{X}, \cdot)$ е монотонна функция на θ;
2) разпределението на $T(\bar{X}, \theta)$ не зависи от θ, т.е. $\mathbb{P}(T(\bar{X}, \theta) < x) = G(x)$ за някаква функция G, зависеща само от x.

(Централните статистики зависят от θ като аргумент, но разпределението им - не.)

Конструкция на доверителен интервал от централна статистика

Нека T е монотонно растяща по θ (случаят намаляваща е аналогичен, само с разменени краища). Избираме квантили $q_1 < q_2$ такива, че $G(q_2) - G(q_1) = \gamma$ (например симетрично, ако G е симетрична относно нулата). Тогава

$$\gamma = \mathbb{P}\big(q_1 \leq T(\bar{X}, \theta) \leq q_2\big) = G(q_2) - G(q_1).$$

Понеже $T(\bar{X}, \cdot)$ е растяща (следователно обратима по θ), можем да „обърнем“ неравенствата, прилагайки $T^{-1}(\bar{X}, \cdot)$ към трите части:

$$\gamma = \mathbb{P}\big(T^{-1}(\bar{X}, q_1) \leq \theta \leq T^{-1}(\bar{X}, q_2)\big).$$

Следователно $I_1 = T^{-1}(\bar{X}, q_1)$, $I_2 = T^{-1}(\bar{X}, q_2)$ (или, ако T е намаляваща по θ: $I_1 = T^{-1}(\bar{X}, q_2)$, $I_2 = T^{-1}(\bar{X}, q_1)$).

Дефиниция 15.2 (Доверителен интервал)

Интервалът $\big(I_1(\bar{X}), I_2(\bar{X})\big)$, конструиран по горния начин от централна статистика T, се нарича **доверителен интервал** за θ с ниво на доверие γ.

15.2 Доверителни интервали за средната стойност на нормално разпределение

Теорема 15.1 (доверителен интервал за μ при известно σ^2)

Нека $X \sim N(\mu, \sigma^2)$, σ^2 известно, и $\bar{X} = (X_1, \ldots, X_n)$. Нека $\hat{\mu} = \overline{X}_n^{(1)} = \frac{1}{n}\sum_{j=1}^n X_j$. Тогава доверителният интервал за μ с ниво на доверие γ е

$$\Big(\hat{\mu} - q\,\frac{\sigma}{\sqrt{n}},\ \hat{\mu} + q\,\frac{\sigma}{\sqrt{n}}\Big), \qquad q = \Phi^{-1}\Big(\frac{1+\gamma}{2}\Big),$$

където Φ е функцията на разпределение на $N(0,1)$.

Доказателство

Понеже $X_j \sim N(\mu, \sigma^2)$ независими, $\hat{\mu} = \frac{1}{n}\sum_j X_j \sim N(\mu, \sigma^2/n)$ (Тема 11: сума на независими нормални случайни величини), следователно

$$T = \frac{\hat{\mu} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

е централна статистика (разпределението ѝ, $N(0,1)$, не зависи от μ). Избираме симетрични квантили $\pm q$ на $N(0,1)$ с $\mathbb{P}(-q \le Z \le q) = \gamma$, т.е. $\Phi(q) - \Phi(-q) = 2\Phi(q) - 1 = \gamma \Rightarrow q = \Phi^{-1}\big(\frac{1+\gamma}{2}\big)$ (използвахме $\Phi(-q) = 1 - \Phi(q)$ по симетрията на $N(0,1)$). Тогава

$$\gamma = \mathbb{P}\Big(-q \le \frac{\hat{\mu} - \mu}{\sigma/\sqrt{n}} \le q\Big) = \mathbb{P}\Big(-q\frac{\sigma}{\sqrt{n}} \le \hat{\mu} - \mu \le q\frac{\sigma}{\sqrt{n}}\Big) = \mathbb{P}\Big(\hat{\mu} - q\frac{\sigma}{\sqrt{n}} \le \mu \le \hat{\mu} + q\frac{\sigma}{\sqrt{n}}\Big). \blacksquare$$

Теорема 15.2 (разлагане на квадратичната сума)

Нека $X \sim N(\mu, \sigma^2)$ и $\bar{X} = (X_1, \ldots, X_n)$, $\hat{\mu} = \overline{X}_n$, $S^2 = \frac{1}{n-1}\sum_{j=1}^n (X_j - \hat{\mu})^2$. Тогава S^2 е неизместена оценка за σ^2, S^2 и $\hat{\mu}$ са независими, и

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

Доказателство

Нека $Z_j = \frac{X_j - \mu}{\sigma} \sim N(0,1)$, i.i.d. По алгебричната идентичност (разлагане чрез добавяне и изваждане на $\hat{\mu}$):

$$\sum_{j=1}^{n}(X_j - \mu)^2 = \sum_{j=1}^{n}(X_j - \hat{\mu})^2 + n(\hat{\mu} - \mu)^2 \quad \Longrightarrow \quad \sum_{j=1}^{n} Z_j^2 = \frac{(n-1)S^2}{\sigma^2} + n\frac{(\hat{\mu} - \mu)^2}{\sigma^2}.$$

Лявата страна $\sum_j Z_j^2 \sim \chi^2(n)$ (сума на квадратите на n независими $N(0,1)$-величини, Тема 11), а вторият член отдясно е $\left(\frac{\hat{\mu}-\mu}{\sigma/\sqrt{n}}\right)^2 \sim \chi^2(1)$ (по предната теорема, изразът в скоби е $N(0,1)$).
За да установим, че $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ и че тя е независима от $\hat{\mu}$, използваме следния класически похват (ортогонална трансформация на нормален вектор): нека $\bar{Z} = (Z_1, \ldots, Z_n)$. Съществува ортогонална матрица O (т.е. $OO^\top = I$), чийто първи ред е $\left(\frac{1}{\sqrt{n}}, \ldots, \frac{1}{\sqrt{n}}\right)$ - останалите редове допълваме до ортонормирана база на $\mathbb{R}^n$. Полагаме $\bar{Y} = O\bar{Z}$. От теорията на многомерното нормално разпределение, линейно (ортогонално) преобразуване на вектор от независими $N(0,1)$ величини отново дава вектор от независими $N(0,1)$ величини (приемаме този факт за известен - той следва от инвариантността на плътността $\prod_j \frac{1}{\sqrt{2\pi}} e^{-z_j^2/2}$ спрямо ротации, тъй като зависи само от нормата $\|\bar{z}\|^2 = \sum z_j^2$, която O запазва). Следователно $Y_1, \ldots, Y_n$ са независими, $Y_i \sim N(0,1)$.
Понеже O е ортогонална, тя запазва евклидовата норма: $\sum_{j=1}^n Z_j^2 = \|\bar{Z}\|^2 = \|\bar{Y}\|^2 = \sum_{j=1}^n Y_j^2 = Y_1^2 + \sum_{j=2}^n Y_j^2$. От избора на първия ред на O:

$$Y_1 = \frac{1}{\sqrt{n}}\sum_{j=1}^{n} Z_j = \frac{1}{\sqrt{n}}\sum_{j=1}^{n}\frac{X_j - \mu}{\sigma} = \frac{\sqrt{n}(\hat{\mu} - \mu)}{\sigma}, \qquad \text{т.е.} \qquad Y_1^2 = n\frac{(\hat{\mu} - \mu)^2}{\sigma^2}.$$

Сравнявайки с разлагането по-горе, $\sum_{j=2}^n Y_j^2 = \sum_j Z_j^2 - Y_1^2 = \frac{(n-1)S^2}{\sigma^2}$. Понеже Y_1 е функция единствено на $\bar{Z}$ през първия ред на O, а $\sum_{j=2}^n Y_j^2$ е функция единствено на $Y_2, \ldots, Y_n$, и $Y_1 \perp\!\!\!\perp (Y_2, \ldots, Y_n)$ (независимост на компонентите на $\bar{Y}$), следва

$$\hat{\mu} = \mu + \frac{\sigma Y_1}{\sqrt{n}} \quad \perp\!\!\!\perp \quad \frac{(n-1)S^2}{\sigma^2} = \sum_{j=2}^{n} Y_j^2,$$

т.е. $\hat{\mu} \perp\!\!\!\perp S^2$. Освен това $Y_2, \ldots, Y_n$ са $n-1$ на брой независими $N(0,1)$ величини, следователно $\sum_{j=2}^n Y_j^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ (отново по Тема 11). ■

Теорема 15.3 (доверителен интервал за μ при неизвестно σ^2)

Нека $X \sim N(\mu, \sigma^2)$, σ^2 неизвестно, и $\hat{\mu}, S^2$ както по-горе. Тогава доверителният интервал за μ с ниво на доверие γ е

$$\left(\hat{\mu} - q\frac{S}{\sqrt{n}},\ \hat{\mu} + q\frac{S}{\sqrt{n}}\right), \qquad q \text{ е } \tfrac{1+\gamma}{2}\text{-ти квантил на } t(n-1).$$

Доказателство

Разглеждаме

$$T = \frac{\hat{\mu}-\mu}{S/\sqrt{n}} = \frac{\frac{\hat{\mu}-\mu}{\sigma/\sqrt{n}}}{\frac{S}{\sigma}} = \frac{\frac{\hat{\mu}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}}.$$

Числителят е $\sim N(0,1)$ (по първата теорема), знаменателят е $\sqrt{\chi^2(n-1)/(n-1)}$ (по предната теорема), и двете са независими (защото $\hat{\mu} \perp\!\!\!\perp S^2$). По дефиницията на t-разпределение (Тема 11), $T \sim t(n-1)$ - централна статистика (разпределението $t(n-1)$ не зависи от μ). Избираме симетрични квантили $\pm q$ на $t(n-1)$ с $\mathbb{P}(-q \le T \le q) = \gamma$ (т.е. q е $\frac{1+\gamma}{2}$-тият квантил на $t(n-1)$, по симетрията на разпределението на Стюдънт). Аналогично на предната теорема:

$$\gamma = \mathbb{P}\Big(-q \le \frac{\hat{\mu}-\mu}{S/\sqrt{n}} \le q\Big) = \mathbb{P}\Big(\hat{\mu} - q\frac{S}{\sqrt{n}} \le \mu \le \hat{\mu} + q\frac{S}{\sqrt{n}}\Big). \blacksquare$$

15.3 Доверителни интервали за дисперсията на нормално разпределение

Теорема 15.4 (доверителен интервал за σ^2 при известно μ)

Нека $X \sim N(\mu, \sigma^2)$, μ известно, $\hat{\sigma}^2 = \frac{1}{n}\sum_{j=1}^{n}(X_j - \mu)^2$. Тогава доверителният интервал за σ^2 с ниво на доверие γ е

$$\Big(\frac{n\hat{\sigma}^2}{q_2}, \frac{n\hat{\sigma}^2}{q_1}\Big),$$

където $q_1 < q_2$ са квантили на $\chi^2(n)$, отрязващи по $\frac{1-\gamma}{2}$ вероятност във всяка опашка.

Доказателство

$T = n\hat{\sigma}^2/\sigma^2 = \sum_{j=1}^{n}\big(\frac{X_j-\mu}{\sigma}\big)^2 \sim \chi^2(n)$ (Тема 11) е централна статистика, намаляваща функция на $\theta = \sigma^2$. Избираме $q_1 < q_2$ с $\mathbb{P}(q_1 \le T \le q_2) = \gamma$. Тогава („обръщайки“ неравенствата спрямо σ^2, което разменя посоката поради намаляващата зависимост):

$$q_1 \le \frac{n\hat{\sigma}^2}{\sigma^2} \iff \sigma^2 \le \frac{n\hat{\sigma}^2}{q_1}, \qquad \frac{n\hat{\sigma}^2}{\sigma^2} \le q_2 \iff \sigma^2 \ge \frac{n\hat{\sigma}^2}{q_2},$$

следователно $\gamma = \mathbb{P}\big(\frac{n\hat{\sigma}^2}{q_2} \le \sigma^2 \le \frac{n\hat{\sigma}^2}{q_1}\big)$. $\blacksquare$

Теорема 15.5 (доверителен интервал за σ^2 при неизвестно μ)

Нека $X \sim N(\mu, \sigma^2)$, μ неизвестно, S^2 както по-горе. Тогава доверителният интервал за σ^2 с ниво на доверие γ е

$$\Big(\frac{(n-1)S^2}{q_2}, \frac{(n-1)S^2}{q_1}\Big),$$

където $q_1 < q_2$ са квантили на $\chi^2(n-1)$, отрязващи по $\frac{1-\gamma}{2}$ вероятност във всяка опашка.

Доказателство

Идентично на предната теорема, но с централна статистика $T = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ (теоремата за разлагането на квадратичната сума). ■

15.4 Проверка на хипотези

Схема на Нойман–Пирсън

1) Допускаме, че хипотезата („базовата“/„нулевата“) е вярна.
2) Конструираме събитие (**критична област**) $W \subseteq \mathbb{R}^n$ (n - размерността на извадката); ако $\bar{X} \in W$, отхвърляме хипотезата, иначе я приемаме.

Изборът на W зависи от вероятността за грешка, която сме готови да допуснем.

Дефиниция 15.3 (Хипотези, грешки от I и II род)

Нека $X \sim F_X(x;\theta)$, $\theta \in \mathbb{R}^s$, и $\bar{X} = (X_1, \ldots, X_n)$ са i.i.d. наблюдения над X. Разглеждаме:

$$H_0 : \ \theta = \theta_0 \quad \text{(нулева/базова хипотеза)}, \qquad H_1 : \ \theta = \theta_1 \quad \text{(алтернативна хипотеза)}.$$

(По-общо, H_0, H_1 могат да са *сложни* - напр. $\theta < \theta_0$, $\theta > \theta_0$, $\theta \neq \theta_0$ - за разлика от *простите* хипотези от вида $\theta = \theta_i$.) Търсим критична област $W \subseteq \mathbb{R}^n$: ако $\bar{X} \in W$, отхвърляме H_0; иначе приемаме H_0. Дефинираме:

$$\alpha_W = \mathbb{P}(\bar{X} \in W \mid H_0) \quad \textbf{(грешка от I род)},$$

$$\beta_W = \mathbb{P}(\bar{X} \notin W \mid H_1) \quad \textbf{(грешка от II род)}.$$

Монотонност и компромис

Ако $W_1 \subseteq W_2$, то $\alpha_{W_1} \leq \alpha_{W_2}$ и $\beta_{W_1} \geq \beta_{W_2}$ - намаляването на едната грешка (чрез свиване на критичната област) неизбежно увеличава другата. По конвенция, обикновено грешката от I род (погрешно отхвърляне на вярна H_0) се смята за по-критична, затова фиксираме малка граница за α (напр. 0.05) и се стремим да минимизираме β при това ограничение.

Дефиниция 15.4 (Оптимална критична област)

Нека разглеждаме проста срещу проста хипотеза и нека за фиксирана грешка от първи род α е в сила $\alpha = \alpha_{W^*}$ за дадено $W^* \subseteq \mathbb{R}^n$. Тогава W^* е **оптимална критична област** за α, ако

$$\beta_{W^*} = \min_{W:\ \alpha_W = \alpha} \beta_W,$$

т.е. W^* минимизира вероятността за грешка от втори род измежду всички критични области със същата грешка от първи род.

Лема 15.6 (на Нойман–Пирсън)

Нека $H_0 : \theta = \theta_0$ срещу $H_1 : \theta = \theta_1$ (проста срещу проста хипотеза), с функции на правдоподобие $L_0(\bar{x}) = L(\bar{x}, \theta_0)$, $L_1(\bar{x}) = L(\bar{x}, \theta_1)$. Нека $W^* \subseteq \mathbb{R}^n$ е такова, че за някое $\kappa > 0$:

$$W^* \subseteq \{\bar{x} \in \mathbb{R}^n : L_1(\bar{x}) \geq \kappa L_0(\bar{x})\}, \qquad (W^*)^c \subseteq \{\bar{x} \in \mathbb{R}^n : L_1(\bar{x}) \leq \kappa L_0(\bar{x})\}.$$

Тогава W^* е оптимална критична област за $\alpha = \alpha_{W^*}$.

Доказателство

Нека $W \subseteq \mathbb{R}^n$ е произволна критична област с $\alpha_W = \alpha_{W^*} = \alpha$, и нека $\beta = \beta_W$, $\beta^* = \beta_{W^*}$. Целта е да покажем $\beta^* \leq \beta$.
Разбиваме W^c и $(W^*)^c$ по двойки дизюнктни части:

$$W^c = \big(W^c \cap (W^*)^c\big) \cup \big(W^c \cap W^*\big), \qquad (W^*)^c = \big(W^c \cap (W^*)^c\big) \cup \big(W \cap (W^*)^c\big).$$

Интегрирайки L_1 по тези разбивания:

$$\beta = \int_{W^c} L_1 \, d\bar{x} = \int_{W^c \cap (W^*)^c} L_1 \, d\bar{x} + \int_{W^c \cap W^*} L_1 \, d\bar{x},$$

$$\beta^* = \int_{(W^*)^c} L_1 \, d\bar{x} = \int_{W^c \cap (W^*)^c} L_1 \, d\bar{x} + \int_{W \cap (W^*)^c} L_1 \, d\bar{x}.$$

Изваждайки:

$$\beta - \beta^* = \int_{W^c \cap W^*} L_1 \, d\bar{x} - \int_{W \cap (W^*)^c} L_1 \, d\bar{x}.$$

От условията на лемата: $W^c \cap W^* \subseteq W^* \subseteq \{L_1 \geq \kappa L_0\}$, следователно $L_1 \geq \kappa L_0$ навсякъде в $W^c \cap W^*$; и $W \cap (W^*)^c \subseteq (W^*)^c \subseteq \{L_1 \leq \kappa L_0\}$, следователно $L_1 \leq \kappa L_0$ навсякъде в $W \cap (W^*)^c$. Тогава

$$\beta - \beta^* \geq \int_{W^c \cap W^*} \kappa L_0 \, d\bar{x} - \int_{W \cap (W^*)^c} \kappa L_0 \, d\bar{x} = \kappa \left(\int_{W^c \cap W^*} L_0 \, d\bar{x} - \int_{W \cap (W^*)^c} L_0 \, d\bar{x} \right).$$

Остава да покажем, че скобата е нула. Понеже $\alpha_W = \alpha_{W^*}$:

$$\int_W L_0 \, d\bar{x} = \alpha_W = \alpha_{W^*} = \int_{W^*} L_0 \, d\bar{x}.$$

Разбиваме отново по дизюнктни части: $W = (W \cap W^*) \cup (W \cap (W^*)^c)$ и $W^* = (W \cap W^*) \cup (W^* \cap W^c)$, откъдето

$$\int_{W \cap W^*} L_0 + \int_{W \cap (W^*)^c} L_0 = \int_W L_0 = \int_{W^*} L_0 = \int_{W \cap W^*} L_0 + \int_{W^* \cap W^c} L_0$$

$$\Longrightarrow \quad \int_{W \cap (W^*)^c} L_0 = \int_{W^* \cap W^c} L_0,$$

т.е. точно скобата по-горе е нула (защото $W^* \cap W^c = W^c \cap W^*$). Следователно $\beta - \beta^* \geq \kappa \cdot 0 = 0$, т.е. $\beta \geq \beta^*$ - W^* минимизира грешката от втори род измежду критичните области със същата грешка от първи род, следователно е оптимална. ■

Тема 16

Линейна регресия

16.1 Модел на линейната регресия

Дефиниция 16.1 (Модел на линейната регресия)

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

където Y е **отклик** (обяснявана величина), X е **предиктор** (обясняваща величина), а ε е случайна грешка. За наблюденията $(X_k, Y_k)_{k=1}^n$: $Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k$. Навсякъде по-долу приемаме, че не всички X_k са равни, т.е. $\sum_{k=1}^n (X_k - \bar{X})^2 > 0$ (иначе наклонът β_1 не е идентифицируем от данните).

Метод на най-малките квадрати

Търсим оценки b_0, b_1 на β_0, β_1, минимизиращи сумата на квадратите на грешките:

$$\min_{b_0,b_1} \sum_{k=1}^n \left(y_k - b_0 - b_1 x_k\right)^2 = \min_{b_0,b_1} \sum_{k=1}^n (y_k - \hat{y}_k)^2, \qquad \hat{y}_k := b_0 + b_1 x_k.$$

Теорема 16.1

Решението на горната задача за минимизация е

$$b_1 = \frac{\sum_{k=1}^n y_k (x_k - \bar{x})}{\sum_{k=1}^n (x_k - \bar{x})^2} \quad \text{(наклон на правата)},$$

$$b_0 = \bar{y} - \bar{x} \cdot b_1 \quad \text{(пресечна точка с ординатата)},$$

където $\bar{x} = \frac{1}{n}\sum_k x_k$, $\bar{y} = \frac{1}{n}\sum_k y_k$.

Доказателство

Нека $f(b_0, b_1) = \sum_{k=1}^{n}(y_k - b_0 - b_1 x_k)^2$. Приравняваме частните производни на нула:

$$0 = \frac{\partial f}{\partial b_0} = -2\sum_{k=1}^{n}(y_k - b_0 - b_1 x_k), \qquad 0 = \frac{\partial f}{\partial b_1} = -2\sum_{k=1}^{n}(y_k - b_0 - b_1 x_k)x_k.$$

От първото уравнение: $n\bar{y} - nb_0 - b_1 n\bar{x} = 0 \Rightarrow b_0 = \bar{y} - b_1\bar{x}$. Заместваме във второто:

$$\sum_{k=1}^{n} x_k y_k - nb_0\bar{x} - b_1\sum_{k=1}^{n} x_k^2 = 0 \quad \Longrightarrow \quad b_1 = \frac{\sum_k x_k y_k - n\bar{x}\bar{y}}{\sum_k x_k^2 - n\bar{x}^2} = \frac{\sum_k y_k(x_k - \bar{x})}{\sum_k (x_k - \bar{x})^2}$$

(последното преобразуване използва тъждеството $\sum_k (x_k - \bar{x})^2 = \sum_k x_k^2 - n\bar{x}^2 = \sum_k x_k(x_k - \bar{x})$ и аналогичното за числителя). ■

16.2 Статистически модел и оценки на параметрите

Дефиниция 16.2 (Статистически модел)

$Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k$, $k = 1, \ldots, n$, където $(\varepsilon_j)_{j=1}^n$ са независими в съвкупност (случайността е единствено в грешките ε_k; стойностите X_k са фиксирани наблюдения), и:

1) $\mathbb{E}\varepsilon_j = 0$;

2) $D\varepsilon_j = \sigma^2$ за всяко j (**хомоскедастичност** - еднаква дисперсия на грешката);

3) $\varepsilon_j \sim N(0, \sigma^2)$.

Оценки по метода на най-малките квадрати

Оценяваме β_0, β_1 чрез метода на най-малките квадрати (формулите от предната теорема, приложени към случайните Y_k):

$$\hat{\beta}_1 = \frac{\sum_{k=1}^{n} Y_k(X_k - \bar{X})}{\sum_{k=1}^{n}(X_k - \bar{X})^2}, \qquad \hat{\beta}_0 = \bar{Y} - \bar{X}\cdot\hat{\beta}_1.$$

От модела: $Y_k \sim N(\beta_0 + \beta_1 X_k, \sigma^2)$, следователно $\mathbb{E}Y_k = \beta_0 + \beta_1 X_k$, $DY_k = \sigma^2$ за всяко k.

Теорема 16.2 (неизместеност на $\hat{\beta}_1$)

$\mathbb{E}\hat{\beta}_1 = \beta_1$.

Доказателство

Нека $A := \sum_{k=1}^{n}(X_k - \bar{X})^2$. Тогава

$$\mathbb{E}\hat{\beta}_1 = \frac{\sum_{k=1}^{n}(\beta_0 + \beta_1 X_k)(X_k - \bar{X})}{A} = \frac{\beta_0\sum_{k=1}^{n}(X_k - \bar{X}) + \beta_1\sum_{k=1}^{n} X_k(X_k - \bar{X})}{A}.$$

Понеже $\sum_k (X_k - \bar{X}) = \sum_k X_k - n\bar{X} = 0$, а по тъждеството от предната теорема $\sum_k X_k(X_k - \bar{X}) = \sum_k (X_k - \bar{X})^2 = A$:

$$\mathbb{E}\hat{\beta}_1 = \frac{0 + \beta_1 \cdot A}{A} = \beta_1.$$ ■

Теорема 16.3 (неизместеност на $\hat{\beta}_0$)

$\mathbb{E}\hat{\beta}_0 = \beta_0$.

Доказателство

$$\mathbb{E}\hat{\beta}_0 = \mathbb{E}\bar{Y} - \bar{X}\,\mathbb{E}\hat{\beta}_1 = \frac{1}{n}\sum_{k=1}^{n}\mathbb{E}Y_k - \beta_1\bar{X} = \frac{1}{n}\sum_{k=1}^{n}(\beta_0+\beta_1 X_k) - \beta_1\bar{X} = \beta_0 + \beta_1\bar{X} - \beta_1\bar{X} = \beta_0. \blacksquare$$

Теорема 16.4 (дисперсии на оценките)

$$D\hat{\beta}_1 = \frac{\sigma^2}{\sum_{k=1}^{n}(X_k-\bar{X})^2}, \qquad D\hat{\beta}_0 = \sigma^2\left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{k=1}^{n}(X_k-\bar{X})^2}\right).$$

Освен това, $\hat{\beta}_1$ и $\hat{\beta}_0$ са линейни комбинации на независими нормални случайни величини (Y_k), следователно самите те са нормално разпределени:

$$\hat{\beta}_1 \sim N\Big(\beta_1,\ \frac{\sigma^2}{\sum_k(X_k-\bar{X})^2}\Big), \qquad \hat{\beta}_0 \sim N\Big(\beta_0,\ \sigma^2\Big(\frac{1}{n} + \frac{\bar{X}^2}{\sum_k(X_k-\bar{X})^2}\Big)\Big).$$

Доказателство

Нека $A = \sum_{k=1}^{n}(X_k-\bar{X})^2$. Понеже (Y_k) са независими, $D(cY_k) = c^2 DY_k$ и дисперсията на сума от независими е сума от дисперсиите (Тема 9):

$$D\hat{\beta}_1 = D\left(\frac{\sum_k Y_k(X_k-\bar{X})}{A}\right) = \frac{1}{A^2}\sum_{k=1}^{n}(X_k-\bar{X})^2\,DY_k = \frac{\sigma^2}{A^2}\sum_{k=1}^{n}(X_k-\bar{X})^2 = \frac{\sigma^2}{A}.$$

За $\hat{\beta}_0$, записваме го директно като линейна комбинация на (Y_k):

$$\hat{\beta}_0 = \frac{1}{n}\sum_{k=1}^{n}Y_k - \bar{X}\cdot\frac{\sum_k Y_k(X_k-\bar{X})}{A} = \sum_{k=1}^{n}Y_k\left(\frac{1}{n} - \frac{\bar{X}(X_k-\bar{X})}{A}\right),$$

и отново по независимостта на (Y_k):

$$D\hat{\beta}_0 = \sum_{k=1}^{n}\left(\frac{1}{n} - \frac{\bar{X}(X_k-\bar{X})}{A}\right)^2 DY_k = \sigma^2\left(\frac{1}{n} + \frac{\bar{X}^2}{A}\right)$$

(след разгръщане на квадрата и опростяване, ползвайки отново $\sum_k(X_k-\bar{X}) = 0$ и $\sum_k(X_k-\bar{X})^2 = A$). $\blacksquare$

16.3 Оценка на дисперсията на грешката

Идея

От модела, $\dfrac{Y_k - \beta_0 - \beta_1 X_k}{\sigma} \sim N(0,1)$, и $\sum_{k=1}^{n} \left(\dfrac{Y_k - \beta_0 - \beta_1 X_k}{\sigma}\right)^2 \sim \chi^2(n)$. Но β_0, β_1 не са ни известни - заместваме ги с оценките $\hat\beta_0, \hat\beta_1$, което (аналогично на загубата на една степен на свобода при замяната на μ с $\hat\mu$ в Тема 15) намалява броя на степените на свобода с 2 (по броя оценени параметри):

$$\sum_{k=1}^{n} \left(\frac{Y_k - \hat\beta_0 - \hat\beta_1 X_k}{\sigma}\right)^2 \sim \chi^2(n-2).$$

Дефиниция 16.3 (Оценка на дисперсията на грешката)

Използвайки, че за $Z_1, \ldots, Z_{n-2} \sim N(0,1)$ независими, $\frac{1}{n-2}\sum_j Z_j^2 \xrightarrow{\text{п.с.}} \mathbb{E}Z_1^2 = 1$ (УЗГЧ, Тема 12), приближаваме $\frac{1}{n-2}\sum_k \left(\frac{Y_k - \hat\beta_0 - \hat\beta_1 X_k}{\sigma}\right)^2 \approx 1$, откъдето получаваме оценката за дисперсията на грешката:

$$\hat\sigma^2 = \frac{\sum_{k=1}^{n} \left(Y_k - \hat\beta_0 - \hat\beta_1 X_k\right)^2}{n-2}.$$

16.4 Проверка на хипотези за наклона

Постановка

Нека искаме да проверим дали наклонът на регресията е равен на конкретна стойност b:

$$H_0 : \ \beta_1 = b \qquad \text{срещу} \qquad H_1 : \ \beta_1 \neq b$$

(аналогично се разглеждат едностранните алтернативи $\beta_1 < b$, $\beta_1 > b$).

Конструкция на теста

При H_0 (т.е. $\beta_1 = b$), по теоремата за разпределението на $\hat\beta_1$: $\hat\beta_1 \sim N\big(b,\ \sigma^2/A\big)$, $A = \sum_k (X_k - \bar X)^2$, следователно

$$\frac{\hat\beta_1 - b}{\sigma/\sqrt{A}} \sim N(0,1).$$

Критичната област за ниво на значимост α (двустранен тест) е

$$W = \left\{ \ |\hat\beta_1 - b| \geq q_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{A}} \ \right\},$$

където $q_{1-\alpha/2}$ е $(1-\alpha/2)$-тият квантил на $N(0,1)$ - отхвърляме H_0, ако наблюдаваната разлика между $\hat\beta_1$ и предполагаемата стойност b е прекалено голяма спрямо стандартното отклонение на оценката.

На практика: неизвестно σ

В горната конструкция приехме σ за известно. На практика σ обикновено не е известно и се замества с оценката $\hat{\sigma}$ от предния раздел, а разпределението на статистиката $\frac{\hat{\beta}_1 - b}{\hat{\sigma}/\sqrt{A}}$ вече не е точно $N(0,1)$, а $t(n-2)$ - напълно аналогично на прехода от Z-тест към t-тест при неизвестна дисперсия за средната стойност (Тема 15).