Тема 7

Ковариация, корелация

7.1 Съвместна функция на разпределение и независимост

Дефиниция 7.1 (Съвместна функция на разпределение)

Нека X, Y са случайни величини. Функцията

$$F_{X,Y}(x,y) := \mathbb{P}(X < x,\, Y < y), \qquad (x,y) \in \mathbb{R}^2,$$

се нарича **съвместна функция на разпределение** на двойката (X,Y). За нея са в сила

$$F_{X,Y}(\infty, y) = F_Y(y), \qquad F_{X,Y}(x,\infty) = F_X(x), \qquad F_{X,Y}(\infty,\infty) = 1, \qquad F_{X,Y}(-\infty, y) = 0.$$

Дефиниция 7.2 (Независимост чрез съвместната функция на разпределение)

Случайните величини X и Y са **независими**, ако

$$F_{X,Y}(x,y) = F_X(x) \cdot F_Y(y), \qquad \forall (x,y) \in \mathbb{R}^2,$$

т.е. $\mathbb{P}(X < x,\, Y < y) = \mathbb{P}(X < x) \cdot \mathbb{P}(Y < y)$.

Следствие 7.1

Ако X, Y са дискретни, дефиницията е еквивалентна на $\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j)$ за всички i, j.

Доказателство

($\Leftarrow$) Нека $\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j)$ за всички i, j. Тогава за произволни x, y:

$$\mathbb{P}(X < x, Y < y) = \sum_{x_i<x}\sum_{y_j<y} \mathbb{P}(X = x_i, Y = y_j) = \sum_{x_i<x}\sum_{y_j<y} \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j)$$

$$= \Big(\sum_{x_i<x} \mathbb{P}(X = x_i)\Big)\Big(\sum_{y_j<y} \mathbb{P}(Y = y_j)\Big) = F_X(x)F_Y(y).$$

($\Rightarrow$) Нека $F_{X,Y}(x, y) = F_X(x)F_Y(y)$ за всички (x, y). Нека x_i, y_j са съседни стойности в носителите на X, Y, а x_i^-, y_j^- означават непосредствено предходната стойност (или $-\infty$, ако x_i/y_j е най-малката). По принципа на включване-изключване:

$$\begin{aligned}\mathbb{P}(X = x_i, Y = y_j) &= F_{X,Y}(x_i^+, y_j^+) - F_{X,Y}(x_i^{-,+}, y_j^+) - F_{X,Y}(x_i^+, y_j^{-,+}) + F_{X,Y}(x_i^{-,+}, y_j^{-,+})\\ &= F_X(x_i)F_Y(y_j) - F_X(x_i^-)F_Y(y_j) - F_X(x_i)F_Y(y_j^-) + F_X(x_i^-)F_Y(y_j^-)\\ &= \big[F_X(x_i) - F_X(x_i^-)\big]\big[F_Y(y_j) - F_Y(y_j^-)\big] = \mathbb{P}(X = x_i)\,\mathbb{P}(Y = y_j).\end{aligned}$$ ■

7.2 Ковариация

Дефиниция 7.3 (Ковариация)

Нека X, Y са случайни величини. Количеството

$$\operatorname{cov}(X, Y) := \mathbb{E}\big[(X - \mathbb{E}X)(Y - \mathbb{E}Y)\big]$$

се нарича **ковариация** на X и Y, ако съществува. Тя измерва как двете случайни величини се изменят заедно. За дискретни X, Y: $\operatorname{cov}(X, Y) = \sum_{i,j}(x_i - \mathbb{E}X)(y_j - \mathbb{E}Y)\,p_{ij}$.

Идея: линейна връзка

Линейна зависимост между две случайни величини имаме, когато $Y = aX + b$. Ковариацията е мярка за *посоката* на линейната връзка. Наистина, ако положим $\widetilde{X} = X - \mathbb{E}X$, $\widetilde{Y} = Y - \mathbb{E}Y$ (центрирани версии), то от $Y = aX + b$ следва

$$Y - \mathbb{E}Y = a(X - \mathbb{E}X) \iff \widetilde{Y} = a\widetilde{X},$$

т.е. центрирането не променя линейната зависимост между величините - то само премества центъра в началото на координатната система.

Теорема 7.1

Нека X, Y са случайни величини. Тогава

$$\operatorname{cov}(X, Y) = \mathbb{E}\widetilde{X}\widetilde{Y} = \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y, \qquad \widetilde{X} = X - \mathbb{E}X,\ \widetilde{Y} = Y - \mathbb{E}Y.$$

Доказателство

$$\begin{aligned}\mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) &= \mathbb{E}\big[XY - Y\,\mathbb{E}X - X\,\mathbb{E}Y + \mathbb{E}X\,\mathbb{E}Y\big]\\ &= \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y - \mathbb{E}Y\,\mathbb{E}X + \mathbb{E}X\,\mathbb{E}Y = \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y.\end{aligned}$$ ■

Забележка: скалиране

Преминаването $X, Y \to X - \mathbb{E}X,\ Y - \mathbb{E}Y$ не променя зависимостта между X и Y, а само центрира величините. От друга страна, скалирането $X, Y \to 10X, 10Y$ скалира ковариацията квадратично:

$$\operatorname{cov}(10X, 10Y) = \mathbb{E}(10X - 10\,\mathbb{E}X)(10Y - 10\,\mathbb{E}Y) = 100\,\mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) = 100\operatorname{cov}(X, Y).$$

Свойства 7.2 (на ковариацията)

1) **Симетрия:** $\operatorname{cov}(X, Y) = \operatorname{cov}(Y, X)$.
2) $\operatorname{cov}(X, X) = DX$.
3) **Линейност:** $\operatorname{cov}(aX + b,\ cY + d) = ac \cdot \operatorname{cov}(X, Y)$.
4) **Адитивност:** $\operatorname{cov}(X + Z,\ Y) = \operatorname{cov}(X, Y) + \operatorname{cov}(Z, Y)$.
5) Ако $X \perp\!\!\!\perp Y$, то $\operatorname{cov}(X, Y) = 0$.

Доказателство

1) Директно от дефиницията: $\operatorname{cov}(X, Y) = \mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) = \mathbb{E}(Y - \mathbb{E}Y)(X - \mathbb{E}X) = \operatorname{cov}(Y, X)$.
2) $\operatorname{cov}(X, X) = \mathbb{E}X \cdot X - \mathbb{E}X \cdot \mathbb{E}X = \mathbb{E}X^2 - (\mathbb{E}X)^2 = DX$.
3) Ползвайки формулата $\operatorname{cov}(U, V) = \mathbb{E}UV - \mathbb{E}U\,\mathbb{E}V$ и линейността на очакването:

$$\begin{aligned}\operatorname{cov}(aX + b, cY + d) &= \mathbb{E}\big[(aX + b)(cY + d)\big] - \mathbb{E}(aX + b)\,\mathbb{E}(cY + d)\\ &= \mathbb{E}\big[ac\,XY + ad\,X + bc\,Y + bd\big] - (a\,\mathbb{E}X + b)(c\,\mathbb{E}Y + d)\\ &= ac\,\mathbb{E}XY + ad\,\mathbb{E}X + bc\,\mathbb{E}Y + bd - \big(ac\,\mathbb{E}X\,\mathbb{E}Y + ad\,\mathbb{E}X + bc\,\mathbb{E}Y + bd\big)\\ &= ac\big(\mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y\big) = ac \cdot \operatorname{cov}(X, Y).\end{aligned}$$

4) Аналогично:

$$\begin{aligned}\operatorname{cov}(X + Z, Y) &= \mathbb{E}\big[(X + Z)Y\big] - \mathbb{E}(X + Z)\,\mathbb{E}Y = \mathbb{E}XY + \mathbb{E}ZY - (\mathbb{E}X + \mathbb{E}Z)\mathbb{E}Y\\ &= \big(\mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y\big) + \big(\mathbb{E}ZY - \mathbb{E}Z\,\mathbb{E}Y\big) = \operatorname{cov}(X, Y) + \operatorname{cov}(Z, Y).\end{aligned}$$

5) Ако $X \perp\!\!\!\perp Y$, по свойството за очакване на произведение на независими случайни величини (Тема 5), $\mathbb{E}XY = \mathbb{E}X\,\mathbb{E}Y$, следователно $\operatorname{cov}(X, Y) = \mathbb{E}XY - \mathbb{E}X\,\mathbb{E}Y = 0$. *(Обратното не е вярно в общия случай - нулева ковариация не означава непременно независимост.)* ■

7.3 Корелация

Дефиниция 7.4 (Корелация)

Нека X, Y са случайни величини с $0 < DX < \infty$, $0 < DY < \infty$ (т.е. нито едната не е почти сигурно константа). Тогава

$$\rho(X, Y) := \frac{\operatorname{cov}(X, Y)}{\sqrt{DX}\sqrt{DY}}$$

се нарича **корелация** (коефициент на корелация) между X и Y.

Инвариантност спрямо мащаб

За разлика от ковариацията, корелацията е инвариантна спрямо (положително) мащабиране:

$$\rho(10X, 10Y) = \frac{100\,\mathrm{cov}(X,Y)}{\sqrt{D(10X)}\sqrt{D(10Y)}} = \frac{100\,\mathrm{cov}(X,Y)}{10\sqrt{DX}\cdot 10\sqrt{DY}} = \frac{\mathrm{cov}(X,Y)}{\sqrt{DX}\sqrt{DY}} = \rho(X,Y).$$

Теорема 7.3

Нека X, Y са случайни величини с $0 < DX < \infty$, $0 < DY < \infty$, и нека $\bar{X} = \dfrac{X - \mathbb{E}X}{\sqrt{DX}}$, $\bar{Y} = \dfrac{Y - \mathbb{E}Y}{\sqrt{DY}}$ (**стандартизирани** случайни величини). Тогава $\mathbb{E}\bar{X} = \mathbb{E}\bar{Y} = 0$, $D\bar{X} = D\bar{Y} = 1$, и

$$\rho(X,Y) = \mathbb{E}\bar{X}\bar{Y}.$$

Доказателство

$\mathbb{E}\bar{X} = \mathbb{E}\dfrac{X - \mathbb{E}X}{\sqrt{DX}} = \dfrac{1}{\sqrt{DX}}\,\mathbb{E}(X - \mathbb{E}X) = 0$, понеже $\mathbb{E}(X - \mathbb{E}X) = \mathbb{E}X - \mathbb{E}X = 0$. Аналогично $\mathbb{E}\bar{Y} = 0$.

$D\bar{X} = D\Big(\dfrac{X - \mathbb{E}X}{\sqrt{DX}}\Big) = \dfrac{1}{(\sqrt{DX})^2}\,D(X - \mathbb{E}X) = \dfrac{1}{DX}\cdot DX = 1$ (изваждането на константа $\mathbb{E}X$ не променя дисперсията). Аналогично $D\bar{Y} = 1$.

Накрая:

$$\rho(X,Y) = \frac{\mathrm{cov}(X,Y)}{\sqrt{DX}\sqrt{DY}} = \mathbb{E}\left(\frac{X - \mathbb{E}X}{\sqrt{DX}}\right)\left(\frac{Y - \mathbb{E}Y}{\sqrt{DY}}\right) = \mathbb{E}\bar{X}\bar{Y}.\blacksquare$$

Теорема 7.4

Нека X, Y са случайни величини с $0 < DX < \infty$, $0 < DY < \infty$. Тогава:

а) $|\rho(X,Y)| \le 1$;

б) $|\rho(X,Y)| = 1 \iff Y = aX + b$ за някои $a, b \in \mathbb{R}$ (т.е. Y се предопределя линейно от X).

Доказателство

а) Нека $\bar{X}, \bar{Y}$ са стандартизираните величини от предната теорема, така че $\rho(X,Y) = \mathbb{E}\bar{X}\bar{Y}$. Понеже $D\bar{X} = \mathbb{E}\bar{X}^2 - (\mathbb{E}\bar{X})^2 = 1$ и $\mathbb{E}\bar{X} = 0$, следва $\mathbb{E}\bar{X}^2 = 1$; аналогично $\mathbb{E}\bar{Y}^2 = 1$. Разглеждаме

$$0 \le \mathbb{E}(\bar{X} \pm \bar{Y})^2 = \mathbb{E}\bar{X}^2 \pm 2\,\mathbb{E}\bar{X}\bar{Y} + \mathbb{E}\bar{Y}^2 = 1 \pm 2\rho(X,Y) + 1 = 2\big(1 \pm \rho(X,Y)\big),$$

откъдето $1 \pm \rho(X,Y) \ge 0$ и за двата знака, т.е. $-1 \le \rho(X,Y) \le 1$, или $|\rho(X,Y)| \le 1$.
б) ($\Rightarrow$) Нека $\rho(X,Y) = 1 = \mathbb{E}\bar{X}\bar{Y}$. От горното с избор на знак „$-$“:

$$\mathbb{E}(\bar{X} - \bar{Y})^2 = 1 - 2\rho(X,Y) + 1 = 1 - 2 + 1 = 0.$$

Понеже $(\bar{X} - \bar{Y})^2 \ge 0$ и очакването му е нула, следва $(\bar{X} - \bar{Y})^2 = 0$ (с вероятност 1), т.е. $\bar{X} = \bar{Y}$. Записвайки explicitno $\bar{X} = \dfrac{X - \mathbb{E}X}{\sqrt{DX}}$, $\bar{Y} = \dfrac{Y - \mathbb{E}Y}{\sqrt{DY}}$, от $\bar{X} = \bar{Y}$ получаваме

$$Y = \sqrt{\frac{DY}{DX}}\,X + \Big(\mathbb{E}Y - \sqrt{\frac{DY}{DX}}\,\mathbb{E}X\Big) =: aX + b,$$

където $a = \sqrt{DY/DX} \ge 0$ (в случая $\rho(X,Y) = -1$ разсъждението е аналогично с избор на знак „$+$“, и се получава $a \le 0$).
б) ($\Leftarrow$) Нека $Y = aX + b$. Тогава $\mathbb{E}Y = a\,\mathbb{E}X + b$, $DY = D(aX+b) = a^2 DX$, и

$$\rho(X,Y) = \frac{\mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y)}{\sqrt{DX}\sqrt{DY}} = \frac{\mathbb{E}(X - \mathbb{E}X)(aX + b - a\,\mathbb{E}X - b)}{\sqrt{DX}\sqrt{a^2 DX}}$$
$$= \frac{a\,\mathbb{E}(X - \mathbb{E}X)^2}{|a|\,DX} = \frac{a\,DX}{|a|\,DX} = \frac{a}{|a|} = \pm 1.\blacksquare$$