Тема 14

Точкови оценки

14.1 Постановка

Идея

Нека X описва някакво свойство на генерална съвкупност, с функция на разпределение $F_X(x) = \mathbb{P}(X < x)$ (или плътност f_X). Разполагаме с **извадка** $\bar{X} = (X_1, \ldots, X_n)$, където $(X_i)_{i=1}^n$ са i.i.d. (независими наблюдения над X, $X_i \overset{d}{=} X$), и искаме на базата на извадката да определим или приближим F_X (респ. f_X). Важно е да отбележим: това, че знаем f_X или F_X, не означава, че познаваме случайния изход X предварително - знаем само разпределението му.

Допускане: параметричен клас

Допускаме, че X принадлежи на някакъв **клас** от случайни величини $F_X(x;\theta)$, където θ е параметър (или вектор от параметри), асоцииран с възможните разпределения на X. Например:

- $\theta = p$: $X \sim Be(p)$, $p \in (0,1)$;
- $\theta = \lambda$: $X \sim Exp(\lambda)$, $F_X(x;\lambda) = 1 - e^{-\lambda x}$, $\lambda > 0$;
- $\theta = (\mu, \sigma^2)$: $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$.

Дефиниция 14.1 (Точкова оценка)

Нека X е от класа $F_X(x;\theta)$ и нека $\bar{X} = (X_1, \ldots, X_n)$ е извадка от независими наблюдения над X. Функцията $\hat{\theta} = \hat{\theta}(\bar{X})$ се нарича **точкова оценка** (или **статистика**) за θ. Тъй като $\hat{\theta}$ е функция на случайни величини, самата $\hat{\theta}$ е случайна величина; за конкретна реализация $\bar{x} = (x_1, \ldots, x_n)$ получаваме конкретно число $\hat{\theta} = \hat{\theta}(\bar{x})$.

14.2 Максимално правдоподобни оценки

Дефиниция 14.2 (Функция на правдоподобие)

Нека X е от класа $f_X(x;\theta)$ (или дискретна с $f(x;\theta) = \mathbb{P}(X = x;\theta)$) и $\bar{X} = (X_1, \ldots, X_n)$ е извадка от независими наблюдения над X. **Функцията на правдоподобие** е съвместната плътност на извадката:

$$L(\bar{X};\theta) = \prod_{j=1}^{n} f_X(X_j;\theta).$$

Дефиниция 14.3 (Максимално правдоподобна оценка, МПО)

Нека Θ е множеството от възможни стойности на θ. Оценката $\hat{\theta}$, за която

$$L(\bar{X}, \hat{\theta}) = \sup_{\theta \in \Theta} \prod_{j=1}^{n} f(X_j; \theta),$$

се нарича **максимално правдоподобна оценка** за θ. Т.е. $\hat{\theta}$ е стойността на параметъра, за която функцията на правдоподобие достига максимум - интуитивно, тази стойност на θ, при която наблюдаваната извадка би била „най-вероятна“.

Логаритмуване

Ако f_X е диференцируема по θ, МПО обикновено се търси чрез $\dfrac{\partial L}{\partial \theta} = 0$ или (по-удобно на практика) чрез $\dfrac{\partial \ln L}{\partial \theta} = 0$ - понеже логаритъмът е монотонна функция, L и $\ln L$ достигат максимум в една и съща точка.

Пример: едно наблюдение от $N(\mu, 1)$

Нека $X \sim N(\mu, 1)$ и $\bar{X} = X_1 = x_1$ (едно единствено наблюдение). Тогава $L(\bar{X}, \mu) = f_X(x_1, \mu)$ - плътността на $N(\mu, 1)$, изчислена в точката x_1, като функция на μ. Тя се максимизира, когато центърът на камбанката съвпада точно с наблюдението, т.е. $\hat{\mu} = x_1$ (интуитивно: измежду всички възможни центрове μ, стойността $\mu = x_1$ прави наблюдението x_1 „най-вероятно“).

Теорема 14.1

Нека $X \sim N(\mu, \sigma^2)$ и $\bar{X} = (X_1, \ldots, X_n)$ са независими наблюдения над X. Тогава МПО за μ е

$$\hat{\mu} = \overline{X}_n = \frac{1}{n} \sum_{j=1}^{n} X_j$$

(винаги, независимо дали σ^2 е известно), а МПО за σ^2 зависи от това дали μ е известно:

а) $\hat{\sigma}^2 = \dfrac{1}{n} \sum_{j=1}^{n} (X_j - \mu)^2$ (ако μ е известно),

б) $\hat{\sigma}^2 = \dfrac{1}{n} \sum_{j=1}^{n} (X_j - \overline{X}_n)^2$ (ако μ не е известно).

Доказателство

Функцията на правдоподобие е

$$L(\bar{X},\theta)=\left(\frac{1}{\sqrt{2\pi}}\right)^n(\sigma^2)^{-n/2}\,e^{-\sum_{j=1}^n\frac{(X_j-\mu)^2}{2\sigma^2}},\qquad \theta=(\mu,\sigma^2),$$

следователно

$$\ln L(\bar{X},\theta)=-\frac{n}{2}\ln(2\pi)-\frac{n}{2}\ln(\sigma^2)-\sum_{j=1}^n\frac{(X_j-\mu)^2}{2\sigma^2}.$$

Диференцираме по μ и приравняваме на нула:

$$\frac{\partial\ln L}{\partial\mu}=\frac{1}{\sigma^2}\sum_{j=1}^n(X_j-\mu)=0\quad\Longrightarrow\quad\hat{\mu}=\overline{X}_n$$

(независимо от стойността на σ^2). Диференцираме по σ^2:

$$\frac{\partial\ln L}{\partial\sigma^2}=-\frac{n}{2\sigma^2}+\frac{1}{2\sigma^4}\sum_{j=1}^n(X_j-\mu)^2=0.$$

Ако μ е известно, решаваме директно: $\hat{\sigma}^2=\frac{1}{n}\sum_{j=1}^n(X_j-\mu)^2$. Ако μ не е известно, заместваме неговата МПО оценка $\hat{\mu}=\overline{X}_n$ (решавайки системата от двете уравнения едновременно): $\hat{\sigma}^2=\frac{1}{n}\sum_{j=1}^n(X_j-\overline{X}_n)^2$. ■

Пример: $X\sim U(0,\theta)$

Нека $f_X(x)=\frac{1}{\theta}\,I_{[0,\theta]}(x)$, $\theta>0$. Тогава

$$L(\bar{X},\theta)=\prod_{j=1}^n\frac{1}{\theta}\,I_{[0,\theta]}(X_j)=\begin{cases}\dfrac{1}{\theta^n}, & \theta\geq\max_{1\leq j\leq n}X_j\\ 0, & \theta<\max_{1\leq j\leq n}X_j\end{cases}.$$

Понеже $\frac{1}{\theta^n}$ намалява по θ, функцията на правдоподобие е максимална при най-малкото допустимо θ, т.е.

$$\hat{\theta}=\max_{1\leq j\leq n}X_j.$$

14.3 Метод на моментите

Идея

От усиления закон за големите числа (Тема 12), за i.i.d. извадка: $\overline{X}_n^{(j)}:=\frac{1}{n}\sum_{k=1}^n X_k^j\xrightarrow{\text{п.с.}}\mathbb{E}X^j$ за всеки ред на момента j (стига моментът да съществува). Идеята на метода на моментите е да *изравним* теоретичните моменти (функции на θ) с емпиричните моменти от извадката и да решим спрямо θ.

Дефиниция 14.4 (Метод на моментите, ММ)

Нека X е случайна величина от клас $F_X(x;\theta)$, $\theta = (\theta_1, \dots, \theta_s)$, и $\bar{X}$ е извадка. Ако първите s момента на X съществуват, полагаме $\mu^{(j)}(\theta) := \mathbb{E}X^j$, $1 \le j \le s$, и емпиричните моменти $\overline{X}_n^{(j)} = \frac{1}{n}\sum_{k=1}^n X_k^j$. Тогава **оценката по метода на моментите** $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_s)$ се получава чрез решаване на системата (спрямо целия вектор θ едновременно - за $s \ge 2$ всеки момент обикновено зависи от *няколко* от параметрите, така че координатно обръщане по компоненти на θ най-често не е възможно)

$$\mu^{(j)}(\theta) = \overline{X}_n^{(j)}, \qquad 1 \le j \le s.$$

При $s = 1$ системата е едно уравнение с едно неизвестно и решението приема простия вид $\hat{\theta} = \big(\mu^{(1)}\big)^{-1}\big(\overline{X}_n^{(1)}\big)$.

Пример: $X \sim U(0, \theta)$

$\mu^{(1)}(\theta) = \mathbb{E}X = \frac{\theta}{2}$. Изравняваме с $\overline{X}_n^{(1)}$: $\frac{\theta}{2} = \overline{X}_n^{(1)} \Rightarrow \hat{\theta} = 2\overline{X}_n^{(1)} = 2\overline{X}_n$ - различна от МПО оценката $\max_j X_j$, но също разумна оценка на θ.

Пример: $X \sim N(\mu, \sigma^2)$, *двата параметъра неизвестни*

Тук $\theta = (\mu, \sigma^2)$, а системата е $\mathbb{E}X = \overline{X}_n^{(1)}$, $\mathbb{E}X^2 = \overline{X}_n^{(2)}$. От $\mathbb{E}X = \mu$ получаваме $\hat{\mu} = \overline{X}_n^{(1)} = \overline{X}_n$. От $\mathbb{E}X^2 = DX + (\mathbb{E}X)^2 = \sigma^2 + \mu^2$ получаваме

$$\hat{\sigma}^2 = \overline{X}_n^{(2)} - \hat{\mu}^2 = \overline{X}_n^{(2)} - \big(\overline{X}_n^{(1)}\big)^2,$$

което съвпада точно с МПО оценката от предната теорема (в случая, когато μ не е известно) - в този пример методът на моментите и методът на максималното правдоподобие дават *една и съща* оценка.

14.4 Свойства на точковите оценки

Дефиниция 14.5 (Неизместеност)

Казваме, че $\hat{\theta}$ е **неизместена** (несмесена) оценка за θ, ако $\mathbb{E}\hat{\theta}(\bar{X}) = \theta$ (респ. $\mathbb{E}\hat{\theta}_j = \theta_j$ за всяко $1 \le j \le s$, ако $\theta = (\theta_1, \dots, \theta_s)$). Величината $|\mathbb{E}\hat{\theta} - \theta|$ се нарича **систематична грешка** на $\hat{\theta}$.

Пример: $\hat{\mu} = \overline{X}_n$, $X \sim N(\mu, \sigma^2)$

$$\mathbb{E}\hat{\mu} = \mathbb{E}\Big(\frac{1}{n}\sum_{j=1}^n X_j\Big) = \frac{1}{n}\sum_{j=1}^n \mathbb{E}X_j = \frac{1}{n}\cdot n\mu = \mu \quad \Longrightarrow \quad \hat{\mu} \text{ е неизместена.}$$

Пример: дисперсията, ако μ ***е известно***

$\hat{\sigma}^2 = \frac{1}{n}\sum_{j=1}^n (X_j - \mu)^2$:

$$\mathbb{E}\hat{\sigma}^2 = \frac{1}{n}\sum_{j=1}^n \mathbb{E}(X_j - \mu)^2 = \frac{1}{n}\cdot n\sigma^2 = \sigma^2 \quad \Longrightarrow \quad \hat{\sigma}^2 \text{ е неизместена.}$$

Пример: дисперсията, ако μ не е известно (важен случай!)

Нека $\hat\sigma^2 = \frac{1}{n}\sum_{j=1}^n (X_j - \overline{X}_n)^2 = \overline{X}_n^{(2)} - \big(\overline{X}_n^{(1)}\big)^2$ (разписано чрез разкриване на квадрата, аналогично на $DX = \mathbb{E}X^2 - (\mathbb{E}X)^2$). Тогава

$$\mathbb{E}\hat\sigma^2 = \mathbb{E}\overline{X}_n^{(2)} - \mathbb{E}\big(\overline{X}_n^{(1)}\big)^2 = \mathbb{E}X_1^2 - \frac{1}{n^2}\,\mathbb{E}\Big(\sum_{j=1}^n X_j^2 + \sum_{i\neq j} X_iX_j\Big).$$

Понеже (X_i) са i.i.d., $\mathbb{E}\sum_j X_j^2 = n\,\mathbb{E}X_1^2$, а за $i \neq j$ (независими, $\mathbb{E}X_iX_j = \mathbb{E}X_i\,\mathbb{E}X_j = \mu^2$) има точно $n(n-1)$ наредени двойки, следователно:

$$\begin{aligned}\mathbb{E}\hat\sigma^2 &= \mathbb{E}X_1^2 - \frac{1}{n^2}\Big(n\,\mathbb{E}X_1^2 + n(n-1)\mu^2\Big) = \Big(1-\frac{1}{n}\Big)\mathbb{E}X_1^2 - \frac{n-1}{n}\mu^2\\ &= \frac{n-1}{n}\big(\mathbb{E}X_1^2 - \mu^2\big) = \frac{n-1}{n}\,\sigma^2 \neq \sigma^2.\end{aligned}$$

Следователно тази оценка е **изместена**, със систематична грешка $|\mathbb{E}\hat\sigma^2 - \sigma^2| = \frac{\sigma^2}{n}$. Но $\mathbb{E}\hat\sigma^2 = \frac{n-1}{n}\sigma^2 \to \sigma^2$ при $n\to\infty$ - казваме, че $\hat\sigma^2$ е **асимптотично неизместена**. *(Затова на практика често се предпочита нормираната с $\frac{1}{n-1}$ версия на извадковата дисперсия - тя е точно неизместена.)*

Пример: $X \sim U(0,\theta)$, МПО оценката $\hat\theta = \max_j X_j$

Намираме плътността на $\hat\theta$:

$$F_{\hat\theta}(x) = \mathbb{P}\Big(\max_{1\le j\le n} X_j \le x\Big) = \prod_{j=1}^n \mathbb{P}(X_j \le x) = \big(\mathbb{P}(X_1\le x)\big)^n = \begin{cases}0, & x\le 0\\ (x/\theta)^n, & x\in(0,\theta)\\ 1, & x\ge\theta\end{cases}$$

(използвахме независимостта на (X_j)), следователно $f_{\hat\theta}(x) = \frac{n}{\theta^n}x^{n-1}$ за $x\in(0,\theta)$. Тогава

$$\mathbb{E}\hat\theta = \int_0^\theta x\cdot\frac{n}{\theta^n}x^{n-1}\,dx = \frac{n}{\theta^n}\int_0^\theta x^n\,dx = \frac{n}{\theta^n}\cdot\frac{\theta^{n+1}}{n+1} = \frac{n}{n+1}\,\theta < \theta,$$

т.е. $\hat\theta$ е **изместена** оценка, но $\frac{n}{n+1}\theta \to \theta$ при $n\to\infty$, т.е. тя е **асимптотично неизместена**.

Дефиниция 14.6 (Състоятелност)

Нека $\hat\theta = \hat\theta(\bar X)$ е точкова оценка на θ (респ. $\theta = (\theta_1,\dots,\theta_s)$). Казваме, че $\hat\theta$ е **състоятелна** оценка на θ, ако

$$\hat\theta \xrightarrow[n\to\infty]{\mathbb{P}} \theta \qquad \Big(\text{еквивалентно: } \forall\varepsilon>0:\ \mathbb{P}\big(|\hat\theta(\bar X)-\theta|>\varepsilon\big)\xrightarrow[n\to\infty]{} 0\Big)$$

(вероятността за грешка намалява, когато броят на наблюденията в извадката расте).

Дефиниция 14.7 (Силна състоятелност)

Казваме, че $\hat\theta$ е **силно състоятелна** оценка на θ, ако $\hat\theta \xrightarrow[n\to\infty]{\text{п.с.}} \theta$. От теоремата за видовете сходимост (Тема 12), силната състоятелност влече състоятелност.

Пример:** $\hat{\mu} = \overline{X}_n$ **е силно състоятелна

По усиления закон за големите числа (Тема 12), директно приложен към i.i.d. извадката (X_j): $\overline{X}_n = \frac{1}{n}\sum_j X_j \xrightarrow{\text{п.с.}} \mathbb{E}X_1 = \mu$.

Пример:** $\hat{\sigma}^2 = \overline{X}_n^{(2)} - (\overline{X}_n^{(1)})^2$ **е силно състоятелна

По УЗГЧ, приложен поотделно към редиците (X_j) и (X_j^2): $\overline{X}_n^{(1)} \xrightarrow{\text{п.с.}} \mathbb{E}X_1 = \mu$ и $\overline{X}_n^{(2)} \xrightarrow{\text{п.с.}} \mathbb{E}X_1^2$. Функцията $g(a,b) = b - a^2$ е непрекъсната, следователно

$$\hat{\sigma}^2 = \overline{X}_n^{(2)} - \left(\overline{X}_n^{(1)}\right)^2 \xrightarrow[n\to\infty]{\text{п.с.}} \mathbb{E}X_1^2 - \mu^2 = \sigma^2,$$

т.е. $\hat{\sigma}^2$ е силно състоятелна (макар да е изместена за крайно n, видяхме по-горе).