Тема 16

Линейна регресия

16.1 Модел на линейната регресия

Дефиниция 16.1 (Модел на линейната регресия)

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

където Y е **отклик** (обяснявана величина), X е **предиктор** (обясняваща величина), а ε е случайна грешка. За наблюденията $(X_k, Y_k)_{k=1}^n$: $Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k$. Навсякъде по-долу приемаме, че не всички X_k са равни, т.е. $\sum_{k=1}^n (X_k - \bar{X})^2 > 0$ (иначе наклонът β_1 не е идентифицируем от данните).

Метод на най-малките квадрати

Търсим оценки b_0, b_1 на β_0, β_1, минимизиращи сумата на квадратите на грешките:

$$\min_{b_0,b_1} \sum_{k=1}^n \left(y_k - b_0 - b_1 x_k\right)^2 = \min_{b_0,b_1} \sum_{k=1}^n (y_k - \hat{y}_k)^2, \qquad \hat{y}_k := b_0 + b_1 x_k.$$

Теорема 16.1

Решението на горната задача за минимизация е

$$b_1 = \frac{\sum_{k=1}^n y_k (x_k - \bar{x})}{\sum_{k=1}^n (x_k - \bar{x})^2} \quad \text{(наклон на правата)},$$

$$b_0 = \bar{y} - \bar{x} \cdot b_1 \quad \text{(пресечна точка с ординатата)},$$

където $\bar{x} = \frac{1}{n}\sum_k x_k$, $\bar{y} = \frac{1}{n}\sum_k y_k$.

Доказателство

Нека $f(b_0, b_1) = \sum_{k=1}^{n}(y_k - b_0 - b_1 x_k)^2$. Приравняваме частните производни на нула:

$$0 = \frac{\partial f}{\partial b_0} = -2\sum_{k=1}^{n}(y_k - b_0 - b_1 x_k), \qquad 0 = \frac{\partial f}{\partial b_1} = -2\sum_{k=1}^{n}(y_k - b_0 - b_1 x_k)x_k.$$

От първото уравнение: $n\bar{y} - nb_0 - b_1 n\bar{x} = 0 \Rightarrow b_0 = \bar{y} - b_1\bar{x}$. Заместваме във второто:

$$\sum_{k=1}^{n} x_k y_k - nb_0\bar{x} - b_1\sum_{k=1}^{n} x_k^2 = 0 \quad \Longrightarrow \quad b_1 = \frac{\sum_k x_k y_k - n\bar{x}\bar{y}}{\sum_k x_k^2 - n\bar{x}^2} = \frac{\sum_k y_k(x_k - \bar{x})}{\sum_k (x_k - \bar{x})^2}$$

(последното преобразуване използва тъждеството $\sum_k (x_k - \bar{x})^2 = \sum_k x_k^2 - n\bar{x}^2 = \sum_k x_k(x_k - \bar{x})$ и аналогичното за числителя). ■

16.2 Статистически модел и оценки на параметрите

Дефиниция 16.2 (Статистически модел)

$Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k$, $k = 1, \ldots, n$, където $(\varepsilon_j)_{j=1}^n$ са независими в съвкупност (случайността е единствено в грешките ε_k; стойностите X_k са фиксирани наблюдения), и:

1) $\mathbb{E}\varepsilon_j = 0$;

2) $D\varepsilon_j = \sigma^2$ за всяко j (**хомоскедастичност** - еднаква дисперсия на грешката);

3) $\varepsilon_j \sim N(0, \sigma^2)$.

Оценки по метода на най-малките квадрати

Оценяваме β_0, β_1 чрез метода на най-малките квадрати (формулите от предната теорема, приложени към случайните Y_k):

$$\hat{\beta}_1 = \frac{\sum_{k=1}^{n} Y_k(X_k - \bar{X})}{\sum_{k=1}^{n}(X_k - \bar{X})^2}, \qquad \hat{\beta}_0 = \bar{Y} - \bar{X}\cdot\hat{\beta}_1.$$

От модела: $Y_k \sim N(\beta_0 + \beta_1 X_k, \sigma^2)$, следователно $\mathbb{E}Y_k = \beta_0 + \beta_1 X_k$, $DY_k = \sigma^2$ за всяко k.

Теорема 16.2 (неизместеност на $\hat{\beta}_1$)

$\mathbb{E}\hat{\beta}_1 = \beta_1$.

Доказателство

Нека $A := \sum_{k=1}^{n}(X_k - \bar{X})^2$. Тогава

$$\mathbb{E}\hat{\beta}_1 = \frac{\sum_{k=1}^{n}(\beta_0 + \beta_1 X_k)(X_k - \bar{X})}{A} = \frac{\beta_0\sum_{k=1}^{n}(X_k - \bar{X}) + \beta_1\sum_{k=1}^{n} X_k(X_k - \bar{X})}{A}.$$

Понеже $\sum_k (X_k - \bar{X}) = \sum_k X_k - n\bar{X} = 0$, а по тъждеството от предната теорема $\sum_k X_k(X_k - \bar{X}) = \sum_k (X_k - \bar{X})^2 = A$:

$$\mathbb{E}\hat{\beta}_1 = \frac{0 + \beta_1 \cdot A}{A} = \beta_1.$$ ■

Теорема 16.3 (неизместеност на $\hat{\beta}_0$)

$\mathbb{E}\hat{\beta}_0 = \beta_0$.

Доказателство

$$\mathbb{E}\hat{\beta}_0 = \mathbb{E}\bar{Y} - \bar{X}\,\mathbb{E}\hat{\beta}_1 = \frac{1}{n}\sum_{k=1}^{n}\mathbb{E}Y_k - \beta_1\bar{X} = \frac{1}{n}\sum_{k=1}^{n}(\beta_0+\beta_1 X_k) - \beta_1\bar{X} = \beta_0 + \beta_1\bar{X} - \beta_1\bar{X} = \beta_0. \blacksquare$$

Теорема 16.4 (дисперсии на оценките)

$$D\hat{\beta}_1 = \frac{\sigma^2}{\sum_{k=1}^{n}(X_k-\bar{X})^2}, \qquad D\hat{\beta}_0 = \sigma^2\left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{k=1}^{n}(X_k-\bar{X})^2}\right).$$

Освен това, $\hat{\beta}_1$ и $\hat{\beta}_0$ са линейни комбинации на независими нормални случайни величини (Y_k), следователно самите те са нормално разпределени:

$$\hat{\beta}_1 \sim N\Big(\beta_1,\ \frac{\sigma^2}{\sum_k(X_k-\bar{X})^2}\Big), \qquad \hat{\beta}_0 \sim N\Big(\beta_0,\ \sigma^2\Big(\frac{1}{n} + \frac{\bar{X}^2}{\sum_k(X_k-\bar{X})^2}\Big)\Big).$$

Доказателство

Нека $A = \sum_{k=1}^{n}(X_k-\bar{X})^2$. Понеже (Y_k) са независими, $D(cY_k) = c^2 DY_k$ и дисперсията на сума от независими е сума от дисперсиите (Тема 9):

$$D\hat{\beta}_1 = D\left(\frac{\sum_k Y_k(X_k-\bar{X})}{A}\right) = \frac{1}{A^2}\sum_{k=1}^{n}(X_k-\bar{X})^2\,DY_k = \frac{\sigma^2}{A^2}\sum_{k=1}^{n}(X_k-\bar{X})^2 = \frac{\sigma^2}{A}.$$

За $\hat{\beta}_0$, записваме го директно като линейна комбинация на (Y_k):

$$\hat{\beta}_0 = \frac{1}{n}\sum_{k=1}^{n}Y_k - \bar{X}\cdot\frac{\sum_k Y_k(X_k-\bar{X})}{A} = \sum_{k=1}^{n}Y_k\left(\frac{1}{n} - \frac{\bar{X}(X_k-\bar{X})}{A}\right),$$

и отново по независимостта на (Y_k):

$$D\hat{\beta}_0 = \sum_{k=1}^{n}\left(\frac{1}{n} - \frac{\bar{X}(X_k-\bar{X})}{A}\right)^2 DY_k = \sigma^2\left(\frac{1}{n} + \frac{\bar{X}^2}{A}\right)$$

(след разгръщане на квадрата и опростяване, ползвайки отново $\sum_k(X_k-\bar{X}) = 0$ и $\sum_k(X_k-\bar{X})^2 = A$). $\blacksquare$

16.3 Оценка на дисперсията на грешката

Идея

От модела, $\dfrac{Y_k - \beta_0 - \beta_1 X_k}{\sigma} \sim N(0,1)$, и $\sum_{k=1}^{n} \left(\dfrac{Y_k - \beta_0 - \beta_1 X_k}{\sigma}\right)^2 \sim \chi^2(n)$. Но β_0, β_1 не са ни известни - заместваме ги с оценките $\hat\beta_0, \hat\beta_1$, което (аналогично на загубата на една степен на свобода при замяната на μ с $\hat\mu$ в Тема 15) намалява броя на степените на свобода с 2 (по броя оценени параметри):

$$\sum_{k=1}^{n} \left(\frac{Y_k - \hat\beta_0 - \hat\beta_1 X_k}{\sigma}\right)^2 \sim \chi^2(n-2).$$

Дефиниция 16.3 (Оценка на дисперсията на грешката)

Използвайки, че за $Z_1, \ldots, Z_{n-2} \sim N(0,1)$ независими, $\frac{1}{n-2}\sum_j Z_j^2 \xrightarrow{\text{п.с.}} \mathbb{E}Z_1^2 = 1$ (УЗГЧ, Тема 12), приближаваме $\frac{1}{n-2}\sum_k \left(\frac{Y_k - \hat\beta_0 - \hat\beta_1 X_k}{\sigma}\right)^2 \approx 1$, откъдето получаваме оценката за дисперсията на грешката:

$$\hat\sigma^2 = \frac{\sum_{k=1}^{n} \left(Y_k - \hat\beta_0 - \hat\beta_1 X_k\right)^2}{n-2}.$$

16.4 Проверка на хипотези за наклона

Постановка

Нека искаме да проверим дали наклонът на регресията е равен на конкретна стойност b:

$$H_0 : \ \beta_1 = b \qquad \text{срещу} \qquad H_1 : \ \beta_1 \neq b$$

(аналогично се разглеждат едностранните алтернативи $\beta_1 < b$, $\beta_1 > b$).

Конструкция на теста

При H_0 (т.е. $\beta_1 = b$), по теоремата за разпределението на $\hat\beta_1$: $\hat\beta_1 \sim N\big(b,\ \sigma^2/A\big)$, $A = \sum_k (X_k - \bar X)^2$, следователно

$$\frac{\hat\beta_1 - b}{\sigma/\sqrt{A}} \sim N(0,1).$$

Критичната област за ниво на значимост α (двустранен тест) е

$$W = \left\{ \ |\hat\beta_1 - b| \geq q_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{A}} \ \right\},$$

където $q_{1-\alpha/2}$ е $(1-\alpha/2)$-тият квантил на $N(0,1)$ - отхвърляме H_0, ако наблюдаваната разлика между $\hat\beta_1$ и предполагаемата стойност b е прекалено голяма спрямо стандартното отклонение на оценката.

На практика: неизвестно σ

В горната конструкция приехме σ за известно. На практика σ обикновено не е известно и се замества с оценката $\hat{\sigma}$ от предния раздел, а разпределението на статистиката $\frac{\hat{\beta}_1 - b}{\hat{\sigma}/\sqrt{A}}$ вече не е точно $N(0,1)$, а $t(n-2)$ - напълно аналогично на прехода от Z-тест към t-тест при неизвестна дисперсия за средната стойност (Тема 15).